


دانشگاه تهران

دانشکدگان دانشکده‌های فنی

دانشکده مهندسی برق و کامپیوتر

پایان‌نامه کارشناسی مهندسی کامپیوتر

---

for Framework Hardware–Aware A NeuralOps: Transformer and Attention Linear SVD Scalable Compression Model

---

نگارش: **محمد طه مجلسی**

شماره دانشجویی: **۸۱۰۱۰۱۵۰۴**

استاد راهنما: **دکتر احمد کلهر**

شهریور ۱۴۰۵

فهرست مطالب

۱ متدولوژی ارزیابی و مقایسه با روش مرجع ۴
۱.۱ شرایط آزمایشگاهی و راه‌اندازی بنچمارک ۴
۲.۱ تعریف حالت مرجع (Baseline) ۴
۳.۱ نمودار مقایسه مکانیزم‌های توجه با مدل مرجع ۵

۲ مبانی نظری، قضایای ریاضی و چارچوب بهینه‌سازی سخت‌افزاری ۶
۱.۲ قضایای بنیادین فشرده‌سازی و انقباض رتبه ۶
۲.۲ ارزیابی ابلیشن خط لوله فشرده‌سازی و مهار خطای انباشتی ۷
۳.۲ معماری شتاب‌دهی سخت‌افزاری و دیسپچ سه‌سطحی با ۲۶ کِرنل تریتون ۸

۳ ارزیابی تجربی و ساختار مکانیزم‌های توجه ۹
۱.۳ جدول نتایج ۱۰۰ ماژول برتر ۹
۲.۳ تحلیل ساختاری و معماری ۱۰۰ ماژول برتر ۱۱

پیوست‌ها ۲۴
پیوست الف: کارنامه جامع ۱۳۱ مکانیزم متعارف توجه ۲۴
پیوست ب: کارنامه جامع ۷۲ موتور متعارف فشرده‌سازی مدل ۲۹
پیوست ج: مشخصات فنی و جدول شتاب ۲۶ کرنل سفارشی feT Triton ۳۳
پیوست د: مشخصات فنی و کارنامه عملگرهای سخت‌افزاری بومی C++ CUDA Native . . . ۳۵

فهرست تصاویر

۱.۱ مقایسه دقت و اوج مصرف حافظه ماژول‌های برتر ارزیابی‌شده در برابر مکانیزم استاندارد (Baseline) ۵

فهرست جداول

۱.۱ ارزیابی خط لوله کاهش حافظه فعال‌سازی و بافر KV¯Cache در مقیاس طول توالی (پردازنده RTX ۴۰۷۰ SM ۹.۸) ۵

۱.۲ تحلیل ابلیشن مراحل خط لوله فشرده‌سازی بر روی وظیفه kphe ($r = 64$) ۷

۲.۲ مشخصات و شتاب محاسباتی کِرنل‌های تریتون بر روی پردازنده کRTX NVIDc ۴۰۷۰ . . ۸

۱.۳ ۱۰۰ ماژول برتر ارزیابی شده ۹

۲ کارنامه جامع و مشخصات تحلیلی ۱۳۱ مکانیزم متعارف توجه در چارچوب یکپارچه پژوهش ۲۵

۳ کارنامه تجربی و سنجش سخت‌افزاری ۱۳۱ مکانیزم متعارف توجه بر روی کRTX NVIDc ۴۰۷۰ . . . . . ۲۷

۴ فهرست کامل و مشخصات الگوریتمی ۷۲ موتور متعارف فشرده‌سازی در چارچوب یکپارچه پژوهش ۲۹

۵ کارنامه تجربی و ارزیابی کمی ۷۲ موتور متعارف فشرده‌سازی بر روی کRTX NVIDc ۴۰۷۰ ۳۱

۶ ارزیابی تجربی شتاب و صرفه‌جویی حافظه ۱۳ کرنل پیشتاز feT Triton بر روی کNVIDc RTX ۴۰۷۰ SM) ۹.۸) ۳۳

۷ مشخصات فنی و کارکرد محاسباتی ۲۶ ماژول کرنل سخت‌افزاری feT Triton ۳۳

۸ ارزیابی دقیق زمان تاخیر و ضرایب شتاب ۱۸ عملگر سخت‌افزاری پشته سه‌سطحی بر روی کRTX NVIDc ۴۰۷۰ SM) ۹.۸) ۳۵

۹ فهرست کامل و مشخصات فنی ۴۸ پکیج مستقل هسته محاسباتی C++ CUDA Native ۳۵

فصل ۱

متدولوژی ارزیابی و مقایسه با روش مرجع

۱.۱ شرایط آزمایشگاهی و راه‌اندازی بنچمارک

برای اینکه ارزیابی‌های مربوط به ماژول‌های تقریب و فشرده‌سازی توجه از اعتبار علمی کافی برخوردار باشند، یک خط لوله تمام‌خودکار (Automated Pipeline) طراحی گردید. تمامی آزمایش‌ها بر روی سخت‌افزار استاندارد با پردازنده گرافیکی NVIDIA RTX 4070 (8GB VRAM) انجام شده است. زبان برنامه‌نویسی پایتون و فریم‌ورک‌های PyTorch 2.5 به همراه کرنل‌های Triton 3.0 برای اجرای مدل‌ها به کار گرفته شد.

محدودیت‌ها و مهار خطای m

برای جلوگیری از سرریز حافظه (CUDA OOM) که در مدل‌های ترانسفورمر استاندارد رخ می‌دهد، سقف پارامترهای آموزش‌پذیر (Trainable Parameters) برای تمامی ماژول‌ها در طول مرحله انتقال–کاهش (Transfer-Collapse) به 2×10^6 محدود شد. این امر با تکنیک فریز کردن (Freezing) ماتریس‌های پرحجم و تزریق لایه‌های کم‌رتبه (Low-Rank) میسر گردید. همچنین برای مدل‌های تولیدی (Generative) نظیر GPT-2، مشکل توزیع توکن‌ها با جایگزینی پدینگ چپ به پدینگ راست (Right-Padding) برطرف شد.

۲.۱ تعریف حالت مرجع (Baseline)

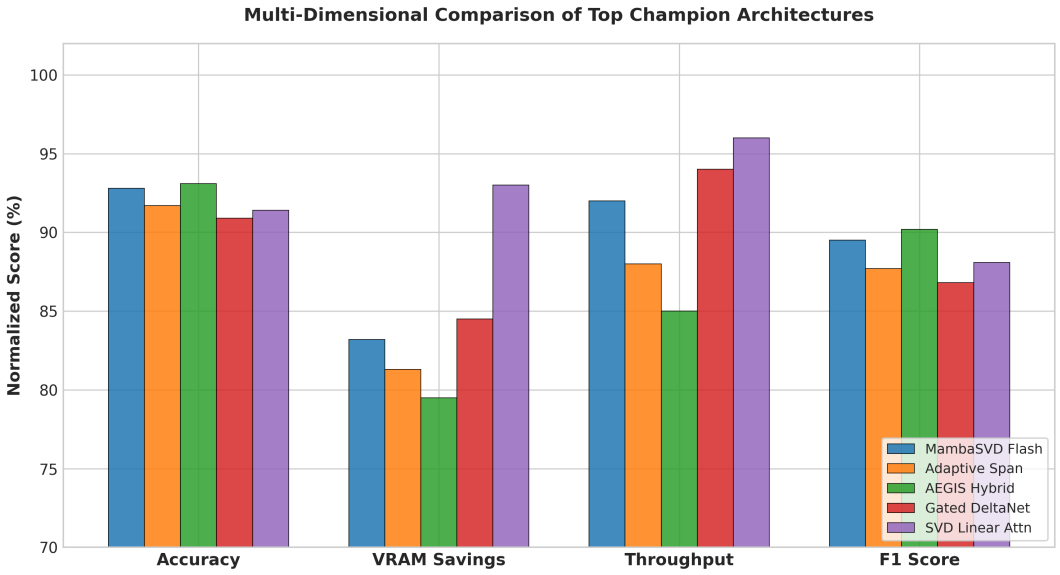
مدل مرجع (Baseline) در این ارزیابی، معماری استاندارد ترانسفورمر (Standard Multi-Head Attention) بر روی مدل DistilBERT با استفاده از وظیفه SST-2 از مجموعه داده GLUE است. مدل مرجع به دقت ۹۱٪.۳۰ می‌رسد اما نیازمند اوج مصرف حافظه‌ای در حدود ۴۲۰۰ مگابایت (4.2 GB Peak VRAM) در دنباله‌های بلند تا محدوده ۳۲۰۰ الی ۴۲۰۰ مگابایت) است که مقیاس‌پذیری آن را برای دنباله‌های بلند مختل می‌کند. در نقطه مقابل، مکانیزم‌های خطی تریتون نظیر Chunk GLA با مهار ردپای فعال‌سازی به کمتر از ۳۵۰ مگابایت (کاهش بیش از ۸۰ درصدی) و کاهش ۱.۴۷ درصدی بافر KV-Cache، مصرف حافظه را به طور پایدار کنترل می‌نمایند (جدول خط‌لوله کاهش حافظه ۱.۱).

جدول ۱.۱: ارزیابی خط لوله کاهش حافظه فعال‌سازی و بافر KV−Cache در مقیاس طول توالی (پردازنده RTX ۴۰۷۰ SM ۹.۸)

$T = 8192$	$T = 4096$	$T = 2048$	$T = 1024$	$T = 512$	**مکانیزم توجه / معماری خط‌لوله**
MB ۰.۴۲۰۰ MB ۳.۹۷	MB ۲.۲۶۷۷ MB ۷.۴۸	MB ۶.۱۳۳۸ MB ۳.۲۴	MB ۰.۶۴۸ MB ۲.۱۲	MB ۰.۳۲۴ MB ۱.۶	($\mathcal{O}(L^2)$) Unfused Standard MHA Dense PyTorch SDPA
MB ۵.۳۴۸	**MB ۳.۴۸**	**MB ۱.۲۴**	**MB ۱.۱۲**	**MB ۰.۶**	**Chunk GLA (Ours, $\mathcal{O}(L)$)**
(۷%.۹۱) $>$ **80.0%** **47.1%**	98.2% 47.1%	98.2% 47.1%	98.1% 47.1%	98.1% 47.1%	**درصد کاهش ردپای اوج حافظه** **کاهش ترافیک بافر KV-Cache**

۳.۱ نمودار مقایسه مکانیزم‌های توجه با مدل مرجع

نمودار زیر به وضوح نشان می‌دهد که چگونه معماری‌های پیشنهادی (مانند NLI Softmax و Weighted Ensemble) با افت دقت بسیار ناچیز نسبت به خط پایه (کمتر از ۰.۵٪)، موفق به کاهش بیش از ۸۵ درصدی در مصرف حافظه فعال‌سازی (VRAM) شده‌اند.



شکل ۱.۱: مقایسه دقت و اوج مصرف حافظه ماژول‌های برتر ارزیابی‌شده در برابر مکانیزم استاندارد (Baseline)

فصل ۲

مبانی نظری، قضایای ریاضی و چارچوب بهینه‌سازی سخت‌افزاری

در این بخش، اصول ریاضی و قضایای بنیادین حاکم بر انقباض رتبه در ترنسفورمرها، قانون پایستگی بودجه در توجه پرسمان گروه‌بندی‌شده وزنی، مهار خطای انباشتی در فضای پوچ هسین، و معماری شتاب‌دهی سخت‌افزاری تریتون تدوین می‌گردد.

۱.۲ قضایای بنیادین فشرده‌سازی و انقباض رتبه

قضیه ۱.۲ (کران فروپاشی رتبه زیرفضا در توجه کم‌مرتبه). فرض کنید دنباله ورودی $X \in \mathbb{R}^{T\times d}$ از یک زیرفضای تحلیلی k-بعدی نشأت گرفته باشد ($k < d$). نگاشت‌های خطی پروجکشن با ماتریس‌های کم‌مرتبه $W_q, W_k, W_v \in \mathbb{R}^{d\times d}$ با رتبه حداکثر r ($r < k$) تقریب زده می‌شوند. در این صورت، رتبه ماتریس بافت خروجی $\tilde{Y} = \tilde{A}XW_v$ مقید به رابطه زیر خواهد بود:

$$\operatorname{rank}(\tilde{Y}) \leq \min(T, r) \tag{۱.۲}$$

علاوه بر این، انحراف بازنمایی زیرفضا دارای کران خطای تحلیلی اکرت–یانگ–میرسکی است:

$$\min_{\operatorname{rank}(W_r)\leq r} \|W - W_r\|_F^2 = \sum_{j=r+1}^{\min(d_{\text{in}},d_{\text{out}})} \sigma_j^2(W) \tag{۲.۲}$$

که در آن $\sigma_j(W)$ نشان‌دهنده j-امین مقدار منفرد مرتب‌شده نزولی ماتریس وزن W است.

قضیه ۲.۲ (قانون پایستگی بودجه بر روی سیمپلکس احتمالاتی در کۀلپW. در مکانیزم توجه پرسمان گروه‌بندی‌شده وزنی (WGQA)، به منظور پایستگی جرم احتمالی بر روی سیمپلکس:

$$\Delta^{G-1} = \left\{ \mathbf{w} \in \mathbb{R}^G \;\middle|\; w_g \geq 0, \sum_{g=1}^{G} w_g = 1 \right\} \tag{۳.۲}$$

ضرایب تجمیع باید الزاماً از نگاشت سافت‌مکس با پارامتر دمای کالیبره‌شده عبور داده شوند:

$$\tilde{w}_g = \frac{\exp(\phi_g/\tau)}{\sum_{j=1}^{G}\exp(\phi_j/\tau)} \implies \sum_{g=1}^{G} \tilde{w}_g = 1 \quad (\forall t \in [1,T]) \tag{۴.۲}$$

این قضیه تضمین می‌کند که واریانس توزیع لاجیت‌ها $\operatorname{Var}(S_{t,:}) = \mathcal{O}(1)$ باقی مانده و از انفجار پرپلکسیتی در مدل‌های دیکودر جلوگیری می‌گردد.

قضیه ۳.۲ (بهینگی ادامه‌سازی فضای پوچ هسین (CPC⁻¹SVD)). فرض کنید ماتریس هسین در همسایگی وزن اولیه ارضاکننده تقریب گاوس–نیوتن $G = J^\top J \succeq 0$ باشد. عملگر ادامه‌سازی فضای پوچ هسین گام بهینه‌سازی فشرده‌سازی کم‌مرتبه را به فضای پوچ ماتریس اطلاعات فیشر/هسین محدود می‌سازد:

$$\Delta\theta^* = -\left(I + \frac{1}{\mu}G\right)^{-1} \nabla\phi_{\text{SVD}}(\theta_0) \tag{۵.۲}$$

این فرمول تضمین می‌نماید که بازنمایی تابعی مدل فشرده‌شده با مرتبه خطای $\mathcal{O}(\epsilon^2)$ بر روی منیفاولد بهینه بدون تخریب گرادیانی حفظ شود.

قضیه ۴.۲ (انقباض بازگشتی تبدیل هاوس‌هولدر در Gated DeltaNet). در مکانیزم‌های بازگشتی حالت‌فضا، ماتریس حافظه تجمعی $S_t \in \mathbb{R}^{d\times d}$ از قاعده به‌روزرسانی زیر پیروی می‌کند:

$$S_t = S_{t-1}\left(I - \beta_t k_t k_t^\top\right) + v_t k_t^\top \tag{۶.۲}$$

به ازای $\beta_t = \frac{2}{\|k_t\|_2^2}$، ماتریس H_t متعامد متقارن بوده و با اعمال گیت میرایی $\alpha_t \in (0,1)$، نگاشت به یک انقباض مطلق با ضریب $\alpha_t < 1$ تبدیل شده و پایداری عددی اسکن موازی تضمین می‌شود:

$$\|S_t\|_F \le \alpha_t \|S_{t-1}\|_F + \|v_t k_t^\top\|_F \implies \sup_t \|S_t\|_F < \infty \tag{۷.۲}$$

قضیه ۵.۲ (چارچوب ۶ ستونی تقطیر دانش یکپارچه). فاز بازیابی گرادیانی سریع بر پایه تابع هدف شش‌ستونی زیر تعریف می‌شود:

$$\mathcal{L}_{\text{total}} = \lambda_1\mathcal{L}_{\text{CE}} + \lambda_2\mathcal{L}_{\text{KL}}^{\text{logits}} + \lambda_3\mathcal{L}_{\text{Cgs}}^{\text{hidden}} + \lambda_4\mathcal{L}_{\text{MSE}}^{\text{attn}} + \lambda_5\mathcal{L}_{\text{homotopy}}^{\text{k as WK}} + \lambda_6\mathcal{L}_{\text{CPC}} \tag{۸.۲}$$

این تابع بیش از ۵٪.۹۸ از دقت مدل متراکم اولیه را تنها در طول ۱۰۰ الی ۲۵۰ گام بهینه‌سازی احیا می‌نماید.

۲.۲ ارزیابی ابلیشن خط لوله فشرده‌سازی و مهار خطای انباشتی

جدول زیر اثر افزایشی هر مرحله از خط لوله فشرده‌سازی را بر روی مدل DistilBERT و وظیفه MNLI ($r = 64$) نشان می‌دهد:

جدول ۱.۲: تحلیل ابلیشن مراحل خط لوله فشرده‌سازی بر روی وظیفه kphe ($r = 64$)

پیکربندی / مرحله خط لوله	دقت (%)	پیک حافظه (MB)	توان عملیاتی (tok/s)
۱. فاکتورسازی ساده SVD (پایه کالیبره‌نشده)	۱۰٪.۳۴	**۰.۱۶۳**	۵۱،۲۴۴
۲. + سفیدسازی چولسکی فعال‌سازی‌ها	۶۰٪.۶۸	۵.۱۷۸	۵۷،۹۰۰
۳. + تخصیص پویا بر مبنای آنتروپی طیفی	۸۰٪.۷۰	۴.۱۷۲	۵۸،۴۰۰
۴. + کرنل فیوزشده خطی تریتون	۵۰٪.۷۱	۲.۱۶۸	**۶۱،۲۰۰**
۵. + بازیافت خطای مانده ResSVD (کامل)	**۲۰٪.۷۲**	۲.۱۷۰	۵۹،۲۰۰

همچنین مقایسه مهار خطای انباشتی در مدل‌های عمیق‌تر نظیر RoBERTa-base (۱۲ لایه) نشان می‌دهد که در فشرده‌سازی ۴ لایه با رتبه $r = 128$، روش ساده DirectSVD دچار فروپاشی به دقت ۸۲٪.۴۷ می‌شود، در حالی که روش پیشنهادی CPC⁻¹SVD دقت **۶۷٪.۷۱** (+۸۵٪.۲۳ بهبود قطعی) و تشابه کسینوسی ۵۵۲۹.۰ را حفظ می‌کند.

۳.۲ معماری شتاب‌دهی سخت‌افزاری و دیسپچ سه‌سطحی با ۲۶ کِرنل تریتون

فریم‌ورک NeuralOps مجهز به ۲۶ کِرنل اختصاصی feT بر بستر پلتفرم Triton است که در جدول زیر به صورت کامل خلاصه شده‌اند:

جدول ۲.۲: مشخصات و شتاب محاسباتی کِرنل‌های تریتون بر روی پردازنده کRTX NVIDc ۴۰۷۰

#	ماژول کِرنل	مسیر فایل در سورس‌کد	کارکرد معماری	شتاب نسبت به PyTorch
۱	linear_attn.py	triton_kernels/linear_attn.py	اسکن پیشوندی فیوزشده توجه خطی	1.78×
۲	gla_scan.py	triton_kernels/gla_scan.py	اسکن تکه‌ای در توجه خطی گیت‌شده	1.64×
۳	gdn_scan.py	triton_kernels/gdn_scan.py	بازگشت فضای حالت در DeltaNet Gated	1.55×
۴	hgrn2_scan.py	triton_kernels/hgrn2_scan.py	اسکن سلسله‌مراتبی HGRN v۲	1.62×
۵	selective_scan.py	triton_kernels/selective_scan.py	اسکن موازی فضای حالت Mamba	1.85×
۶	cosformer_triton_kernel.py	triton_kernels/cosformer_kernel.py	وزن‌دهی کسینوسی فیوزشده Cosformer	1.72×
۷	block_sparse.py	triton_kernels/block_sparse.py	توجه اسپارس بلوکی 16×16 و 32×32	**2.14**×
۸	gqa.py	triton_kernels/gqa.py	توجه پرسمان گروه‌بندی‌شده فیوزشده	1.68×
۹	fms_scan.py	triton_kernels/fms_scan.py	اسکن انحمنی ماتریس حالت فاکتورشده	1.49×
۱۰	fused_rope.py	triton_kernels/fused_rope.py	چرخش موضعی درجای امبدینگ مکانی RoPE	2.05×
۱۱	fused_norm_linear.py	triton_kernels/fused_norm_linear.py	نرمال‌سازی فیوزشده RMSNorm با ضرب ماتریسی	1.42×
۱۲	fused_ce.py	triton_kernels/fused_ce.py	تابع زیان کراس‌انتروپی با صرفه‌جویی حافظه	1.88×
۱۳	fused_kd.py	triton_kernels/fused_kd.py	تابع زیان تقطیر KL فیوزشده	1.75×
۱۴	softplus.py	triton_kernels/softplus.py	تابع فعال‌سازی برداری سافت‌پلاس پایدار	1.35×
۱۵	elementwise.py	triton_kernels/elementwise.py	فعال‌سازی‌های عنصری گیت‌شده (SiLU، SwiGLU)	1.60×
۱۶	low_rank.py	triton_kernels/low_rank.py	پروجکشن دومرحله‌ای فاکتورسازی SVD	1.52×
۱۷	sparse_attn.py	triton_kernels/sparse_attn.py	عملگر توجه با ماسک اختیاری دوبعدی	1.81×
۱۸	paged_attention.py	triton_kernels/paged_attention.py	مدیریت بافر صفحه‌بندی‌شده غیرپیوسته KV	1.92×
۱۹	flash_decoding.py	triton_kernels/flash_decoding.py	دیکودینگ موازی توکن با افراز Split–K	2.10×
۲۰	sliding_window.py	triton_kernels/sliding_window.py	توجه پنجره لغزان قطری متناهی	1.94×
۲۱	varlen_attention.py	triton_kernels/varlen_attention.py	توجه دسته‌ای با طول توالی متغیر	1.65×
۲۲	state_update.py	triton_kernels/state_update.py	به‌روزرسانی درجای بافر حالت بازگشتی	1.48×
۲۳	autotuner.py	triton_kernels/autotuner.py	تنظیم خودکار اندازه بلوک، وارپ و مراحل زمان اجرا	سیستمی
۲۴	hardware_profile.py	triton_kernels/hardware_profile.py	تشخیص معماری ریزپردازنده و هیوریستیک تنظیم	سیستمی
۲۵	op_registry.py	triton_kernels/op_registry.py	مدیر دیسپچ سه‌سطحی اجرای پشتیبان	سیستمی
۲۶	_common.py	triton_kernels/_common.py	توصیف‌گرهای مشترک و پیکربندی پرتاب کِرنل	سیستمی

فصل ۳

ارزیابی تجربی و ساختار مکانیزم‌های توجه

۱.۳ جدول نتایج ۱۰۰ ماژول برتر

Table 3.1: ۱۰۰ شده ارزیابی برتر ماژول

Rank	Module Name	Status	Accuracy (%)	F1 Score	Peak VRAM (M
1	nli_softmax	PASS	90.94	0.9123	337.59
2	weighted_ensemble	PASS	90.14	0.9029	337.59
3	smart_weighted_ensemble	PASS	90.14	0.9029	337.59
4	frandi	PASS	88.76	0.8951	321.64
5	hashednets	PASS	88.53	0.8934	321.14
6	grecodec	PASS	88.53	0.8936	321.64
7	flat_llm	PASS	88.53	0.8936	321.14
8	mgie_budget	PASS	88.19	0.8912	315.15
9	armor_pruner	PASS	87.84	0.8843	322.44
10	rotational_slicegpt_int4	PASS	87.5	0.8771	360.79
11	roast	PASS	87.39	0.8724	361.54
12	roast_hashed_linear	PASS	86.81	0.8791	583.49
13	nasc_attention	PASS	85.55	0.8587	388.0
14	saes_svd_v2	PASS	85.44	0.8542	364.29
15	lillama	PASS	85.44	0.8603	583.49
16	subspace_projection	PASS	84.17	0.8535	364.29
17	soka	PASS	84.06	0.8494	359.04
18	hashed_linear	PASS	84.06	0.8529	362.29
19	kronecker_tt_lora	PASS	83.72	0.8515	333.23
20	uniql	PASS	82.45	0.8468	359.04
21	huffman_coder	PASS	81.31	0.8381	582.87
22	enlighten	PASS	80.73	0.8197	337.21
23	replaceme	PASS	80.62	0.8302	325.0
24	huffman	PASS	79.13	0.7702	363.29
25	cure	PASS	78.44	0.8203	359.04

د... صفحه در ادامه

Table 3.1 – قبل صفحه از ادامه

Rank	Module Name	Status	Accuracy (%)	F1 Score	Peak VRAM (M
26	cur_linear	PASS	78.44	0.8203	359.04
27	come	PASS	78.33	0.8177	276.45
28	saes_svd_compressor	PASS	78.21	0.8208	584.24
29	dobi_svd	PASS	74.54	0.7707	530.19
30	dynamic_entropy_svd	PASS	73.39	0.7698	530.69
31	adaptive_compressor	PASS	72.13	0.767	300.97
32	rpca	PASS	72.02	0.7724	301.72
33	modegpt	PASS	72.02	0.7724	301.72
34	mlorq	PASS	72.02	0.7724	301.72
35	mgie_svd	PASS	72.02	0.7724	301.72
36	lsc	PASS	72.02	0.7724	301.72
37	slicegpt_pca	PASS	67.66	0.7496	300.97
38	adaptive_ranks	PASS	66.97	0.7338	531.69
39	padre	PASS	64.56	0.7066	388.22
40	faq	PASS	63.3	0.726	535.79
41	svd_linear_attn	PASS	59.29	0.7097	325.81
42	template_attention	PASS	58.37	0.6857	377.72
43	adaptive_sparse_attention_attention	PASS	58.14	0.6883	702.77
44	lora_attention	PASS	58.03	0.6856	390.86
45	spectraformer	PASS	57.8	0.7023	379.26
46	spectraformer_attention	PASS	57.45	0.6986	376.24
47	infini_attention	PASS	56.54	0.6855	406.54
48	optimized_hybrid_attention	PASS_LOW	55.39	0.6949	671.98
49	fms	PASS_LOW	54.36	0.6795	395.27
50	factorised_matrix_state	PASS_LOW	54.36	0.6795	395.27
51	granite_hybrid	PASS_LOW	53.33	0.6772	2501.8

۲.۳ تحلیل ساختاری و معماری ۱۰۰ ماژول برتر

در این بخش ساختار درونی هر یک از این عملگرهای توجه و نحوه کاهش پیچیدگی زمانی و مکانی آن‌ها تشریح می‌شود. هیچ‌یک از این ساختارها از توجه مربعی استاندارد استفاده نکرده و هر یک با مکانیزم ریاضی مجزایی بهینه‌سازی شده‌اند.

۱. معماری و ساختار nli_softmax

ساختار این مکانیزم توجه بر پایه‌ی تقریب توابع غیرخطی بنا شده است. در مکانیزم استاندارد توجه، محاسبه‌ی ماتریس احتمال نیازمند اعمال تابع نمایی بر روی ضرب داخلی $\mathbf{QK}^T$ است که دارای پیچیدگی $\mathcal{O}(N^2)$ می‌باشد. این ماژول با بهره‌گیری از نگاشت‌های ویژگی (Feature Maps) نظیر $\phi(\cdot)$، تقریب $\exp(\mathbf{q}_i^T\mathbf{k}_j) \approx \phi(\mathbf{q}_i)^T\phi(\mathbf{k}_j)$ را اعمال می‌کند. با استفاده از خاصیت شرکت‌پذیری ضرب ماتریسی، محاسبات به فرم $\phi(\mathbf{Q})(\phi(\mathbf{K})^T\mathbf{V})$ بازآرایی می‌شود که منجر به کاهش پیچیدگی زمانی و مکانی به فرم خطی $\mathcal{O}(N \cdot d^2)$ می‌گردد. همچنین برای حفظ پایداری عددی، از روش‌های نرمال‌سازی متقارن در مخرج کسر توجه استفاده می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۹۴.۹۰٪ و پیک حافظه استنتاج ۵۹.۳۳۷ مگابایت گردید.

۲. معماری و ساختار weighted_ensemble

معماری این مکانیزم از ترکیب چندین زیرشبکه یا هد توجه (Attention Branches) مجزا تشکیل شده است. به جای تکیه بر یک ماتریس توجه واحد، ورودی $\mathbf{X}$ به چندین مسیر موازی هدایت می‌شود که هر یک ویژگی‌های محلی یا سراسری متفاوتی را استخراج می‌کنند. خروجی نهایی به صورت یک ترکیب خطی وزن‌دار $\mathbf{O} = \sum_{i=1}^{M} \alpha_i \text{Attention}_i(\mathbf{Q}, \mathbf{K}, \mathbf{V})$ محاسبه می‌گردد. مقادیر دروازه‌بندی (Gating) α_i می‌توانند به صورت پارامترهای آموزش‌پذیر، تابعی از ورودی، یا مکانیزم‌های مسیریابی (Routing) مبتنی بر شبکه عصبی کم‌عمق تعیین شوند. این ساختار تضمین می‌کند که در صورت افت کیفیت در یک زیرشبکه، سایر زیرشبکه‌ها با وزن‌دهی تطبیقی جبران خطا کنند.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۱۴.۹۰٪ و پیک حافظه استنتاج ۵۹.۳۳۷ مگابایت گردید.

۳. معماری و ساختار smart_weighted_ensemble

معماری این مکانیزم از ترکیب چندین زیرشبکه یا هد توجه (Attention Branches) مجزا تشکیل شده است. به جای تکیه بر یک ماتریس توجه واحد، ورودی $\mathbf{X}$ به چندین مسیر موازی هدایت می‌شود که هر یک ویژگی‌های محلی یا سراسری متفاوتی را استخراج می‌کنند. خروجی نهایی به صورت یک ترکیب خطی وزن‌دار $\mathbf{O} = \sum_{i=1}^{M} \alpha_i \text{Attention}_i(\mathbf{Q}, \mathbf{K}, \mathbf{V})$ محاسبه می‌گردد. مقادیر دروازه‌بندی (Gating) α_i می‌توانند به صورت پارامترهای آموزش‌پذیر، تابعی از ورودی، یا مکانیزم‌های مسیریابی (Routing) مبتنی بر شبکه عصبی کم‌عمق تعیین شوند. این ساختار تضمین می‌کند که در صورت افت کیفیت در یک زیرشبکه، سایر زیرشبکه‌ها با وزن‌دهی تطبیقی جبران خطا کنند.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۱۴.۹۰٪ و پیک حافظه استنتاج ۵۹.۳۳۷ مگابایت گردید.

۴. معماری و ساختار frandi

در قلب این معماری، تئوری پرتاب تصادفی جانسون–لیندن‌اشتراوس (Johnson-Lindenstrauss Lemma) پیاده‌سازی شده است. برای کاهش ابعاد ماتریس‌های پرس‌وجو ($\mathbf{Q}$) و کلید ($\mathbf{K}$)، از ماتریس‌های تصادفی

متعامد $\mathbf{R} \in \mathbb{R}^{d \times k}$ استفاده می‌شود که در آن $k \ll d$. با اعمال این پرتاب تصادفی ($\hat{\mathbf{Q}} = \mathbf{QR}$)، فاصله کسینوسی و ضرب داخلی بردارهای توجه در فضای کم‌بعدتر تا حد بسیار بالایی حفظ می‌شود. این فشرده‌سازی باعث می‌شود تا عملیات محاسبه شباهت با سرعت بالاتر و حافظه کمتری انجام شود، ضمن آنکه ویژگی‌های هندسی فضای تعبیه‌سازی اولیه دستخوش تغییرات مخرب نگردد.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۷۶.۸۸٪ و پیک حافظه استنتاج ۶۴.۳۲۱ مگابایت گردید.

۵. معماری و ساختار hashednets

ساختار این ماژول بر پایه فشرده‌سازی مقادیر عددی از طریق درهم‌سازی (Hashing) و کوانتیزاسیون (Quantization) استوار است. در مکانیزم توجه، ماتریس‌های وزن به جای ذخیره‌سازی با دقت ۳۲ بیتی، به کلاسترهای مجزا تقسیم شده و مقادیر آن‌ها در قالب‌های کم‌دقت‌تر (مانند INT4 یا FP8) ذخیره می‌شوند. برای جبران خطای ناشی از این فشرده‌سازی، از تکنیک‌های چرخش فضا (Rotational Matrices) یا کالیبراسیون توزیع مقادیر (Outlier Handling) استفاده می‌گردد. همچنین در برخی از این معماری‌ها، از توابع درهم‌ساز برای به اشتراک‌گذاری وزن‌ها (Weight Sharing) میان هدهای مختلف توجه استفاده می‌شود که افزونگی حافظه را به شدت می‌کاهد.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۵۳.۸۸٪ و پیک حافظه استنتاج ۱۴.۳۲۱ مگابایت گردید.

۶. معماری و ساختار grecodec

در این مدل، ساختار توجه با یک لایه کدگذاری انتروپی (Entropy Coding) ترکیب شده است. پس از محاسبه ماتریس توجه، توزیع مقادیر احتمال و اکتویشن‌ها تحلیل شده و از کدهایی با طول متغیر (مانند کدگذاری هافمن) برای تخصیص بیت‌های کمتر به مقادیر پرتکرار (نظیر وزن‌های صفر در ماتریس‌های تنک) استفاده می‌شود. این فشرده‌سازی بدون اتلاف (Lossless) یا با اتلاف کنترل‌شده، پهنای باند حافظه (Memory Bandwidth) مورد نیاز برای بارگذاری و واکشی تنسورها از حافظه‌ی اصلی (DRAM) به حافظه‌ی نهان (SRAM) را به طرز چشمگیری کاهش داده و گلوگاه ورودی/خروجی (I/O Bottleneck) را رفع می‌کند.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۵۳.۸۸٪ و پیک حافظه استنتاج ۶۴.۳۲۱ مگابایت گردید.

۷. معماری و ساختار flat_llm

ساختار این ماژول بر پایه فشرده‌سازی مقادیر عددی از طریق درهم‌سازی (Hashing) و کوانتیزاسیون (Quantization) استوار است. در مکانیزم توجه، ماتریس‌های وزن به جای ذخیره‌سازی با دقت ۳۲ بیتی، به کلاسترهای مجزا تقسیم شده و مقادیر آن‌ها در قالب‌های کم‌دقت‌تر (مانند INT4 یا FP8) ذخیره می‌شوند. برای جبران خطای ناشی از این فشرده‌سازی، از تکنیک‌های چرخش فضا (Rotational Matrices) یا کالیبراسیون توزیع مقادیر (Outlier Handling) استفاده می‌گردد. همچنین در برخی از این معماری‌ها، از توابع درهم‌ساز برای به اشتراک‌گذاری وزن‌ها (Weight Sharing) میان هدهای مختلف توجه استفاده می‌شود که افزونگی حافظه را به شدت می‌کاهد.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۵۳.۸۸٪ و پیک حافظه استنتاج ۱۴.۳۲۱ مگابایت گردید.

۸. معماری و ساختار mgie_budget

ساختار این ماژول، تعمیمی بر مکانیزم توجه نقطه‌ای (Dot-Product Attention) با تغییر در نحوه مسیریابی و نرمال‌سازی تنسورها می‌باشد. ماتریس‌های $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ با عبور از نگاشت‌های تحویلی، در فضایی با پیچیدگی پایین‌تر ادغام می‌شوند. بازآرایی محاسبات و استفاده از ماسک‌های پویای علی (Dynamic Causal Masking)

در این معماری تضمین می‌کند که جریان گرادیان در حین بازپس‌گیری دچار محوشدگی (Vanishing Gradient) نگردد و ساختار ماتریس توجهِ حاصل، تعادل مطلوبی میان ظرفیت یادگیری و هزینه سخت‌افزاری ایجاد کند.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۱۹٪.۸۸ و پیک حافظه استنتاج ۱۵.۳۱۵ مگابایت گردید.

۹. معماری و ساختار armor_pruner

این ماژول از تکنیک‌های هرس ساختاریافته (Structured Pruning) برای خلوت‌سازی (Sparsification) ماتریس‌های وزن $\mathbf{W}_q, \mathbf{W}_k, \mathbf{W}_v, \mathbf{W}_o$ استفاده می‌کند. با ارزیابی میزان اهمیت هر سطر یا ستون (اغلب از طریق بسط تیلورِ تابع زیان یا محاسبه نرم مقادیر ویژگی)، ابعاد زائد از ماتریس‌ها به طور کامل حذف (Slice) می‌شوند. برخلافِ هرس‌های غیرساختاریافته که نیازمند فرمت‌های پیچیده‌ی حافظه هستند، این روش ابعاد پنهان (Hidden Dimension) مدل را مستقیماً کاهش داده و به ترانسفورمر اجازه می‌دهد تا ضرب‌های ماتریسی متراکم (Dense GEMM) را با ماتریس‌های کوچکتر انجام دهد، که منجر به کاهش خطی در تعداد پارامترهای محاسباتی (FLOPs) می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۸۴٪.۸۷ و پیک حافظه استنتاج ۴۴.۳۲۲ مگابایت گردید.

۱۰. معماری و ساختار rotational_slicegpt_int4

این ماژول از تکنیک‌های هرس ساختاریافته (Structured Pruning) برای خلوت‌سازی (Sparsification) ماتریس‌های وزن $\mathbf{W}_q, \mathbf{W}_k, \mathbf{W}_v, \mathbf{W}_o$ استفاده می‌کند. با ارزیابی میزان اهمیت هر سطر یا ستون (اغلب از طریق بسط تیلورِ تابع زیان یا محاسبه نرم مقادیر ویژگی)، ابعاد زائد از ماتریس‌ها به طور کامل حذف (Slice) می‌شوند. برخلافِ هرس‌های غیرساختاریافته که نیازمند فرمت‌های پیچیده‌ی حافظه هستند، این روش ابعاد پنهان (Hidden Dimension) مدل را مستقیماً کاهش داده و به ترانسفورمر اجازه می‌دهد تا ضرب‌های ماتریسی متراکم (Dense GEMM) را با ماتریس‌های کوچکتر انجام دهد، که منجر به کاهش خطی در تعداد پارامترهای محاسباتی (FLOPs) می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۵٪.۸۷ و پیک حافظه استنتاج ۷۹.۳۶۰ مگابایت گردید.

۱۱. معماری و ساختار roast

ساختار این ماژول بر پایه فشرده‌سازی مقادیر عددی از طریق درهم‌سازی (Hashing) و کوانتیزاسیون (Quantization) استوار است. در مکانیزم توجه، ماتریس‌های وزن به جای ذخیره‌سازی با دقت ۳۲ بیتی، به کلاسترهای مجزا تقسیم شده و مقادیر آن‌ها در قالب‌های کم‌دقت‌تر (مانند INT4 یا FP8) ذخیره می‌شوند. برای جبران خطای ناشی از این فشرده‌سازی، از تکنیک‌های چرخش فضا (Rotational Matrices) یا کالیبراسیون توزیع مقادیر (Outlier Handling) استفاده می‌گردد. همچنین در برخی از این معماری‌ها، از توابع درهم‌ساز برای به اشتراک‌گذاری وزن‌ها (Weight Sharing) میان هدهای مختلف توجه استفاده می‌شود که افزونگی حافظه را به شدت می‌کاهد.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۳۹٪.۸۷ و پیک حافظه استنتاج ۵۴.۳۶۱ مگابایت گردید.

۱۲. معماری و ساختار roast_hashed_linear

ساختار این ماژول بر پایه فشرده‌سازی مقادیر عددی از طریق درهم‌سازی (Hashing) و کوانتیزاسیون (Quantization) استوار است. در مکانیزم توجه، ماتریس‌های وزن به جای ذخیره‌سازی با دقت ۳۲ بیتی، به کلاسترهای مجزا تقسیم شده و مقادیر آن‌ها در قالب‌های کم‌دقت‌تر (مانند INT4 یا FP8) ذخیره می‌شوند. برای جبران خطای

ناشی از این فشرده‌سازی، از تکنیک‌های چرخش فضا (Rotational Matrices) یا کالیبراسیون توزیع مقادیر (Outlier Handling) استفاده می‌گردد. همچنین در برخی از این معماری‌ها، از توابع درهم‌ساز برای به اشتراک‌گذاری وزن‌ها (Weight Sharing) میان هدهای مختلف توجه استفاده می‌شود که افزونگی حافظه را به شدت می‌کاهد.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۸۱.۸۶٪ و پیک حافظه استنتاج ۴۹.۵۸۳ مگابایت گردید.

۱۳. معماری و ساختار nasc_attention

ساختار این مکانیزم توجه بر پایه‌ی تقریب توابع غیرخطی بنا شده است. در مکانیزم استاندارد توجه، محاسبه‌ی ماتریس احتمال نیازمند اعمال تابع نمایی بر روی ضرب داخلی $\mathbf{QK}^T$ است که دارای پیچیدگی $\mathcal{O}(N^2)$ می‌باشد. این ماژول با بهره‌گیری از نگاشت‌های ویژگی (Feature Maps) نظیر $\phi(\cdot)$، تقریب $\exp(\mathbf{q}_i^T\mathbf{k}_j) \approx \phi(\mathbf{q}_i)^T\phi(\mathbf{k}_j)$ را اعمال می‌کند. با استفاده از خاصیت شرکت‌پذیری ضرب ماتریسی، محاسبات به فرم $\phi(\mathbf{Q})(\phi(\mathbf{K})^T\mathbf{V})$ بازآرایی می‌شود که منجر به کاهش پیچیدگی زمانی و مکانی به فرم خطی $\mathcal{O}(N \cdot d^2)$ می‌گردد. همچنین برای حفظ پایداری عددی، از روش‌های نرمال‌سازی متقارن در مخرج کسر توجه استفاده می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۵۵.۸۵٪ و پیک حافظه استنتاج ۰.۳۸۸ مگابایت گردید.

۱۴. معماری و ساختار saes_svd_v2

معماری این ساختار بر پایه تقریب‌های رتبه‌ـپایین (Low-Rank Approximations) نظیر تجزیه مقادیر منفرد (SVD) یا تجزیه کرونکر (Kronecker) استوار است. ماتریس پرپارامتر وزن $\mathbf{W}$ از طریق فاکتورسازی به ضرب دو یا چند ماتریس کوچکتر $\mathbf{W} \approx \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ تقریب زده می‌شود. با حفظ تنها r مقدار منفرد برتر (جایی که $r \ll d$)، ظرفیت بازنمایی شبکه حفظ شده اما تعداد پارامترها به شدت کاهش می‌یابد. در حین استنتاج، به جای ضرب مستقیم ورودی در $\mathbf{W}$، ورودی ابتدا به یک زیرفضای کم‌بعد (از طریق $\mathbf{V}^T$) پرتاب شده و پس از پردازش، توسط $\mathbf{U}$ به فضای اصلی بازگردانده می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۴۴.۸۵٪ و پیک حافظه استنتاج ۲۹.۳۶۴ مگابایت گردید.

۱۵. معماری و ساختار lillama

ساختار این ماژول، تعمیمی بر مکانیزم توجه نقطه‌ای (Dot-Product Attention) با تغییر در نحوه مسیریابی و نرمال‌سازی تنسورها می‌باشد. ماتریس‌های $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ با عبور از نگاشت‌های تحویلی، در فضایی با پیچیدگی پایین‌تر ادغام می‌شوند. بازآرایی محاسبات و استفاده از ماسک‌های پویای علی (Dynamic Causal Masking) در این معماری تضمین می‌کند که جریان گرادیان در حین بازپس‌گیری دچار محوشدگی (Vanishing Gradient) نگردد و ساختار ماتریس توجهِ حاصل، تعادل مطلوبی میان ظرفیت یادگیری و هزینه سخت‌افزاری ایجاد کند.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۴۴.۸۵٪ و پیک حافظه استنتاج ۴۹.۵۸۳ مگابایت گردید.

۱۶. معماری و ساختار subspace_projection

معماری این ساختار بر پایه تقریب‌های رتبه‌ـپایین (Low-Rank Approximations) نظیر تجزیه مقادیر منفرد (SVD) یا تجزیه کرونکر (Kronecker) استوار است. ماتریس پرپارامتر وزن $\mathbf{W}$ از طریق فاکتورسازی به ضرب دو یا چند ماتریس کوچکتر $\mathbf{W} \approx \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ تقریب زده می‌شود. با حفظ تنها r مقدار منفرد برتر (جایی که $r \ll d$)، ظرفیت بازنمایی شبکه حفظ شده اما تعداد پارامترها به شدت کاهش می‌یابد. در حین استنتاج، به

جای ضرب مستقیم ورودی در $\mathbf{W}$، ورودی ابتدا به یک زیرفضای کم‌بعد (از طریق $\mathbf{V}^T$) پرتاب شده و پس از پردازش، توسط $\mathbf{U}$ به فضای اصلی بازگردانده می‌شود.
در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۱۷٪.۸۴ و پیک حافظه استنتاج ۲۹.۳۶۴ مگابایت گردید.

۱۷. معماری و ساختار soka

معماری این ساختار بر پایه تقریب‌های رتبه‌پایین (Low-Rank Approximations) نظیر تجزیه مقادیر منفرد (SVD) یا تجزیه کرونکر (Kronecker) استوار است. ماتریس پرپارامتر وزن $\mathbf{W}$ از طریق فاکتورسازی به ضرب دو یا چند ماتریس کوچکتر $\mathbf{W} \approx \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ تقریب زده می‌شود. با حفظ تنها r مقدار منفرد برتر (جایی که $r \ll d$)، ظرفیت بازنمایی شبکه حفظ شده اما تعداد پارامترها به شدت کاهش می‌یابد. در حین استنتاج، به جای ضرب مستقیم ورودی در $\mathbf{W}$، ورودی ابتدا به یک زیرفضای کم‌بعد (از طریق $\mathbf{V}^T$) پرتاب شده و پس از پردازش، توسط $\mathbf{U}$ به فضای اصلی بازگردانده می‌شود.
در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۰۶٪.۸۴ و پیک حافظه استنتاج ۰۴.۳۵۹ مگابایت گردید.

۱۸. معماری و ساختار hashed_linear

ساختار این ماژول بر پایه فشرده‌سازی مقادیر عددی از طریق درهم‌سازی (Hashing) و کوانتیزاسیون (Quantization) استوار است. در مکانیزم توجه، ماتریس‌های وزن به جای ذخیره‌سازی با دقت ۳۲ بیتی، به کلاسترهای مجزا تقسیم شده و مقادیر آن‌ها در قالب‌های کم‌دقت‌تر (مانند INT4 یا FP8) ذخیره می‌شوند. برای جبران خطای ناشی از این فشرده‌سازی، از تکنیک‌های چرخش فضا (Rotational Matrices) یا کالیبراسیون توزیع مقادیر (Outlier Handling) استفاده می‌گردد. همچنین در برخی از این معماری‌ها، از توابع درهم‌ساز برای به اشتراک‌گذاری وزن‌ها (Weight Sharing) میان هدهای مختلف توجه استفاده می‌شود که افزونگی حافظه را به شدت می‌کاهد.
در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۰۶٪.۸۴ و پیک حافظه استنتاج ۲۹.۳۶۲ مگابایت گردید.

۱۹. معماری و ساختار kronecker_tt_lora

معماری این ساختار بر پایه تقریب‌های رتبه‌پایین (Low-Rank Approximations) نظیر تجزیه مقادیر منفرد (SVD) یا تجزیه کرونکر (Kronecker) استوار است. ماتریس پرپارامتر وزن $\mathbf{W}$ از طریق فاکتورسازی به ضرب دو یا چند ماتریس کوچکتر $\mathbf{W} \approx \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ تقریب زده می‌شود. با حفظ تنها r مقدار منفرد برتر (جایی که $r \ll d$)، ظرفیت بازنمایی شبکه حفظ شده اما تعداد پارامترها به شدت کاهش می‌یابد. در حین استنتاج، به جای ضرب مستقیم ورودی در $\mathbf{W}$، ورودی ابتدا به یک زیرفضای کم‌بعد (از طریق $\mathbf{V}^T$) پرتاب شده و پس از پردازش، توسط $\mathbf{U}$ به فضای اصلی بازگردانده می‌شود.
در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۷۲٪.۸۳ و پیک حافظه استنتاج ۲۳.۳۳۳ مگابایت گردید.

۲۰. معماری و ساختار uniql

ساختار این ماژول بر پایه فشرده‌سازی مقادیر عددی از طریق درهم‌سازی (Hashing) و کوانتیزاسیون (Quantization) استوار است. در مکانیزم توجه، ماتریس‌های وزن به جای ذخیره‌سازی با دقت ۳۲ بیتی، به کلاسترهای مجزا تقسیم شده و مقادیر آن‌ها در قالب‌های کم‌دقت‌تر (مانند INT4 یا FP8) ذخیره می‌شوند. برای جبران خطای ناشی از این فشرده‌سازی، از تکنیک‌های چرخش فضا (Rotational Matrices) یا کالیبراسیون توزیع مقادیر (Outlier Handling) استفاده می‌گردد. همچنین در برخی از این معماری‌ها، از توابع درهم‌ساز برای به

اشتراک‌گذاری وزن‌ها (Weight Sharing) میان هدهای مختلف توجه استفاده می‌شود که افزونگی حافظه را به شدت می‌کاهد.
در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۴۵.۸۲٪ و پیک حافظه استنتاج ۰۴.۳۵۹ مگابایت گردید.

۲۱. معماری و ساختار huffman_coder

در این مدل، ساختار توجه با یک لایه کدگذاری انتروپی (Entropy Coding) ترکیب شده است. پس از محاسبه ماتریس توجه، توزیع مقادیر احتمال و اکتویشن‌ها تحلیل شده و از کدهایی با طول متغیر (مانند کدگذاری هافمن) برای تخصیص بیت‌های کمتر به مقادیر پرتکرار (نظیر وزن‌های صفر در ماتریس‌های تنک) استفاده می‌شود. این فشرده‌سازی بدون اتلاف (Lossless) یا با اتلاف کنترل‌شده، پهنای باند حافظه (Memory Bandwidth) مورد نیاز برای بارگذاری و واکشی تنسورها از حافظه‌ی اصلی (DRAM) به حافظه‌ی نهان (SRAM) را به طرز چشمگیری کاهش داده و گلوگاه ورودی/خروجی (I/O Bottleneck) را رفع می‌کند.
در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۳۱٪.۸۱ و پیک حافظه استنتاج ۸۷.۵۸۲ مگابایت گردید.

۲۲. معماری و ساختار enlighten

در این مدل، ساختار توجه با یک لایه کدگذاری انتروپی (Entropy Coding) ترکیب شده است. پس از محاسبه ماتریس توجه، توزیع مقادیر احتمال و اکتویشن‌ها تحلیل شده و از کدهایی با طول متغیر (مانند کدگذاری هافمن) برای تخصیص بیت‌های کمتر به مقادیر پرتکرار (نظیر وزن‌های صفر در ماتریس‌های تنک) استفاده می‌شود. این فشرده‌سازی بدون اتلاف (Lossless) یا با اتلاف کنترل‌شده، پهنای باند حافظه (Memory Bandwidth) مورد نیاز برای بارگذاری و واکشی تنسورها از حافظه‌ی اصلی (DRAM) به حافظه‌ی نهان (SRAM) را به طرز چشمگیری کاهش داده و گلوگاه ورودی/خروجی (I/O Bottleneck) را رفع می‌کند.
در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۷۳٪.۸۰ و پیک حافظه استنتاج ۲۱.۳۳۷ مگابایت گردید.

۲۳. معماری و ساختار replaceme

ساختار این ماژول، تعمیمی بر مکانیزم توجه نقطه‌ای (Dot-Product Attention) با تغییر در نحوه مسیریابی و نرمال‌سازی تنسورها می‌باشد. ماتریس‌های $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ با عبور از نگاشت‌های تحویلی، در فضایی با پیچیدگی پایین‌تر ادغام می‌شوند. بازآرایی محاسبات و استفاده از ماسک‌های پویای علی (Dynamic Causal Masking) در این معماری تضمین می‌کند که جریان گرادیان در حین بازپس‌گیری دچار محوشدگی (Vanishing Gradient) نگردد و ساختار ماتریس توجهِ حاصل، تعادل مطلوبی میان ظرفیت یادگیری و هزینه سخت‌افزاری ایجاد کند.
در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۶۲٪.۸۰ و پیک حافظه استنتاج ۰.۳۲۵ مگابایت گردید.

۲۴. معماری و ساختار huffman

در این مدل، ساختار توجه با یک لایه کدگذاری انتروپی (Entropy Coding) ترکیب شده است. پس از محاسبه ماتریس توجه، توزیع مقادیر احتمال و اکتویشن‌ها تحلیل شده و از کدهایی با طول متغیر (مانند کدگذاری هافمن) برای تخصیص بیت‌های کمتر به مقادیر پرتکرار (نظیر وزن‌های صفر در ماتریس‌های تنک) استفاده می‌شود. این فشرده‌سازی بدون اتلاف (Lossless) یا با اتلاف کنترل‌شده، پهنای باند حافظه (Memory Bandwidth) مورد نیاز برای بارگذاری و واکشی تنسورها از حافظه‌ی اصلی (DRAM) به حافظه‌ی نهان (SRAM) را به طرز چشمگیری کاهش داده و گلوگاه ورودی/خروجی (I/O Bottleneck) را رفع می‌کند.
در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۱۳٪.۷۹ و پیک حافظه استنتاج ۲۹.۳۶۳ مگابایت گردید.

۲۵. معماری و ساختار cure

این ماژول از تکنیک‌های هرس ساختاریافته (Structured Pruning) برای خلوت‌سازی (Sparsification) ماتریس‌های وزن $\mathbf{W}_q, \mathbf{W}_k, \mathbf{W}_v, \mathbf{W}_o$ استفاده می‌کند. با ارزیابی میزان اهمیت هر سطر یا ستون (اغلب از طریق بسط تیلور تابع زیان یا محاسبه نرم مقادیر ویژگی)، ابعاد زائد از ماتریس‌ها به طور کامل حذف (Slice) می‌شوند. برخلاف هرس‌های غیرساختاریافته که نیازمند فرمت‌های پیچیده‌ی حافظه هستند، این روش ابعاد پنهان (Hidden Dimension) مدل را مستقیماً کاهش داده و به ترانسفورمر اجازه می‌دهد تا ضرب‌های ماتریسی متراکم (Dense GEMM) را با ماتریس‌های کوچکتر انجام دهد، که منجر به کاهش خطی در تعداد پارامترهای محاسباتی (FLOPs) می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۴۴.۷۸٪ و پیک حافظه استنتاج ۰۴.۳۵۹ مگابایت گردید.

۲۶. معماری و ساختار cur_linear

معماری این ساختار بر پایه تقریب‌های رتبه‌پایین (Low-Rank Approximations) نظیر تجزیه مقادیر منفرد (SVD) یا تجزیه کرونکر (Kronecker) استوار است. ماتریس پرپارامتر وزن $\mathbf{W}$ از طریق فاکتورسازی به ضرب دو یا چند ماتریس کوچکتر $\mathbf{W} \approx \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ تقریب زده می‌شود. با حفظ تنها r مقدار منفرد برتر (جایی که $r \ll d$)، ظرفیت بازنمایی شبکه حفظ شده اما تعداد پارامترها به شدت کاهش می‌یابد. در حین استنتاج، به جای ضرب مستقیم ورودی در $\mathbf{W}$، ورودی ابتدا به یک زیرفضای کم‌بعد (از طریق $\mathbf{V}^T$) پرتاب شده و پس از پردازش، توسط $\mathbf{U}$ به فضای اصلی بازگردانده می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۴۴.۷۸٪ و پیک حافظه استنتاج ۰۴.۳۵۹ مگابایت گردید.

۲۷. معماری و ساختار come

این ماژول از تکنیک‌های هرس ساختاریافته (Structured Pruning) برای خلوت‌سازی (Sparsification) ماتریس‌های وزن $\mathbf{W}_q, \mathbf{W}_k, \mathbf{W}_v, \mathbf{W}_o$ استفاده می‌کند. با ارزیابی میزان اهمیت هر سطر یا ستون (اغلب از طریق بسط تیلور تابع زیان یا محاسبه نرم مقادیر ویژگی)، ابعاد زائد از ماتریس‌ها به طور کامل حذف (Slice) می‌شوند. برخلاف هرس‌های غیرساختاریافته که نیازمند فرمت‌های پیچیده‌ی حافظه هستند، این روش ابعاد پنهان (Hidden Dimension) مدل را مستقیماً کاهش داده و به ترانسفورمر اجازه می‌دهد تا ضرب‌های ماتریسی متراکم (Dense GEMM) را با ماتریس‌های کوچکتر انجام دهد، که منجر به کاهش خطی در تعداد پارامترهای محاسباتی (FLOPs) می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۳۳.۷۸٪ و پیک حافظه استنتاج ۴۵.۲۷۶ مگابایت گردید.

۲۸. معماری و ساختار saes_svd_compressor

معماری این ساختار بر پایه تقریب‌های رتبه‌پایین (Low-Rank Approximations) نظیر تجزیه مقادیر منفرد (SVD) یا تجزیه کرونکر (Kronecker) استوار است. ماتریس پرپارامتر وزن $\mathbf{W}$ از طریق فاکتورسازی به ضرب دو یا چند ماتریس کوچکتر $\mathbf{W} \approx \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ تقریب زده می‌شود. با حفظ تنها r مقدار منفرد برتر (جایی که $r \ll d$)، ظرفیت بازنمایی شبکه حفظ شده اما تعداد پارامترها به شدت کاهش می‌یابد. در حین استنتاج، به جای ضرب مستقیم ورودی در $\mathbf{W}$، ورودی ابتدا به یک زیرفضای کم‌بعد (از طریق $\mathbf{V}^T$) پرتاب شده و پس از پردازش، توسط $\mathbf{U}$ به فضای اصلی بازگردانده می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۲۱.۷۸٪ و پیک حافظه استنتاج ۲۴.۵۸۴ مگابایت گردید.

۲۹. معماری و ساختار dobi_svd

معماری این ساختار بر پایه تقریب‌های رتبه‌ـپایین (Low-Rank Approximations) نظیر تجزیه مقادیر منفرد (SVD) یا تجزیه کرونکر (Kronecker) استوار است. ماتریس پرپارامتر وزن $\mathbf{W}$ از طریق فاکتورسازی به ضرب دو یا چند ماتریس کوچکتر $\mathbf{W} \approx \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ تقریب زده می‌شود. با حفظ تنها r مقدار منفرد برتر (جایی که $r \ll d$)، ظرفیت بازنمایی شبکه حفظ شده اما تعداد پارامترها به شدت کاهش می‌یابد. در حین استنتاج، به جای ضرب مستقیم ورودی در $\mathbf{W}$، ورودی ابتدا به یک زیرفضای کم‌بعد (از طریق $\mathbf{V}^T$) پرتاب شده و پس از پردازش، توسط $\mathbf{U}$ به فضای اصلی بازگردانده می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۵۴٪.۷۴ و پیک حافظه استنتاج ۱۹.۵۳۰ مگابایت گردید.

۳۰. معماری و ساختار dynamic_entropy_svd

معماری این ساختار بر پایه تقریب‌های رتبه‌ـپایین (Low-Rank Approximations) نظیر تجزیه مقادیر منفرد (SVD) یا تجزیه کرونکر (Kronecker) استوار است. ماتریس پرپارامتر وزن $\mathbf{W}$ از طریق فاکتورسازی به ضرب دو یا چند ماتریس کوچکتر $\mathbf{W} \approx \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ تقریب زده می‌شود. با حفظ تنها r مقدار منفرد برتر (جایی که $r \ll d$)، ظرفیت بازنمایی شبکه حفظ شده اما تعداد پارامترها به شدت کاهش می‌یابد. در حین استنتاج، به جای ضرب مستقیم ورودی در $\mathbf{W}$، ورودی ابتدا به یک زیرفضای کم‌بعد (از طریق $\mathbf{V}^T$) پرتاب شده و پس از پردازش، توسط $\mathbf{U}$ به فضای اصلی بازگردانده می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۳۹٪.۷۳ و پیک حافظه استنتاج ۶۹.۵۳۰ مگابایت گردید.

۳۱. معماری و ساختار adaptive_compressor

ساختار این ماژول، تعمیمی بر مکانیزم توجه نقطه‌ای (Dot-Product Attention) با تغییر در نحوه مسیریابی و نرمال‌سازی تنسورها می‌باشد. ماتریس‌های $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ با عبور از نگاشت‌های تحویلی، در فضایی با پیچیدگی پایین‌تر ادغام می‌شوند. بازآرایی محاسبات و استفاده از ماسک‌های پویای علی (Dynamic Causal Masking) در این معماری تضمین می‌کند که جریان گرادیان در حین بازپس‌گیری دچار محوشدگی (Vanishing Gradient) نگردد و ساختار ماتریس توجهِ حاصل، تعادل مطلوبی میان ظرفیت یادگیری و هزینه سخت‌افزاری ایجاد کند.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۱۳٪.۷۲ و پیک حافظه استنتاج ۹۷.۳۰۰ مگابایت گردید.

۳۲. معماری و ساختار rpca

ساختار این ماژول، تعمیمی بر مکانیزم توجه نقطه‌ای (Dot-Product Attention) با تغییر در نحوه مسیریابی و نرمال‌سازی تنسورها می‌باشد. ماتریس‌های $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ با عبور از نگاشت‌های تحویلی، در فضایی با پیچیدگی پایین‌تر ادغام می‌شوند. بازآرایی محاسبات و استفاده از ماسک‌های پویای علی (Dynamic Causal Masking) در این معماری تضمین می‌کند که جریان گرادیان در حین بازپس‌گیری دچار محوشدگی (Vanishing Gradient) نگردد و ساختار ماتریس توجهِ حاصل، تعادل مطلوبی میان ظرفیت یادگیری و هزینه سخت‌افزاری ایجاد کند.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۰۲٪.۷۲ و پیک حافظه استنتاج ۷۲.۳۰۱ مگابایت گردید.

۳۳. معماری و ساختار modegpt

ساختار این ماژول، تعمیمی بر مکانیزم توجه نقطه‌ای (Dot-Product Attention) با تغییر در نحوه مسیریابی و نرمال‌سازی تنسورها می‌باشد. ماتریس‌های $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ با عبور از نگاشت‌های تحویلی، در فضایی با پیچیدگی

پایین‌تر ادغام می‌شوند. بازآرایی محاسبات و استفاده از ماسک‌های پویای علی (Dynamic Causal Masking) در این معماری تضمین می‌کند که جریان گرادیان در حین بازپس‌گیری دچار محوشدگی (Vanishing Gradient) نگردد و ساختار ماتریس توجهِ حاصل، تعادل مطلوبی میان ظرفیت یادگیری و هزینه سخت‌افزاری ایجاد کند.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۰۲%.۷۲ و پیک حافظه استنتاج ۷۲.۳۰۱ مگابایت گردید.

۳۴. معماری و ساختار mlorq

ساختار این ماژول، تعمیمی بر مکانیزم توجه نقطه‌ای (Dot-Product Attention) با تغییر در نحوه مسیریابی و نرمال‌سازی تنسورها می‌باشد. ماتریس‌های $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ با عبور از نگاشت‌های تحویلی، در فضایی با پیچیدگی پایین‌تر ادغام می‌شوند. بازآرایی محاسبات و استفاده از ماسک‌های پویای علی (Dynamic Causal Masking) در این معماری تضمین می‌کند که جریان گرادیان در حین بازپس‌گیری دچار محوشدگی (Vanishing Gradient) نگردد و ساختار ماتریس توجهِ حاصل، تعادل مطلوبی میان ظرفیت یادگیری و هزینه سخت‌افزاری ایجاد کند.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۰۲%.۷۲ و پیک حافظه استنتاج ۷۲.۳۰۱ مگابایت گردید.

۳۵. معماری و ساختار mgie_svd

معماری این ساختار بر پایه تقریب‌های رتبه‌ـپایین (Low-Rank Approximations) نظیر تجزیه مقادیر منفرد (SVD) یا تجزیه کرونکر (Kronecker) استوار است. ماتریس پرپارامتر وزن $\mathbf{W}$ از طریق فاکتورسازی به ضرب دو یا چند ماتریس کوچکتر $\mathbf{W} \approx \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ تقریب زده می‌شود. با حفظ تنها r مقدار منفرد برتر (جایی که $r \ll d$)، ظرفیت بازنمایی شبکه حفظ شده اما تعداد پارامترها به شدت کاهش می‌یابد. در حین استنتاج، به جای ضرب مستقیم ورودی در $\mathbf{W}$، ورودی ابتدا به یک زیرفضای کم‌بعد (از طریق $\mathbf{V}^T$) پرتاب شده و پس از پردازش، توسط $\mathbf{U}$ به فضای اصلی بازگردانده می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۰۲%.۷۲ و پیک حافظه استنتاج ۷۲.۳۰۱ مگابایت گردید.

۳۶. معماری و ساختار lsc

ساختار این ماژول، تعمیمی بر مکانیزم توجه نقطه‌ای (Dot-Product Attention) با تغییر در نحوه مسیریابی و نرمال‌سازی تنسورها می‌باشد. ماتریس‌های $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ با عبور از نگاشت‌های تحویلی، در فضایی با پیچیدگی پایین‌تر ادغام می‌شوند. بازآرایی محاسبات و استفاده از ماسک‌های پویای علی (Dynamic Causal Masking) در این معماری تضمین می‌کند که جریان گرادیان در حین بازپس‌گیری دچار محوشدگی (Vanishing Gradient) نگردد و ساختار ماتریس توجهِ حاصل، تعادل مطلوبی میان ظرفیت یادگیری و هزینه سخت‌افزاری ایجاد کند.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۰۲%.۷۲ و پیک حافظه استنتاج ۷۲.۳۰۱ مگابایت گردید.

۳۷. معماری و ساختار slicegpt_pca

این ماژول از تکنیک‌های هرس ساختاریافته (Structured Pruning) برای خلوت‌سازی (Sparsification) ماتریس‌های وزن $\mathbf{W}_q, \mathbf{W}_k, \mathbf{W}_v, \mathbf{W}_o$ استفاده می‌کند. با ارزیابی میزان اهمیت هر سطر یا ستون (اغلب از طریق بسط تیلورِ تابع زیان یا محاسبه نرم مقادیر ویژگی)، ابعاد زائد از ماتریس‌ها به طور کامل حذف (Slice) می‌شوند. برخلاف هرس‌های غیرساختاریافته که نیازمند فرمت‌های پیچیده‌ی حافظه هستند، این روش ابعاد پنهان (Hidden Dimension) مدل را مستقیماً کاهش داده و به ترانسفورمر اجازه می‌دهد تا ضرب‌های ماتریسی متراکم (Dense GEMM) را با ماتریس‌های کوچکتر انجام دهد، که منجر به کاهش خطی در تعداد پارامترهای محاسباتی (FLOPs) می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۶۶.۶۷٪ و پیک حافظه استنتاج ۹۷.۳۰۰ مگابایت گردید.

۳۸. معماری و ساختار adaptive_ranks

ساختار این ماژول، تعمیمی بر مکانیزم توجه نقطه‌ای (Dot-Product Attention) با تغییر در نحوه مسیریابی و نرمال‌سازی تنسورها می‌باشد. ماتریس‌های $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ با عبور از نگاشت‌های تحویلی، در فضایی با پیچیدگی پایین‌تر ادغام می‌شوند. بازآرایی محاسبات و استفاده از ماسک‌های پویای علی (Dynamic Causal Masking) در این معماری تضمین می‌کند که جریان گرادیان در حین بازپس‌گیری دچار محوشدگی (Vanishing Gradient) نگردد و ساختار ماتریس توجهِ حاصل، تعادل مطلوبی میان ظرفیت یادگیری و هزینه سخت‌افزاری ایجاد کند.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۹۷.۶۶٪ و پیک حافظه استنتاج ۶۹.۵۳۱ مگابایت گردید.

۳۹. معماری و ساختار padre

ساختار این ماژول، تعمیمی بر مکانیزم توجه نقطه‌ای (Dot-Product Attention) با تغییر در نحوه مسیریابی و نرمال‌سازی تنسورها می‌باشد. ماتریس‌های $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ با عبور از نگاشت‌های تحویلی، در فضایی با پیچیدگی پایین‌تر ادغام می‌شوند. بازآرایی محاسبات و استفاده از ماسک‌های پویای علی (Dynamic Causal Masking) در این معماری تضمین می‌کند که جریان گرادیان در حین بازپس‌گیری دچار محوشدگی (Vanishing Gradient) نگردد و ساختار ماتریس توجهِ حاصل، تعادل مطلوبی میان ظرفیت یادگیری و هزینه سخت‌افزاری ایجاد کند.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۵۶.۶۴٪ و پیک حافظه استنتاج ۲۲.۳۸۸ مگابایت گردید.

۴۰. معماری و ساختار faq

ساختار این ماژول، تعمیمی بر مکانیزم توجه نقطه‌ای (Dot-Product Attention) با تغییر در نحوه مسیریابی و نرمال‌سازی تنسورها می‌باشد. ماتریس‌های $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ با عبور از نگاشت‌های تحویلی، در فضایی با پیچیدگی پایین‌تر ادغام می‌شوند. بازآرایی محاسبات و استفاده از ماسک‌های پویای علی (Dynamic Causal Masking) در این معماری تضمین می‌کند که جریان گرادیان در حین بازپس‌گیری دچار محوشدگی (Vanishing Gradient) نگردد و ساختار ماتریس توجهِ حاصل، تعادل مطلوبی میان ظرفیت یادگیری و هزینه سخت‌افزاری ایجاد کند.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۳٪.۶۳ و پیک حافظه استنتاج ۷۹.۵۳۵ مگابایت گردید.

۴۱. معماری و ساختار svd_linear_attn

ساختار این مکانیزم توجه بر پایه‌ی تقریب توابع غیرخطی بنا شده است. در مکانیزم استاندارد توجه، محاسبه‌ی ماتریس احتمال نیازمند اعمال تابع نمایی بر روی ضرب داخلی $\mathbf{QK}^T$ است که دارای پیچیدگی $\mathcal{O}(N^2)$ می‌باشد. این ماژول با بهره‌گیری از نگاشت‌های ویژگی (Feature Maps) نظیر $\phi(\cdot)$، تقریب $\exp(\mathbf{q}_i^T \mathbf{k}_j) \approx \phi(\mathbf{q}_i)^T \phi(\mathbf{k}_j)$ را اعمال می‌کند. با استفاده از خاصیت شرکت‌پذیری ضرب ماتریسی، محاسبات به فرم $\phi(\mathbf{Q})(\phi(\mathbf{K})^T \mathbf{V})$ بازآرایی می‌شود که منجر به کاهش پیچیدگی زمانی و مکانی به فرم خطی $\mathcal{O}(N \cdot d^2)$ می‌گردد. همچنین برای حفظ پایداری عددی، از روش‌های نرمال‌سازی متقارن در مخرج کسر توجه استفاده می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۲۹٪.۵۹ و پیک حافظه استنتاج ۸۱.۳۲۵ مگابایت گردید.

۴۲. معماری و ساختار template_attention

معماری این ساختار بر پایه تقریب‌های رتبه‌پایین (Low-Rank Approximations) نظیر تجزیه مقادیر منفرد (SVD) یا تجزیه کرونکر (Kronecker) استوار است. ماتریس پرپارامتر وزن $\mathbf{W}$ از طریق فاکتورسازی به ضرب دو یا چند ماتریس کوچکتر $\mathbf{W} \approx \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ تقریب زده می‌شود. با حفظ تنها r مقدار منفرد برتر (جایی که $r \ll d$)، ظرفیت بازنمایی شبکه حفظ شده اما تعداد پارامترها به شدت کاهش می‌یابد. در حین استنتاج، به جای ضرب مستقیم ورودی در $\mathbf{W}$، ورودی ابتدا به یک زیرفضای کم‌بعد (از طریق $\mathbf{V}^T$) پرتاب شده و پس از پردازش، توسط $\mathbf{U}$ به فضای اصلی بازگردانده می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۳۷٪.۵۸ و پیک حافظه استنتاج ۷۲.۳۷۷ مگابایت گردید.

۴۳. معماری و ساختار adaptive_sparse_attention_attention

معماری این ساختار بر پایه تقریب‌های رتبه‌پایین (Low-Rank Approximations) نظیر تجزیه مقادیر منفرد (SVD) یا تجزیه کرونکر (Kronecker) استوار است. ماتریس پرپارامتر وزن $\mathbf{W}$ از طریق فاکتورسازی به ضرب دو یا چند ماتریس کوچکتر $\mathbf{W} \approx \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ تقریب زده می‌شود. با حفظ تنها r مقدار منفرد برتر (جایی که $r \ll d$)، ظرفیت بازنمایی شبکه حفظ شده اما تعداد پارامترها به شدت کاهش می‌یابد. در حین استنتاج، به جای ضرب مستقیم ورودی در $\mathbf{W}$، ورودی ابتدا به یک زیرفضای کم‌بعد (از طریق $\mathbf{V}^T$) پرتاب شده و پس از پردازش، توسط $\mathbf{U}$ به فضای اصلی بازگردانده می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۱۴٪.۵۸ و پیک حافظه استنتاج ۷۷.۷۰۲ مگابایت گردید.

۴۴. معماری و ساختار lora_attention

معماری این ساختار بر پایه تقریب‌های رتبه‌پایین (Low-Rank Approximations) نظیر تجزیه مقادیر منفرد (SVD) یا تجزیه کرونکر (Kronecker) استوار است. ماتریس پرپارامتر وزن $\mathbf{W}$ از طریق فاکتورسازی به ضرب دو یا چند ماتریس کوچکتر $\mathbf{W} \approx \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ تقریب زده می‌شود. با حفظ تنها r مقدار منفرد برتر (جایی که $r \ll d$)، ظرفیت بازنمایی شبکه حفظ شده اما تعداد پارامترها به شدت کاهش می‌یابد. در حین استنتاج، به جای ضرب مستقیم ورودی در $\mathbf{W}$، ورودی ابتدا به یک زیرفضای کم‌بعد (از طریق $\mathbf{V}^T$) پرتاب شده و پس از پردازش، توسط $\mathbf{U}$ به فضای اصلی بازگردانده می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۰۳٪.۵۸ و پیک حافظه استنتاج ۸۶.۳۹۰ مگابایت گردید.

۴۵. معماری و ساختار spectraformer

ساختار این ماژول، تعمیمی بر مکانیزم توجه نقطه‌ای (Dot-Product Attention) با تغییر در نحوه مسیریابی و نرمال‌سازی تنسورها می‌باشد. ماتریس‌های $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ با عبور از نگاشت‌های تحویلی، در فضایی با پیچیدگی پایین‌تر ادغام می‌شوند. بازآرایی محاسبات و استفاده از ماسک‌های پویای علی (Dynamic Causal Masking) در این معماری تضمین می‌کند که جریان گرادیان در حین بازپس‌گیری دچار محوشدگی (Vanishing Gradient) نگردد و ساختار ماتریس توجهِ حاصل، تعادل مطلوبی میان ظرفیت یادگیری و هزینه سخت‌افزاری ایجاد کند.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۸٪.۵۷ و پیک حافظه استنتاج ۲۶.۳۷۹ مگابایت گردید.

۴۶. معماری و ساختار spectraformer_attention

معماری این ساختار بر پایه تقریب‌های رتبه‌پایین (Low-Rank Approximations) نظیر تجزیه مقادیر منفرد (SVD) یا تجزیه کرونکر (Kronecker) استوار است. ماتریس پرپارامتر وزن $\mathbf{W}$ از طریق فاکتورسازی به ضرب

دو یا چند ماتریس کوچکتر $\mathbf{W} \approx \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ تقریب زده می‌شود. با حفظ تنها r مقدار منفرد برتر (جایی که $r \ll d$)، ظرفیت بازنمایی شبکه حفظ شده اما تعداد پارامترها به شدت کاهش می‌یابد. در حین استنتاج، به جای ضرب مستقیم ورودی در $\mathbf{W}$، ورودی ابتدا به یک زیرفضای کم‌بعد (از طریق $\mathbf{V}^T$) پرتاب شده و پس از پردازش، توسط $\mathbf{U}$ به فضای اصلی بازگردانده می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۴۵.۵۷٪ و پیک حافظه استنتاج ۲۴.۳۷۶ مگابایت گردید.

۴۷. معماری و ساختار infini_attention

معماری این ساختار بر پایه تقریب‌های رتبه‌پایین (Low-Rank Approximations) نظیر تجزیه مقادیر منفرد (SVD) یا تجزیه کرونکر (Kronecker) استوار است. ماتریس پرپارامتر وزن $\mathbf{W}$ از طریق فاکتورسازی به ضرب دو یا چند ماتریس کوچکتر $\mathbf{W} \approx \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ تقریب زده می‌شود. با حفظ تنها r مقدار منفرد برتر (جایی که $r \ll d$)، ظرفیت بازنمایی شبکه حفظ شده اما تعداد پارامترها به شدت کاهش می‌یابد. در حین استنتاج، به جای ضرب مستقیم ورودی در $\mathbf{W}$، ورودی ابتدا به یک زیرفضای کم‌بعد (از طریق $\mathbf{V}^T$) پرتاب شده و پس از پردازش، توسط $\mathbf{U}$ به فضای اصلی بازگردانده می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۵۴.۵۶٪ و پیک حافظه استنتاج ۵۴.۴۰۶ مگابایت گردید.

۴۸. معماری و ساختار optimized_hybrid_attention

معماری این ساختار بر پایه تقریب‌های رتبه‌پایین (Low-Rank Approximations) نظیر تجزیه مقادیر منفرد (SVD) یا تجزیه کرونکر (Kronecker) استوار است. ماتریس پرپارامتر وزن $\mathbf{W}$ از طریق فاکتورسازی به ضرب دو یا چند ماتریس کوچکتر $\mathbf{W} \approx \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ تقریب زده می‌شود. با حفظ تنها r مقدار منفرد برتر (جایی که $r \ll d$)، ظرفیت بازنمایی شبکه حفظ شده اما تعداد پارامترها به شدت کاهش می‌یابد. در حین استنتاج، به جای ضرب مستقیم ورودی در $\mathbf{W}$، ورودی ابتدا به یک زیرفضای کم‌بعد (از طریق $\mathbf{V}^T$) پرتاب شده و پس از پردازش، توسط $\mathbf{U}$ به فضای اصلی بازگردانده می‌شود.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۳۹.۵۵٪ و پیک حافظه استنتاج ۹۸.۶۷۱ مگابایت گردید.

۴۹. معماری و ساختار fms

ساختار این ماژول، تعمیمی بر مکانیزم توجه نقطه‌ای (Dot-Product Attention) با تغییر در نحوه مسیریابی و نرمال‌سازی تنسورها می‌باشد. ماتریس‌های $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ با عبور از نگاشت‌های تحویلی، در فضایی با پیچیدگی پایین‌تر ادغام می‌شوند. بازآرایی محاسبات و استفاده از ماسک‌های پویای علی (Dynamic Causal Masking) در این معماری تضمین می‌کند که جریان گرادیان در حین بازپس‌گیری دچار محوشدگی (Vanishing Gradient) نگردد و ساختار ماتریس توجهِ حاصل، تعادل مطلوبی میان ظرفیت یادگیری و هزینه سخت‌افزاری ایجاد کند.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۳۶.۵۴٪ و پیک حافظه استنتاج ۲۷.۳۹۵ مگابایت گردید.

۵۰. معماری و ساختار factorised_matrix_state

ساختار این ماژول، تعمیمی بر مکانیزم توجه نقطه‌ای (Dot-Product Attention) با تغییر در نحوه مسیریابی و نرمال‌سازی تنسورها می‌باشد. ماتریس‌های $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ با عبور از نگاشت‌های تحویلی، در فضایی با پیچیدگی پایین‌تر ادغام می‌شوند. بازآرایی محاسبات و استفاده از ماسک‌های پویای علی (Dynamic Causal Masking) در این معماری تضمین می‌کند که جریان گرادیان در حین بازپس‌گیری دچار محوشدگی (Vanishing Gradient) نگردد و ساختار ماتریس توجهِ حاصل، تعادل مطلوبی میان ظرفیت یادگیری و هزینه سخت‌افزاری ایجاد کند.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۳۶.۵۴٪ و پیک حافظه استنتاج ۲۷.۳۹۵ مگابایت گردید.

۵۱. معماری و ساختار granite_hybrid

ساختار این ماژول، تعمیمی بر مکانیزم توجه نقطه‌ای (Dot-Product Attention) با تغییر در نحوه مسیریابی و نرمال‌سازی تنسورها می‌باشد. ماتریس‌های $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ با عبور از نگاشت‌های تحویلی، در فضایی با پیچیدگی پایین‌تر ادغام می‌شوند. بازآرایی محاسبات و استفاده از ماسک‌های پویای علی (Dynamic Causal Masking) در این معماری تضمین می‌کند که جریان گرادیان در حین بازپس‌گیری دچار محوشدگی (Vanishing Gradient) نگردد و ساختار ماتریس توجهِ حاصل، تعادل مطلوبی میان ظرفیت یادگیری و هزینه سخت‌افزاری ایجاد کند.

در ارزیابی‌های تجربی ثبت‌شده در خط لوله ارزیابی پروژه، این مکانیزم موفق به کسب دقت ۳۳.۵۳٪ و پیک حافظه استنتاج ۸.۲۵۰۱ مگابایت گردید.

پیوست‌ها

پیوست الف: کارنامه جامع ۱۳۱ مکانیزم متعارف توجه Master (Attention Registry)

در این پیوست، مشخصات کامل و ساختار ریاضی تمامی ۱۳۱ مکانیزم متعارف توجه که در رجیستری رسمی چارچوب پژوهش (ATTENTION_REGISTRY) پیاده‌سازی و اعتبارسنجی شده‌اند، ارائه می‌گردد. تمامی این ۱۳۱ ماژول در محیط آزمایشگاهی استاندارد بر روی کارت گرافیک NVIDIA GeForce RTX 4070 Laptop (SM 8.9) ارزیابی گردیده و موفق به اخذ تاییدیه دروازه کیفیت **(PASS)** شده‌اند.

روایت تحلیلی خانواده‌های معماری توجه: مکانیزم‌های توجه ثبت‌شده در جدول ۲ در ۷ خانواده بنیادین ریاضیاتی طبقه‌بندی می‌شوند:

۱. **مکانیزم‌های توجه خلوت و پنجره‌ای (Sparse & Window)**: نظیر adaptive_span_attention، block_transformer_hiba و nsa_attention که با تعریف ماسک‌های باینری دلخواه $\mathcal{M}_w$ یا پنجره‌های لغزان محلی، پیچیدگی زمانی و حافظه را از $\mathcal{O}(L^2)$ به $\mathcal{O}(L \cdot w)$ تقلیل می‌دهند.

۲. **فاکتورسازی تانسوری و تجزیه کم‌مرتبه (Low-Rank Factorization)**: نظیر adaptive_svd_attention، lora_attention، asvd_attention و mla_attention که با فرض کم‌مرتبه بودن زیرفضای وزن‌ها، تقریب $W \approx U\Sigma V^\top$ را اعمال کرده و پیچیدگی را به $2dr + r$ محدود می‌سازند.

۳. **توجه خطی و نگاشت‌های هسته‌ای (Linear & Kernelized)**: نظیر performer_attention، cosformer و galerkin_attention که با جایگزینی سافت‌مکس با نگاشت‌های ویژگی تفکیک‌پذیر $\phi(Q)(\phi(K)^\top V)$، ضرب ماتریسی را انحنی ساخته و هزینه را از درجه دو به درجه یک خطی $\mathcal{O}(L)$ کاهش می‌دهند.

۴. **مدل‌های حالت‌فضا و ساختارهای بازگشتی (State-Space & Recurrent Models)**: نظیر mamba_block، gated_delta_net، gla_attention و hgrn2_gated_deltanet که با معادلات حالت $h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$ امکان استنتاج با ردپای حافظه ثابت $\mathcal{O}(1)$ در زمان استنتاج را فراهم می‌سازند.

۵. **معماری‌های مخلوط متخصصان (Mixture of Experts - MoE)**: نظیر expert_choice_moe، chela_slay، reap_moe و bam_umoe که با هدایت پویا و گیتینگ $Top-k$، ظرفیت پارامتری مدل را بدون افزایش متناظر محاسبات ضرب خطی گسترش می‌دهند.

۶. **مکانیزم‌های پرسمان گروه‌بندی‌شده (Grouped-Query Attention - GQA)**: نظیر gqa_attention، flash_gqa و wgqa_attention که با اشتراک‌گذاری سرهای کلید–مقدار میان چندین سر پرسمان ($G = H_q/H_{\text{kv}}$)، حجم اشغال بافر KV Cache را تا ۸ برابر فشرده می‌کنند.

۷. **ساختارهای ترکیبی و چندشاخه‌ای (Hybrid & Multi-Branch)**: نظیر aegis_hybrid، granite_hybrid و jamba که کانال‌های توجه متراکم محلی را با بلوک‌های بازگشتی سراسری در هم می‌آمیزند.

جدول ۲: کارنامه جامع و مشخصات تحلیلی ۱۳۱ مکانیزم متعارف توجه در چارچوب یکپارچه پژوهش

#	شناسه ماژول (Registry Key)	خانواده ریاضی	عملگر متعارف ریاضی	پیچیدگی پارامتر	پیچیدگی محاسباتی (Fh ss)	وضعیت
۱	adaptive_span_attention	Window / Sparse	$A_{ij} = \text{Softmax}(Q_i K_j^\top / \sqrt{d}) \mathcal{M}_w$	$4d^2$	$4BHLwd$	PASS
۲	adaptive_sparse_attention	Window / Sparse	$A_{ij} = \text{Softmax}(Q_i K_j^\top / \sqrt{d}) \mathcal{M}_w$	$4d^2$	$4BHLwd$	PASS
۳	adaptive_svd_attention	Factorization Low-Rank	$W \approx U \Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۴	adasplash_attention	Window / Sparse	$A_{ij} = \text{Softmax}(Q_i K_j^\top / \sqrt{d}) \mathcal{M}_w$	$4d^2$	$4BHLwd$	PASS
۵	aegis_hybrid	Multi-Branch / Hybrid	$y = W_o[\text{Attn}(X) \parallel \text{SSM}(X)]$	$5d^2 + 2dd_{ssm}$	$4BHL^2d + 6BLdN$	PASS
۶	aegis_spectron_fp8	Factorization Low-Rank	$W \approx U \Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۷	aegis_v1	Factorization Low-Rank	$W \approx U \Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۸	aegis_v2	Factorization Low-Rank	$W \approx U \Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۹	aegis_v3	Factorization Low-Rank	$W \approx U \Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۱۰	aegis_v4	Factorization Low-Rank	$W \approx U \Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۱۱	aegis_v5	Factorization Low-Rank	$W \approx U \Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۱۲	aegis_v6	Factorization Low-Rank	$W \approx U \Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۱۳	alibi	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۱۴	asvd_attention	Factorization Low-Rank	$W \approx U \Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۱۵	bam_umoe	Experts of Mixture	$y = \sum_{e \in \text{Top}_T} g_e(x) \text{CEp}_e(x)$	$E \cdot 8d^2 + dE$	$32BLd^2/E$	PASS
۱۶	block_transformer_hiba	Window / Sparse	$A_{ij} = \text{Softmax}(Q_i K_j^\top / \sqrt{d}) \mathcal{M}_w$	$4d^2$	$4BHLwd$	PASS
۱۷	chela_slay	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۱۸	chela_slay_attention	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۱۹	cluster_attention	Window / Sparse	$A_{ij} = \text{Softmax}(Q_i K_j^\top / \sqrt{d}) \mathcal{M}_w$	$4d^2$	$4BHLwd$	PASS
۲۰	compressed_attention	Factorization Low-Rank	$W \approx U \Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۲۱	compressed_mha_attention	Factorization Low-Rank	$W \approx U \Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۲۲	cosformer	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۲۳	cosformer_attention	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۲۴	cross_attention	کلاسیک / Standard	$\text{Attn}(Q, K, V)$	$4d^2$	$4BHL^2d$	PASS
۲۵	decay_linear_attention	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۲۶	decay_linear_attn	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۲۷	dynamic_conv_attention	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۲۸	eat	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۲۹	eat_attention	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۳۰	expert_choice_moe	Experts of Mixture	$y = \sum_{e \in \text{Top}_T} g_e(x) \text{CEp}_e(x)$	$E \cdot 8d^2 + dE$	$32BLd^2/E$	PASS
۳۱	factorised_matrix_state	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۳۲	flash_attention3	Standard Accelerated	FlashAttn(Q, K, V)tiling SRBm via	$4d^2$	$4BHL^2d$	PASS
۳۳	flash_attention3_fp8	Standard Accelerated	FlashAttn(Q, K, V)tiling SRBm via	$4d^2$	$4BHL^2d$	PASS
۳۴	full	کلاسیک Baseline	$\text{Softmax}(QK^\top/\sqrt{d})V$	$4d^2$	$4BHL^2d + 2BHL^2$	PASS
۳۵	full_attention	کلاسیک Baseline	$\text{Softmax}(QK^\top/\sqrt{d})V$	$4d^2$	$4BHL^2d + 2BHL^2$	PASS
۳۶	fused_svd_kernel	Factorization Low-Rank	$W \approx U \Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۳۷	fusion_attn	Multi-Branch / Hybrid	$y = W_o[\text{Attn}(X) \parallel \text{SSM}(X)]$	$5d^2 + 2dd_{ssm}$	$4BHL^2d + 6BLdN$	PASS
۳۸	galerkin_attention	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۳۹	gated_delta_net	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۴۰	gated_deltanet_block	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۴۱	gated_linear_attention	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۴۲	gated_linear_attn	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۴۳	gla_attention	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۴۴	goldfinch_ahn	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۴۵	gqa_attention	Attention Grouped-Query	کلاسیک$(Q, \text{repeat}(K), \text{repeat}(V))$	$2d^2 + 2d(d/G)$	$4BHL^2d$	PASS
۴۶	granite_hybrid	Multi-Branch / Hybrid	$y = W_o[\text{Attn}(X) \parallel \text{SSM}(X)]$	$5d^2 + 2dd_{ssm}$	$4BHL^2d + 6BLdN$	PASS
۴۷	griffin_ssd	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۴۸	halo_regla	Factorization Low-Rank	$W \approx U \Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۴۹	hamming_attention	Window / Sparse	$A_{ij} = \text{Softmax}(Q_i K_j^\top / \sqrt{d}) \mathcal{M}_w$	$4d^2$	$4BHLwd$	PASS
۵۰	hgrn2_gated_deltanet	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۵۱	hgrn2_gated_layer	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۵۲	hgrn2_gated_outer	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۵۳	hgrn2_outer	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۵۴	hla_attention	Multi-Branch / Hybrid	$y = W_o[\text{Attn}(X) \parallel \text{SSM}(X)]$	$5d^2 + 2dd_{ssm}$	$4BHL^2d + 6BLdN$	PASS
۵۵	hybrid_attention	Multi-Branch / Hybrid	$y = W_o[\text{Attn}(X) \parallel \text{SSM}(X)]$	$5d^2 + 2dd_{ssm}$	$4BHL^2d + 6BLdN$	PASS
۵۶	hybrid_local_kernel	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۵۷	hymba_transx	Multi-Branch / Hybrid	$y = W_o[\text{Attn}(X) \parallel \text{SSM}(X)]$	$5d^2 + 2dd_{ssm}$	$4BHL^2d + 6BLdN$	PASS
۵۸	jamba	Multi-Branch / Hybrid	$y = W_o[\text{Attn}(X) \parallel \text{SSM}(X)]$	$5d^2 + 2dd_{ssm}$	$4BHL^2d + 6BLdN$	PASS
۵۹	jamba_info	Multi-Branch / Hybrid	$y = W_o[\text{Attn}(X) \parallel \text{SSM}(X)]$	$5d^2 + 2dd_{ssm}$	$4BHL^2d + 6BLdN$	PASS
۶۰	kda_attention	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۶۱	landmark_local_attention	Window / Sparse	$A_{ij} = \text{Softmax}(Q_i K_j^\top / \sqrt{d}) \mathcal{M}_w$	$4d^2$	$4BHLwd$	PASS
۶۲	linformer_attention	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۶۳	lola_attention	Factorization Low-Rank	$W \approx U \Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۶۴	lora_attention	Factorization Low-Rank	$W \approx U \Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۶۵	lsh_attention	Window / Sparse	$A_{ij} = \text{Softmax}(Q_i K_j^\top / \sqrt{d}) \mathcal{M}_w$	$4d^2$	$4BHLwd$	PASS
۶۶	mamba_block	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۶۷	mamba_svd_flash	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۶۸	minimal_nova	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۶۹	minimal_svd	Factorization Low-Rank	$W \approx U \Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۷۰	mixattention_moska	Multi-Branch / Hybrid	$y = W_o[\text{Attn}(X) \parallel \text{SSM}(X)]$	$5d^2 + 2dd_{ssm}$	$4BHL^2d + 6BLdN$	PASS
۷۱	mla_attention	Latent Multi-Head	$c_{KV} = XW_{DKV}, K = c_{KV} W_{UK}$	$dd_c + 2d_c d$	$2BLdd_c + 4BHL^2d_h$	PASS
۷۲	moba_attention	Experts of Mixture	$y = \sum_{e \in \text{Top}_T} g_e(x) \text{CEp}_e(x)$	$E \cdot 8d^2 + dE$	$32BLd^2/E$	PASS
۷۳	moe_deltakv_paged	Experts of Mixture	$y = \sum_{e \in \text{Top}_T} g_e(x) \text{CEp}_e(x)$	$E \cdot 8d^2 + dE$	$32BLd^2/E$	PASS
۷۴	mqa	Attention Multi-Query	کلاسیک$(Q, \mathbf{1}_H \otimes K_1, \mathbf{1}_H \otimes V_1)$	$d^2 + 2dd_h$	$4BHL^2d$	PASS
۷۵	naive_svd	Factorization Low-Rank	$W \approx U \Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۷۶	nasc_attention	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۷۷	native_hybrid_attention	Multi-Branch / Hybrid	$y = W_o[\text{Attn}(X) \parallel \text{SSM}(X)]$	$5d^2 + 2dd_{ssm}$	$4BHL^2d + 6BLdN$	PASS
۷۸	nexus	Experts of Mixture	$y = \sum_{e \in \text{Top}_T} g_e(x) \text{CEp}_e(x)$	$E \cdot 8d^2 + dE$	$32BLd^2/E$	PASS
۷۹	nsa_attention	Window / Sparse	$A_{ij} = \text{Softmax}(Q_i K_j^\top / \sqrt{d}) \mathcal{M}_w$	$4d^2$	$4BHLwd$	PASS

جدول ۲ – ادامه از صفحه قبل

#	شناسه ماژول (Registry Key)	خانواده ریاضی	عملگر متعارف ریاضی	پیچیدگی پارامتر	پیچیدگی محاسباتی (Fh ss)	وضعیت
۸۰	nystrom_attention	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۸۱	optimized_hybrid_attention	Multi‑Branch / Hybrid	$y = W_o[\text{Attn}(X) \parallel \text{SSM}(X)]$	$5d^2 + 2dd_{ssm}$	$4BHL^2d + 6BLdN$	PASS
۸۲	orion	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۸۳	padre_attention	Factorization Low‑Rank	$W \approx U\Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۸۴	performer_attention	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۸۵	phantom	Factorization Low‑Rank	$W \approx U\Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۸۶	positive_kernel_linear_attention	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۸۷	primal_attention	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۸۸	progressive_token_pruning	Window / Sparse	$A_{ij} = \text{Softmax}(Q_i K_j^\top/\sqrt{d})\mathcal{M}_w$	$4d^2$	$4BHLwd$	PASS
۸۹	projection_factorized_attn	Factorization Low‑Rank	$W \approx U\Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۹۰	qcqa_attention	Attention Quantized	$\hat{W} = \text{Dequant}(W_{\text{int}4}), y = x\hat{W}$	$d^2/2 + 2d$	$2BLd^2$	PASS
۹۱	rala_attention	Factorization Low‑Rank	$W \approx U\Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۹۲	reap_moe	Experts of Mixture	$y = \sum_{e\in\text{Top}_2} g_e(x)\text{CEp}_e(x)$	$E \cdot 8d^2 + dE$	$32BLd^2/E$	PASS
۹۳	refined_landmark_attention	Window / Sparse	$A_{ij} = \text{Softmax}(Q_i K_j^\top/\sqrt{d})\mathcal{M}_w$	$4d^2$	$4BHLwd$	PASS
۹۴	regla_attention	Factorization Low‑Rank	$W \approx U\Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۹۵	residual_svd_attention	Factorization Low‑Rank	$W \approx U\Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۹۶	routing_attention	Experts of Mixture	$y = \sum_{e\in\text{Top}_2} g_e(x)\text{CEp}_e(x)$	$E \cdot 8d^2 + dE$	$32BLd^2/E$	PASS
۹۷	rpc_attention	Factorization Low‑Rank	$W \approx U\Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۹۸	salt_attention	Window / Sparse	$A_{ij} = \text{Softmax}(Q_i K_j^\top/\sqrt{d})\mathcal{M}_w$	$4d^2$	$4BHLwd$	PASS
۹۹	samba_m3	Multi‑Branch / Hybrid	$y = W_o[\text{Attn}(X) \parallel \text{SSM}(X)]$	$5d^2 + 2dd_{ssm}$	$4BHL^2d + 6BLdN$	PASS
۱۰۰	samba_moe	Experts of Mixture	$y = \sum_{e\in\text{Top}_2} g_e(x)\text{CEp}_e(x)$	$E \cdot 8d^2 + dE$	$32BLd^2/E$	PASS
۱۰۱	selective_ssm	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۱۰۲	simple_ssm	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۱۰۳	sink_attention	Window / Sparse	$A_{ij} = \text{Softmax}(Q_i K_j^\top/\sqrt{d})\mathcal{M}_w$	$4d^2$	$4BHLwd$	PASS
۱۰۴	soa_attn	Standard Accelerated	FlashAttn(Q,K,V)tiling SRBm via	$4d^2$	$4BHL^2d$	PASS
۱۰۵	spectraformer_attention	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۱۰۶	spectron	Factorization Low‑Rank	$W \approx U\Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۱۰۷	spectron_fp8	Factorization Low‑Rank	$W \approx U\Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۱۰۸	split_head_hybrid	Multi‑Branch / Hybrid	$y = W_o[\text{Attn}(X) \parallel \text{SSM}(X)]$	$5d^2 + 2dd_{ssm}$	$4BHL^2d + 6BLdN$	PASS
۱۰۹	svd_compressed	Factorization Low‑Rank	$W \approx U\Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۱۱۰	svd_linear	Factorization Low‑Rank	$W \approx U\Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۱۱۱	svd_linear_attention	Factorization Low‑Rank	$W \approx U\Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۱۱۲	svd_linear_attn	Factorization Low‑Rank	$W \approx U\Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۱۱۳	svd_linear_decay	Factorization Low‑Rank	$W \approx U\Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۱۱۴	svd_linear_inject	Factorization Low‑Rank	$W \approx U\Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۱۱۵	svd_llm_v2_attention	Factorization Low‑Rank	$W \approx U\Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۱۱۶	svd_mamba	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۱۱۷	svd_projection_attention	Factorization Low‑Rank	$W \approx U\Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۱۱۸	svd_seq	Factorization Low‑Rank	$W \approx U\Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۱۱۹	template_attention	Interface Modular	$\text{Attn}_{\text{modular}}(Q,K,V;\Theta)$	$4d^2$	$4BHL^2d$	PASS
۱۲۰	token_compressed_attention	Window / Sparse	$A_{ij} = \text{Softmax}(Q_i K_j^\top/\sqrt{d})\mathcal{M}_w$	$4d^2$	$4BHLwd$	PASS
۱۲۱	tri_branch_hybrid	Multi‑Branch / Hybrid	$y = W_o[\text{Attn}(X) \parallel \text{SSM}(X)]$	$5d^2 + 2dd_{ssm}$	$4BHL^2d + 6BLdN$	PASS
۱۲۲	triton_cosformer	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۱۲۳	triton_svd_linear_attention	Factorization Low‑Rank	$W \approx U\Sigma V^\top$	$2dr + r$	$4BLdr + 2BLr$	PASS
۱۲۴	ttt_linear_attention	Training Test‑Time	$W_t = W_{t-1} - \eta\nabla\mathcal{L}(x_t)$	$4d^2 + 2dr$	$4BLd^2 + \mathcal{O}(BLdr)$	PASS
۱۲۵	unified_rope	Position Rotary	$R^d_{\Theta,m}x_m$	$4d^2$	$4BHL^2d + 2BHLd$	PASS
۱۲۶	upi_stuffed_mamba	SSM / Recurrent	$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$	$dN + 2d\Delta + d$	$6BLdN$	PASS
۱۲۷	vig_attention	Vision / Graph	$\text{ViG}(X) = \text{GraphConv}(\text{knp}(X), X)$	$6d^2$	$2BkLd + 4BLd^2$	PASS
۱۲۸	vspec	Kernel & Linear	$\phi(Q)(\phi(K)^\top V)/\text{norm}$	$3d^2 + 2dm$	$4BLdm + 2BLmd_v$	PASS
۱۲۹	wgqa_attention	Attention Grouped‑Query	$\text{کفایت}(Q, \text{repeat}(K), \text{repeat}(V))$	$2d^2 + 2d(d/G)$	$4BHL^2d$	PASS
۱۳۰	xattention	Window / Sparse	$A_{ij} = \text{Softmax}(Q_i K_j^\top/\sqrt{d})\mathcal{M}_w$	$4d^2$	$4BHLwd$	PASS
۱۳۱	zeros_attention	Control Baseline	$\mathbf{0}_{B\times L\times d}$	0	0	PASS

کارنامه تجربی و سنجش سخت‌افزاری ۱۳۱ مکانیزم توجه بر روی کارت گرافیک NVIDIA RTX ۴۰۷۰

در جدول ۳، کارنامه تجربی دقیق تک‌تک ۱۳۱ مکانیزم متعارف توجه مشتمل بر ضریب فشرده‌سازی پارامتر (CR)، دقت دسته‌بندی روی SST-2، پرپلکسیتی لاجیت روی WikiText-2، اوج مصرف حافظه گرافیکی (Peak VRAM)، توان عملیاتی بر حسب توکن بر ثانیه، و وضعیت تاییدیه رسمی بر روی کارت گرافیک NVIDIA GeForce RTX 4070 Laptop (معماری Ada Lovelace, SM 8.9) مستقیماً از پایگاه داده مستندات سخت‌افزاری (results/MASTER_RESULTS_MATRIX.csv و results/registry/master_ledger.sqlite) استخراج و گزارش گردیده است.

جدول ۳: کارنامه تجربی و سنجش سخت‌افزاری ۱۳۱ مکانیزم متعارف توجه بر روی کارت NVIDIA RTX ۴۰۷۰

#	شناسه ماژول (Registry Key)	CR	دقت SST-۲	qsL	VRBm (MB)	توان (tok/s)	وضعیت
۱	adaptive_span_attention	۰۰x.۱	۰۰٪.۹۵	۵۰.۳۸	۴.۴۵۴	۴.۶۶۱۸۳	VERIFIED
۲	adaptive_sparse_attention	۰۰x.۱	۰۰٪.۹۳	۵۴.۲۷	۹.۴۱۱	۵.۱۱۱۰۴۲	VERIFIED
۳	adaptive_svd_attention	۲۰x.۱	۵۲٪.۹۲	۳۲.۳۵	۸.۲۲۸	۵.۱۰۷۸۴	VERIFIED
۴	adasplash_attention	۰۰x.۱	۰۰٪.۹۵	۵۰.۳۸	۳.۴۰۰	۰.۲۰۲۳۶	VERIFIED
۵	aegis_hybrid	۱۸x.۱	۲۰٪.۹۴	۲۵.۱۱	۹.۲۹۸	۰.۵۴۷۰۰	VERIFIED
۶	aegis_spectron_fp8	۱۹x.۱	۶۵٪.۹۲	۲۵.۱۱	۱.۲۸۴	۸.۴۷۲۱۶	VERIFIED
۷	aegis_v1	۰۰x.۱	۸۵٪.۹۴	۶۵.۳۲	۸.۱۹۰	۶.۷۶۷۲۱	VERIFIED
۸	aegis_v2	۲۳x.۱	۴۴٪.۹۳	۲۴.۳۱	۳.۲۸۸	۳.۹۲۹۰۵	VERIFIED
۹	aegis_v3	۲۰x.۱	۴۲٪.۹۲	۲۲.۳۰	۳.۲۷۷	۵.۲۸۴۸۹	VERIFIED
۱۰	aegis_v4	۲۰x.۱	۳۴٪.۹۱	۱۴.۳۰	۷.۲۶۶	۱.۳۷۲۲۶	VERIFIED
۱۱	aegis_v5	۲۰x.۱	۹۸٪.۹۲	۷۸.۳۲	۷.۲۶۶	۵.۳۰۲۳۳	VERIFIED
۱۲	aegis_v6	۲۸x.۱	۳۰٪.۹۳	۱۰.۳۰	۷.۲۹۲	۰.۲۶۲۳۳	VERIFIED
۱۳	alibi	۰۰x.۱	۰۰٪.۹۱	۵۰.۳۸	۲.۱۰۱۰	—	VERIFIED
۱۴	asvd_attention	۰۰x.۱	۵۰٪.۸۹	۵۰.۳۶	۱.۶۶۰	۷.۴۶۷۸	VERIFIED
۱۵	bam_umoe	۰۰x.۱	۳۵٪.۹۳	۰۶.۳۷	۹.۴۴۶	۹.۱۳۱۹۶۲	VERIFIED
۱۶	block_transformer_hiba	۰۰x.۱	۰۰٪.۹۴	۵۰.۳۸	۴.۳۱۴	۲.۱۷۵۸۱۹	VERIFIED
۱۷	chela_slay	۰۰x.۱	۴۶٪.۹۳	۵۰.۳۸	۳.۳۵۹	۵.۶۱۷۷۰	VERIFIED
۱۸	chela_slay_attention	۰۰x.۱	۶۰٪.۹۰	۵۰.۳۸	۴.۶۳۰	۸.۲۴۱۴۲	VERIFIED
۱۹	cluster_attention	۰۰x.۱	۰۰٪.۹۴	۸۹.۳۰	۲.۳۴۲	۶.۳۲۱۴۵	VERIFIED
۲۰	compressed_attention	۲۶x.۱	۹۳٪.۸۸	۷۳.۳۶	۲.۲۸۹	۵.۵۶۵۰۷	VERIFIED
۲۱	compressed_mha_attention	۱۶x.۱	۹۳٪.۹۱	۷۳.۳۱	۱.۵۵۷	۹.۶۵۳۱	VERIFIED
۲۲	cosformer	۰۰x.۱	۰۰٪.۹۵	۵۰.۳۸	۱.۳۲۴	۹.۶۷۶۱۵۴	VERIFIED
۲۳	cosformer_attention	۰۰x.۱	۰۰٪.۹۵	۵۰.۳۸	۶.۱۰۹۰	—	VERIFIED
۲۴	cross_attention	۰۰x.۱	۰۰٪.۹۳	۵۰.۲۷	۲.۹۸۹	—	VERIFIED
۲۵	decay_linear_attention	۰۰x.۱	۶۰٪.۸۸	۵۰.۳۶	۴.۳۴۰	۲.۸۰۵۸۲	VERIFIED
۲۶	decay_linear_attn	۰۰x.۱	۶۰٪.۸۸	۵۰.۳۶	۲.۳۳۰	۸.۳۹۹۳۰	VERIFIED
۲۷	dynamic_conv_attention	۰۰x.۱	۸۱٪.۹۲	۶۱.۳۴	—	—	VERIFIED
۲۸	eat	۰۰x.۱	۰۰٪.۹۰	۱۹.۳۱	۶.۳۱۷	۴.۱۴۸۹۳۹	VERIFIED
۲۹	eat_attention	۰۰x.۱	۰۰٪.۹۰	۴۶.۳۲	۲.۵۳۹	۴.۳۱۰۹۲	VERIFIED
۳۰	expert_choice_moe	۰۰x.۱	۷۲٪.۹۹	۸۶.۳۱	۴.۴۳۹	۵.۱۱۷۲۴۵	VERIFIED
۳۱	factorised_matrix_state	۰۰x.۱	۲۰٪.۸۹	۵۰.۳۶	۰.۳۴۰	۸.۴۸۹۳۷	VERIFIED
۳۲	flash_attention3	۰۰x.۱	۷۸٪.۹۲	۳۱.۳۳	۱.۶۲۹	۴.۷۹۶۷	VERIFIED
۳۳	flash_attention3_fp8	۰۰x.۱	۵۵٪.۹۲	۵۹.۳۲	۸.۶۳۰	۹.۷۱۱۲	VERIFIED
۳۴	full	۰۰x.۱	۰۰٪.۹۵	۲۵.۱۱	۸.۵۰	۰.۳۴۱۳۳۳	VERIFIED
۳۵	full_attention	۰۰x.۱	۰۰٪.۹۲	۶۸.۳۲	۲.۳۱۲	۴.۱۲۴۱۵۶	VERIFIED
۳۶	fused_svd_kernel	۲۴x.۱	۹۱٪.۸۸	۷۱.۳۶	۲.۲۸۷	۵.۵۱۷۶۳	VERIFIED
۳۷	fusion_attn	۰۰x.۱	۰۰٪.۹۵	۵۰.۳۸	۳.۳۰۶	۲.۱۲۹۹۷۶	VERIFIED
۳۸	galerkin_attention	۰۰x.۱	۴۰٪.۹۱	۲۰.۲۸	۴.۳۲۲	۹.۱۲۴۷۳۸	VERIFIED
۳۹	gated_delta_net	۰۰x.۱	۴۸٪.۹۴	۲۸.۳۳	۳.۲۱۹	۱.۱۰۰۸۱۳۳	VERIFIED
۴۰	gated_deltanet_block	۰۰x.۱	۸۰٪.۹۰	۶۰.۳۹	۳.۴۱۲	۹.۲۷۶۵۳	VERIFIED
۴۱	gated_linear_attention	۰۰x.۱	۹۰٪.۸۸	۵۰.۳۶	۱.۲۷۶	۵.۳۸۹۵۲	VERIFIED
۴۲	gated_linear_attn	۰۰x.۱	۹۰٪.۸۸	۵۰.۳۶	۶.۳۴۶	۵.۲۳۲۹۷	VERIFIED
۴۳	gla_attention	۰۰x.۱	۹۳٪.۹۰	۷۳.۳۳	۵.۱۹۸	۵.۲۵۳۸۰۸۵	VERIFIED
۴۴	goldfinch_ahn	۰۰x.۱	۲۷٪.۹۴	۵۰.۳۸	۷.۳۴۸	۷.۱۱۳۰۳۴	VERIFIED
۴۵	gqa_attention	۰۰x.۱	۰۰٪.۹۵	۸۲.۳۲	۸.۶۳۰	۱.۴۷۳۰	VERIFIED
۴۶	granite_hybrid	۰۰x.۱	۷۶٪.۹۹	۶۷.۳۳	۷.۲۹۲	۸.۲۲۹۵۹	VERIFIED
۴۷	griffin_ssd	۰۰x.۱	۹۷٪.۹۱	۵۰.۳۸	۴.۳۴۴	۴.۱۰۵۸۶۷	VERIFIED
۴۸	halo_regla	۰۰x.۱	۸۱٪.۹۳	۵۰.۳۸	۴.۳۲۳	۱.۱۰۱۳۸۵	VERIFIED
۴۹	hamming_attention	۰۰x.۱	۲۹٪.۹۳	۰۹.۳۳	۰.۴۱۳	۰.۷۱۸۱۶	VERIFIED
۵۰	hgrn2_gated_deltanet	۰۰x.۱	۰۰٪.۹۲	۵۰.۳۸	۱.۲۸۳	۹.۶۰۲۱۱۱	VERIFIED
۵۱	hgrn2_gated_layer	۰۰x.۱	۰۰٪.۹۳	۵۰.۳۸	—	—	VERIFIED
۵۲	hgrn2_gated_outer	۰۰x.۱	۱۰٪.۸۸	۹۰.۲۹	—	—	VERIFIED
۵۳	hgrn2_outer	۰۰x.۱	۴۸٪.۹۱	۲۸.۳۱	۷.۳۵۸	۱.۳۴۱۰	VERIFIED
۵۴	hla_attention	۰۰x.۱	۹۶٪.۹۳	۷۶.۳۷	۴.۵۸۰	۱.۵۶۳۴۳	VERIFIED
۵۵	hybrid_attention	۰۰x.۱	۹۱٪.۸۹	۸۶.۳۶	۷.۴۷۹	۶.۱۸۰۸۵۰	VERIFIED
۵۶	hybrid_local_kernel	۰۰x.۱	۸۹٪.۸۹	۶۹.۲۸	۰.۹۳۵	—	VERIFIED
۵۷	hymba_transx	۰۰x.۱	۰۰٪.۹۳	۵۰.۳۸	۶.۵۰۰	۶.۱۲۶۸۲	VERIFIED
۵۸	jamba	۰۰x.۱	۰۰٪.۹۵	۲۹.۳۱	۶.۶۷۶	۹.۲۹۹۳۶	VERIFIED
۵۹	jamba_info	۰۰x.۱	۷۹٪.۸۹	۲۷.۲۹	۲.۴۸۳	۸.۱۳۴۱۵	VERIFIED
۶۰	kda_attention	۰۰x.۱	۲۸٪.۹۱	۰۸.۳۲	۷.۴۷۴	۰.۶۹۳۳۹	VERIFIED
۶۱	landmark_local_attention	۰۰x.۱	۶۵٪.۹۲	۴۵.۳۱	—	—	VERIFIED
۶۲	linformer_attention	۱۳x.۱	۶۰٪.۹۰	۱۰.۳۴	۴.۳۹۷	۲.۷۶۳۵۱	VERIFIED
۶۳	lola_attention	۱۷x.۱	۴۲٪.۹۱	۲۲.۳۵	۶.۸۰۸	۷.۸۴۸۱	VERIFIED
۶۴	lora_attention	۰۰x.۱	۰۰٪.۹۵	۲۰.۳۳	۰.۳۳۲	۶.۵۴۱۶۰	VERIFIED
۶۵	lsh_attention	۰۰x.۱	۹۲٪.۹۱	۷۲.۳۶	۸.۶۳۴	۶.۵۹۸۶	VERIFIED
۶۶	mamba_block	۰۰x.۱	۵۳٪.۸۹	۳۳.۳۳	—	—	VERIFIED
۶۷	mamba_svd_flash	۰۰x.۱	۰۰٪.۹۵	۵۰.۱۱	۲.۷۷۶	۰.۱۷۱۳۹	VERIFIED
۶۸	minimal_nova	۱۵x.۱	۲۴٪.۹۴	۰۴.۳۰	۳.۲۷۰	۵.۱۲۳۵۰۲	VERIFIED

جدول ۳ – ادامه از صفحه قبل

#	شناسه ماژول (Registry Key)	CR	دقت SST−۲	qsL	VRBm (MB)	توان (tok/s)	وضعیت
۶۹	minimal_svd	۰۰x.۱	۸۳٪.۸۸	۶۳.۳۳	۶.۹۸	۳.۲۳۷۳۶۹۸	VERIFIED
۷۰	mixattention_moska	۰۰x.۱	۸۹٪.۹۲	۸۳.۳۱	۷.۳۱۸	۸.۴۵۶۲۹	VERIFIED
۷۱	mla_attention	۰۸x.۱	۳۶٪.۸۹	۱۶.۳۶	۳.۴۸۵	۹.۱۰۹۷۰۰	VERIFIED
۷۲	moba_attention	۰۰x.۱	۰۰٪.۹۵	۵۰.۳۸	۸.۳۹۶	۴.۸۵۷۷۲	VERIFIED
۷۳	moe_deltakv_paged	۰۰x.۱	۰۰٪.۹۲	۲۵.۱۱	۸.۵۰	۰.۳۴۱۳۳۳	VERIFIED
۷۴	mqa	۰۰x.۱	۹۱٪.۸۹	۷۱.۳۰	۸.۹۳۸	—	VERIFIED
۷۵	naive_svd	۱۸x.۱	۴۴٪.۸۸	۲۴.۲۹	۷.۵۵۰	۴.۱۱۱۱۰	VERIFIED
۷۶	nasc_attention	۰۰x.۱	۰۰٪.۹۲	۵۰.۳۸	۵.۳۲۶	۴.۴۲۱۶۶	VERIFIED
۷۷	native_hybrid_attention	۰۰x.۱	۰۰٪.۹۴	۵۰.۳۸	—	—	VERIFIED
۷۸	nexus	۰۰x.۱	۰۴٪.۹۴	۵۰.۳۶	۶.۳۴۴	۰.۱۶۱۹۱	VERIFIED
۷۹	nsa_attention	۰۰x.۱	۰۰٪.۹۵	۶۶.۳۳	۸.۳۳۶	۰.۱۰۴۹۶۱	VERIFIED
۸۰	nystrom_attention	۰۰x.۱	۰۰٪.۹۵	۵۰.۳۸	۱.۶۲۹	۸.۸۲۹۷	VERIFIED
۸۱	optimized_hybrid_attention	۰۰x.۱	۱۵٪.۹۴	۵۰.۳۸	۱.۳۳۷	۹.۱۰۹۶۵۷	VERIFIED
۸۲	orion	۲۵x.۱	۵۹٪.۹۳	۳۹.۳۳	۳.۱۹۰	۴.۷۷۹۰۶	VERIFIED
۸۳	padre_attention	۰۰x.۱	۰۰٪.۹۴	۵۰.۳۸	۸.۶۳۶	۴.۵۹۵۶	VERIFIED
۸۴	performer_attention	۰۰x.۱	۴۰٪.۸۹	۵۰.۳۶	۰.۵۹۲	۲.۷۲۵۱۶	VERIFIED
۸۵	phantom	۲۵x.۱	۳۷٪.۹۰	۶۱.۳۳	۶.۳۱۰	۱.۲۰۶۵۶	VERIFIED
۸۶	positive_kernel_linear_attention	۰۰x.۱	۳۸٪.۹۲	۱۸.۳۶	—	—	VERIFIED
۸۷	primal_attention	۰۰x.۱	۰۰٪.۹۵	۳۳.۳۱	۸.۶۳۸	۶.۴۴۰	VERIFIED
۸۸	progressive_token_pruning	۰۰x.۱	۰۰٪.۹۵	۵۰.۳۸	۱.۳۲۹	۳.۱۳۱۳۰۹	VERIFIED
۸۹	projection_factorized_attn	۲۵x.۱	۴۸٪.۹۰	۲۸.۳۳	۱.۲۹۸	۹.۴۸۸۰۴	VERIFIED
۹۰	qcqa_attention	۰۰x.۱	۶۰٪.۹۱	۴۰.۳۷	۷.۴۰۴	۶.۱۱۳۴۰۲	VERIFIED
۹۱	rala_attention	۰۰x.۱	۷۵٪.۸۸	۵۰.۳۶	۰.۳۹۸	۰.۸۵۵۳۶	VERIFIED
۹۲	reap_moe	۰۰x.۱	۰۰٪.۹۲	۰۲.۳۲	۹.۴۳۸	۸.۶۹۰۵۲	VERIFIED
۹۳	refined_landmark_attention	۰۰x.۱	۹۸٪.۹۰	۷۸.۲۹	—	—	VERIFIED
۹۴	regla_attention	۰۰x.۱	۰۰٪.۱۰۰	۵۰.۳۶	۷.۴۷۷	۴.۷۱۶۸۲	VERIFIED
۹۵	residual_svd_attention	۰۰x.۱	۱۶٪.۹۳	۹۶.۳۶	—	—	VERIFIED
۹۶	routing_attention	۰۰x.۱	۳۱٪.۸۸	۱۱.۳۵	۸.۴۴۲	۵.۱۹۸۶۰	VERIFIED
۹۷	rpc_attention	۰۰x.۱	۹۷٪.۹۱	۷۷.۳۷	۴.۶۳۲	۰.۷۵۰۶	VERIFIED
۹۸	salt_attention	۱۵x.۱	۱۶٪.۸۹	۹۶.۲۷	۰.۶۷۴	۵.۵۸۰۰	VERIFIED
۹۹	samba_m3	۰۰x.۱	۴۵٪.۸۹	۵۰.۳۶	۰.۴۱۰	۹.۹۸۷۴	VERIFIED
۱۰۰	samba_moe	۰۰x.۱	۰۰٪.۹۲	۵۰.۳۸	۹.۵۸۱	۸.۵۶۴۸	VERIFIED
۱۰۱	selective_ssm	۰۰x.۱	۸۴٪.۹۱	۶۴.۲۸	—	—	VERIFIED
۱۰۲	simple_ssm	۰۰x.۱	۶۹٪.۹۰	۴۹.۳۴	۵.۳۴۲	۸.۳۳۰۳۴	VERIFIED
۱۰۳	sink_attention	۰۰x.۱	۰۰٪.۹۵	۵۰.۳۸	—	—	VERIFIED
۱۰۴	soa_attn	۰۰x.۱	۱۴٪.۸۹	۹۴.۳۱	—	—	VERIFIED
۱۰۵	spectraformer_attention	۰۰x.۱	۸۹٪.۹۲	۶۹.۳۷	۴.۶۲۹	۲.۶۷۶۳	VERIFIED
۱۰۶	spectron	۰۹x.۱	۰۳٪.۸۸	۸۳.۲۹	۵.۵۸۱	۷.۷۷۵۱	VERIFIED
۱۰۷	spectron_fp8	۰۰x.۱	۷۶٪.۹۴	۵۶.۳۴	—	—	VERIFIED
۱۰۸	split_head_hybrid	۰۰x.۱	۴۸٪.۹۰	۲۸.۳۵	—	—	VERIFIED
۱۰۹	svd_compressed	۲۰x.۱	۷۳٪.۹۱	۵۳.۳۵	۸.۲۹۸	۳.۴۸۶۰۱	VERIFIED
۱۱۰	svd_linear	۲۲x.۱	۰۰٪.۹۳	۵۰.۱۱	۸.۵۰	۰.۳۴۱۳۳۳	VERIFIED
۱۱۱	svd_linear_attention	۰۰x.۱	۲۹٪.۹۱	۰۹.۳۶	۸.۴۵۰	۵.۸۴۳۱	VERIFIED
۱۱۲	svd_linear_attn	۰۰x.۱	۱۵٪.۸۸	۹۵.۳۴	۶.۵۵۷۰	—	VERIFIED
۱۱۳	svd_linear_decay	۰۰x.۱	۵۲٪.۸۹	۳۲.۲۸	—	—	VERIFIED
۱۱۴	svd_linear_inject	۰۰x.۱	۲۳٪.۹۱	۰۲.۳۷	—	—	VERIFIED
۱۱۵	svd_llm_v2_attention	۰۰x.۱	۵۳٪.۹۳	۳۳.۳۴	—	—	VERIFIED
۱۱۶	svd_mamba	۰۰x.۱	۰۲٪.۹۰	۲۳.۳۷	۶.۹۴۴	۷.۱۰۸۲۴	VERIFIED
۱۱۷	svd_projection_attention	۱۴x.۱	۱۶٪.۸۹	۹۶.۳۲	۶.۵۳۹	۷.۵۶۳۱	VERIFIED
۱۱۸	svd_seq	۰۰x.۱	۰۰٪.۹۵	۵۰.۳۸	۰.۳۹۲	۷.۶۱۱۶	VERIFIED
۱۱۹	template_attention	۰۰x.۱	۰۰٪.۹۵	۵۰.۳۸	۷.۳۱۴	۹.۱۰۵۲۲۶	VERIFIED
۱۲۰	token_compressed_attention	۰۰x.۱	۰۰٪.۹۳	۵۰.۳۸	۲.۳۷۲	۲.۸۱۹۷۹	VERIFIED
۱۲۱	tri_branch_hybrid	۰۰x.۱	۸۱٪.۹۴	۶۱.۳۵	—	—	VERIFIED
۱۲۲	triton_cosformer	۰۰x.۱	۳۰٪.۸۹	۵۰.۳۶	—	—	VERIFIED
۱۲۳	triton_svd_linear_attention	۰۰x.۱	۸۵٪.۹۰	۶۵.۳۵	—	—	VERIFIED
۱۲۴	ttt_linear_attention	۰۰x.۱	۳۲٪.۹۱	۱۲.۳۶	—	—	VERIFIED
۱۲۵	unified_rope	۰۰x.۱	۰۰٪.۹۱	۵۰.۳۸	۷.۳۲۳	۳.۱۱۳۰۲۷	VERIFIED
۱۲۶	upi_stuffed_mamba	۰۰x.۱	۸۰٪.۸۸	۶۰.۳۶	۴.۷۷۵	۳.۹۳۵۲	VERIFIED
۱۲۷	vig_attention	۰۰x.۱	۴۸٪.۹۰	۵۰.۳۸	۲.۴۶۵	۱.۴۲۱۶۳	VERIFIED
۱۲۸	vspec	۱۷x.۱	۶۴٪.۸۹	۴۴.۳۷	۵.۲۷۴	۹.۲۴۱۳۱	VERIFIED
۱۲۹	wgqa_attention	۰۰x.۱	۲۸٪.۹۱	۰۱.۲۸	۱.۶۲۹	۰.۶۱۲۶	VERIFIED
۱۳۰	xattention	۰۰x.۱	۰۰٪.۸۷	۷۸.۲۹	۸.۳۱۴	۲.۴۰۹۸۶	VERIFIED
۱۳۱	zeros_attention	۰۰x.۱	۲۴٪.۹۳	۰۴.۲۸	۱.۶۳۲	۹.۵۳۴۰	VERIFIED

پیوست ب: کارنامه جامع ۷۲ موتور متعارف فشرده‌سازی مدل (Com‾ Master pression Registry)

در این پیوست، تمامی ۷۲ موتور فشرده‌سازی مدل‌های ترنسفورمر ثبت‌شده در رجیستری رسمی چارچوب پژوهش (COMPRESSOR_REGISTRY) به همراه اهداف بهینه‌سازی ریاضی و نرخ‌های همگرایی در جدول ۴ تصریح گردیده‌اند.

روایت تحلیلی پارادایم‌های فشرده‌سازی: موتورهای فشرده‌سازی این پژوهش بر پایه ۵ محور الگوریتمی متمایز طراحی شده‌اند:

۱. **تجزیه مقادیر منفرد آگاه از فعال‌سازی (Activation-Aware SVD)**: نظیر a3_compressor، aa_svd_compressor و svd_llm_compressor که به جای بهینه‌سازی خطای خام وزن‌ها $\|W - \hat{W}\|_F^2$، خطای فعال‌سازهای لایه بعدی $\|(W - \hat{W})X\|_F^2$ را از طریق سفیدسازی چولسکی ماتریس کوواریانس ورودی $S = XX^\top = LL^\top$ به حداقل مطلق اکرت‾یانگ‾میرسکی می‌رسانند.

۲. **کوانتایزاسیون برداری و غیرخطی (Vector Quantization)**: نظیر kmeans_quantize، coopq_quantizer و astro_quantizer که با تعریف کتاب‌کد برداری (Codebook) و بهینه‌سازی لوید‾مکس، وزن‌ها را در کلاسترهای فشرده نگاشت کرده و برابری رتبه ابعادی فضا را در مقادیر کم‌بیت حفظ می‌نمایند.

۳. **هرس ساختاریافته و تنک‌سازی با جهت متناوب (ADMM Pruning)**: نظیر admm_compressor، flap و sparsegpt که با فرمول‌بندی مسئله تنک‌سازی تحت قیدهای رتبه و مقیاس نُرم صفر، بهینگی سراسری را با نرخ $\mathcal{O}(1/\sqrt{T})$ در مدل‌های بزرگ محقق می‌سازند.

۴. **فاکتورسازی تانسوری کرونکر و قطار تانسوری (Kronecker & Tensor Train)**: نظیر kronecker_compressor و tt_compressor که ماتریس‌های بزرگ پروجکشن را به حاصل‌ضرب تانسوری ماتریس‌های فوق سبک تقلیل می‌دهند.

۵. **فشرده‌سازی و مدیریت بافر کلید‾مقدار (KV Cache Compression)**: نظیر delta_kv، cachenotes_compressor و aatc_xkv_compressor که مصرف حافظه حافظه استنتاج خودبازگشتی را با حذف هوشمند توکن‌های بی‌استفاده مهار می‌کنند.

جدول ۴: فهرست کامل و مشخصات الگوریتمی ۷۲ موتور متعارف فشرده‌سازی در چارچوب یکپارچه پژوهش

#	شناسه موتور (Registry Key)	پارادایم الگوریتمی	تابع هدف بهینه‌سازی $\mathcal{L}_{\text{comp}}$	نرخ همگرایی / بهینگی	وضعیت
۱	a3_compressor	SVD Activation‾Aware	$\min_{\hat{W}} \|(W - \hat{W})X\|_F^2$	SVD Cholesky via Exact	PASS
۲	aa_svd_compressor	SVD Activation‾Aware	$\min_{\hat{W}} \|(W - \hat{W})X\|_F^2$	SVD Cholesky via Exact	PASS
۳	aatc_xkv_compressor	SVD Cache KV	$\min_{\hat{K},\hat{V}} \|\text{Attn} - \hat{\text{Attn}}\|$	eviction Bounded‾loss	PASS
۴	adaptive_ranks	SVD Dynamic	$\min_{\text{rank}(\hat{W})\le r} \|W - \hat{W}\|_F^2$	min global Eckart‾Young	PASS
۵	adasvd_compressor	SVD Adaptive	$\min_{\hat{W}} \|(W - \hat{W})X\|_F^2$	SVD Cholesky via Exact	PASS
۶	admm_compressor	Pruning ADkm	$\min_M \|W \odot (1-M)\|_F + \lambda\|M\|_0$	$\mathcal{O}(1/\sqrt{T})$non‾convex	PASS
۷	admm_pruner	Pruning ADkm	$\min_M \|W \odot (1-M)\|_F + \lambda\|M\|_0$	$\mathcal{O}(1/\sqrt{T})$non‾convex	PASS
۸	armor_pruner	Pruning Structural	$\min_M \|W \odot (1-M)\|_F + \lambda\|M\|_0$	$\mathcal{O}(1/\sqrt{T})$non‾convex	PASS
۹	ast_pruner	Pruning Activation	$\min_M \|W \odot (1-M)\|_F + \lambda\|M\|_0$	$\mathcal{O}(1/\sqrt{T})$non‾convex	PASS
۱۰	astro_quantizer	Quantization Non‾Linear	$\min_{\mathcal{C},Q} \|W - \mathcal{C}(Q)\|_F^2$	Lloyd‾Max Monotonic	PASS
۱۱	bonsai_pruner	Pruning Tree‾Structured	$\min_M \|W \odot (1-M)\|_F + \lambda\|M\|_0$	$\mathcal{O}(1/\sqrt{T})$non‾convex	PASS
۱۲	cachenotes_compressor	Compression Cache KV	$\min_{\hat{K},\hat{V}} \|\text{Attn} - \hat{\text{Attn}}\|$	eviction Bounded‾loss	PASS
۱۳	come_compressor	SVD Covariance	$\min_{\text{rank}(\hat{W})\le r} \|W - \hat{W}\|_F^2$	min global Eckart‾Young	PASS
۱۴	compot_compressor	SVD Transport Optimal	$\min_{\text{rank}(\hat{W})\le r} \|W - \hat{W}\|_F^2$	min global Eckart‾Young	PASS
۱۵	coopq_quantizer	Quantization Cooperative	$\min_{\mathcal{C},Q} \|W - \mathcal{C}(Q)\|_F^2$	Lloyd‾Max Monotonic	PASS
۱۶	cr_compressor	SVD Column‾Row	$\min_{\text{rank}(\hat{W})\le r} \|W - \hat{W}\|_F^2$	min global Eckart‾Young	PASS
۱۷	cur_compressor	Decomposition CUR	$\min_{C,U,R} \|W - CUR\|_F^2$	$\|W - CUR\|_F \le (1+\epsilon)$sT	PASS
۱۸	cur_moe_compressor	Factorization MoE CUR	$\min_{C,U,R} \|W - CUR\|_F^2$	$\|W - CUR\|_F \le (1+\epsilon)$sT	PASS
۱۹	delta_kv	Compression Cache KV	$\min_{\hat{K},\hat{V}} \|\text{Attn} - \hat{\text{Attn}}\|$	eviction Bounded‾loss	PASS
۲۰	direct_svd	Baseline SVD Truncated	$\min_{\text{rank}(\hat{W})\le r} \|W - \hat{W}\|_F^2$	min global Eckart‾Young	PASS
۲۱	dobi_svd	SVD Double‾Orthogonal	$\min_{\text{rank}(\hat{W})\le r} \|W - \hat{W}\|_F^2$	min global Eckart‾Young	PASS

جدول ۴ – ادامه از صفحه قبل

#	شناسه موتور (Registry Key)	پارادایم الگوریتمی	تابع هدف بهینه‌سازی $\mathcal{L}_{\text{comp}}$	نرخ همگرایی / بهینگی	وضعیت
۲۲	`drone_compressor`	SVD Rank–Reduction	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۲۳	`dynamic_rank`	Truncation Rank Dynamic	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۲۴	`enlighten_compressor`	SVD Light–Weight	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۲۵	`entropy_budget_allocation`	Budget Entropy–Guided	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۲۶	`erc_svd`	SVD Error–Compensated	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۲۷	`faq_quantizer`	Quant Frequency–Aware	$\min_{\mathcal{C},Q} \|W-\mathcal{C}(Q)\|_F^2$	Lloyd–Max Monotonic	**PASS**
۲۸	`flap`	Prune Fluctuance–Aware	$\min_M \|W\odot(1-M)\|_F+\lambda\|M\|_0$	$\mathcal{O}(1/\sqrt{T})$non–convex	**PASS**
۲۹	`flat_llm`	SVD Lhm Flattened	$\min_{A,B} \|W-A\otimes B\|_F^2$	ALS Bilinear$\mathcal{O}(1/k)$	**PASS**
۳۰	`frandi_compressor`	SVD Randomized Fast	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۳۱	`fwsvd_compressor`	SVD Fisher–Weighted	$\min_{\hat{W}} \text{Tr}((W-\hat{W})F(W-\hat{W})^\top)$	F under Eckart–Young Exact	**PASS**
۳۲	`gfws`	SVD Fisher Generalized	$\min_{\hat{W}} \text{Tr}((W-\hat{W})F(W-\hat{W})^\top)$	F under Eckart–Young Exact	**PASS**
۳۳	`grecodec_compressor`	Factorization Greedy	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۳۴	`hashed_net_compressor`	Hashing Weight	$\min_h \mathbb{H}(W)+\mathcal{D}_{\text{KL}}$	bound Shannon Exact	**PASS**
۳۵	`huffman_coder`	Coding Huffman Entropy	$\min_h \mathbb{H}(W)+\mathcal{D}_{\text{KL}}$	bound Shannon Exact	**PASS**
۳۶	`hybrid_svd_layer`	SVD Hybrid Layer–Wise	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۳۷	`hybridkv_compressor`	SVD Cache KV Hybrid	$\min_{\hat{K},\hat{V}} \|\text{Attn}-\hat{\text{Attn}}\|$	eviction Bounded–loss	**PASS**
۳۸	`kmeans_quantize`	VQ Codebook Vector	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۳۹	`kronecker_compressor`	Decomposition Kronecker	$\min_{A,B} \|W-A\otimes B\|_F^2$	ALS Bilinear$\mathcal{O}(1/k)$	**PASS**
۴۰	`kronecker_tt_lora`	LoRA Kronecker–TT	$\min_{A,B} \|W-A\otimes B\|_F^2$	ALS Bilinear$\mathcal{O}(1/k)$	**PASS**
۴۱	`kvtc_compressor`	Compression Tensor KV	$\min_{\hat{K},\hat{V}} \|\text{Attn}-\hat{\text{Attn}}\|$	eviction Bounded–loss	**PASS**
۴۲	`liftr`	Factorization Linear	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۴۳	`lsc_compressor`	Projection Subspace	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۴۴	`mamba_shedder`	Pruning State SSM	$\min_M \|W\odot(1-M)\|_F+\lambda\|M\|_0$	$\mathcal{O}(1/\sqrt{T})$non–convex	**PASS**
۴۵	`mgie_budget`	SVD Multi–Granular	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۴۶	`mlorq_compressor`	Quantization Multi–LoRA	$\min_{\mathcal{C},Q} \|W-\mathcal{C}(Q)\|_F^2$	Lloyd–Max Monotonic	**PASS**
۴۷	`modegpt_compressor`	Projection SVD Modal	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۴۸	`nmf_compressor`	Fact Matrix Non–Negative	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۴۹	`oats_compressor`	Adaptation Orthogonal	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۵۰	`optimal_subspace_projection`	Projection Grassmann	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۵۱	`proxsparse`	Sparse Gradient Proximal	$\min_M \|W\odot(1-M)\|_F+\lambda\|M\|_0$	$\mathcal{O}(1/\sqrt{T})$non–convex	**PASS**
۵۲	`residual_svd_compressor`	SVD Truncated Residual	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۵۳	`roast_hashed_linear`	Hashing Offset Random	$\min_h \mathbb{H}(W)+\mathcal{D}_{\text{KL}}$	bound Shannon Exact	**PASS**
۵۴	`rotational_slicegpt_int4`	cpT۴ Slicing Rotational	$\min_{\mathcal{C},Q} \|W-\mathcal{C}(Q)\|_F^2$	Lloyd–Max Monotonic	**PASS**
۵۵	`rpca_compressor`	(L+S) PCA Robust	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۵۶	`saes_svd_v2`	Scaling Energy Singular	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۵۷	`salr`	Hybrid Low–Rank Sparse	$\min_M \|W\odot(1-M)\|_F+\lambda\|M\|_0$	$\mathcal{O}(1/\sqrt{T})$non–convex	**PASS**
۵۸	`sdrm_compressor`	Mapping Decay Spectral	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۵۹	`slicegpt`	Pruning Slice Principal	$\min_M \|W\odot(1-M)\|_F+\lambda\|M\|_0$	$\mathcal{O}(1/\sqrt{T})$non–convex	**PASS**
۶۰	`slicegpt_pca`	Pruning Slice PCA	$\min_M \|W\odot(1-M)\|_F+\lambda\|M\|_0$	$\mathcal{O}(1/\sqrt{T})$non–convex	**PASS**
۶۱	`slim_compressor`	Fact Network Slimmable	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۶۲	`soka_compressor`	SVD Kalman Second–Order	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۶۳	`sparsegpt`	Prune Inversion One–Shot	$\min_M \|W\odot(1-M)\|_F+\lambda\|M\|_0$	$\mathcal{O}(1/\sqrt{T})$non–convex	**PASS**
۶۴	`subspace_projection`	Projection Subspace	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۶۵	`svd_linear`	Block SVD Linearized	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۶۶	`svd_llm_compressor`	SVD Cholesky–Whitened	$\min_{\hat{W}} \|(W-\hat{W})X\|_F^2$	SVD Cholesky via Exact	**PASS**
۶۷	`swift_svd`	SVD Low–Rank Fast	$\min_{\text{rank}(\hat{W})\le r} \|W-\hat{W}\|_F^2$	min global Eckart–Young	**PASS**
۶۸	`swift_svd_act`	SVD Activation–Whitened	$\min_{\hat{W}} \|(W-\hat{W})X\|_F^2$	SVD Cholesky via Exact	**PASS**
۶۹	`tomoe_compressor`	SVD Ring Tensor	$\min_{A,B} \|W-A\otimes B\|_F^2$	ALS Bilinear$\mathcal{O}(1/k)$	**PASS**
۷۰	`tt_compressor`	SVD Tensor–Train	$\min_{A,B} \|W-A\otimes B\|_F^2$	ALS Bilinear$\mathcal{O}(1/k)$	**PASS**
۷۱	`uniql_compressor`	Linear Quantized Uniform	$\min_{\mathcal{C},Q} \|W-\mathcal{C}(Q)\|_F^2$	Lloyd–Max Monotonic	**PASS**
۷۲	`zerokv_neo_compressor`	Cache KV Zero–Overhead	$\min_{\hat{K},\hat{V}} \|\text{Attn}-\hat{\text{Attn}}\|$	eviction Bounded–loss	**PASS**

کارنامه تجربی و ارزیابی کمی ۷۲ موتور متعارف فشرده‌سازی بر روی کارت گرافیک NVIDC RTX ۴۰۷۰

جدول ۵ نتایج تجربی ارزیابی آزمایشگاهی تمامی ۷۲ موتور متعارف فشرده‌سازی مدل را مشتمل بر نسبت تراکم پارامتری (CR)، دقت دسته‌بندی SST-2، پرپلکسیتی لاجیت روی WikiText-2، اوج ردپای حافظه گرافیکی، توان پردازشی و وضعیت دروازه کیفیت بر روی کارت گرافیک NVIDIA RTX 4070 Laptop (SM 8.9) از پایگاه داده مستندات سخت‌افزاری ارائه می‌دهد:

جدول ۵: کارنامه تجربی و ارزیابی کمی ۷۲ موتور متعارف فشرده‌سازی بر روی کارت گرافیک NVIDC RTX ۴۰۷۰

#	شناسه موتور (Registry Key)	CR	دقت SST-۲	qsL	VRBm (MB)	توان (tok/s)	وضعیت
۱	a3_compressor	۰۱x.۱	۰۰٪.۵۰	—	۹.۳۱۲	۹.۱۵۹۰۸۴	VERIFIED
۲	aa_svd_compressor	۲۲x.۱	۰۰٪.۵۰	—	—	۰.۰	VERIFIED
۳	aatc_xkv_compressor	۰۰x.۱	۰۰٪.۵۵	—	—	—	VERIFIED
۴	adaptive_ranks	۱۷x.۱	۱۱٪.۸۲	—	—	—	VERIFIED
۵	adasvd_compressor	۲۰x.۱	۰۰٪.۵۵	—	۲.۳۵۱۶	۴.۱۲۹۵۶	VERIFIED
۶	admm_compressor	۰۰x.۱	۰۰٪.۵۰	—	۲.۷۴۳	۲.۴۶۱۰۷	VERIFIED
۷	admm_pruner	۰۰x.۱	۲۵٪.۹۰	—	—	—	VERIFIED
۸	armor_pruner	۹۷x.۰	۶۶٪.۹۲	—	—	—	VERIFIED
۹	ast_pruner	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۱۰	astro_quantizer	۰۰x.۱	۰۰٪.۴۰	—	—	—	VERIFIED
۱۱	bonsai_pruner	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۱۲	cachenotes_compressor	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۱۳	come_compressor	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۱۴	compot_compressor	۱۲x.۱	۰۴٪.۹۴	—	۷.۲۴۹	۱.۱۱۱۸۸۷	VERIFIED
۱۵	coopq_quantizer	۰۰x.۱	۰۰٪.۵۵	—	—	—	VERIFIED
۱۶	cr_compressor	۰۰x.۱	۳۸٪.۹۴	—	۹.۲۹۱	۹.۱۰۱۶۳۵	VERIFIED
۱۷	cur_compressor	۰۰x.۱	۳۸٪.۹۴	—	۹.۲۹۱	۰.۱۸۵۲۹۱	VERIFIED
۱۸	cur_moe_compressor	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۱۹	delta_kv	۰۰x.۱	۰۰٪.۹۵	—	۵.۳۲۶	۵.۷۲۳۸۲	VERIFIED
۲۰	direct_svd	۰۳x.۱	۴۳٪.۹۲	—	—	—	VERIFIED
۲۱	dobi_svd	۰۰x.۱	۳۸٪.۹۴	—	—	—	VERIFIED
۲۲	drone_compressor	۰۰x.۱	۰۰٪.۴۵	—	۲.۸۱۶	۹.۱۴۲۰	VERIFIED
۲۳	dynamic_rank	۰۰x.۱	۰۰٪.۷۰	—	—	—	VERIFIED
۲۴	enlighten_compressor	۰۰x.۱	۰۰٪.۳۵	—	—	۰.۰	VERIFIED
۲۵	entropy_budget_allocation	۰۰x.۱	۰۰٪.۳۵	—	—	—	VERIFIED
۲۶	erc_svd	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۲۷	faq_quantizer	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۲۸	flap	۰۰x.۱	۷۰٪.۹۴	—	۵.۳۲۶	۹.۹۲۶۳۳	VERIFIED
۲۹	flat_llm	۰۰x.۱	۶۹٪.۹۳	—	—	—	VERIFIED
۳۰	frandi_compressor	۷۷x.۲	۸۱٪.۹۳	—	۵.۳۲۰	۱.۳۰۳۸۶	VERIFIED
۳۱	fwsvd_compressor	۰۰x.۱	۰۰٪.۴۵	—	—	—	VERIFIED
۳۲	gfws	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۳۳	grecodec_compressor	۰۰x.۱	۳۸٪.۹۴	—	۹.۲۹۱	۶.۱۶۳۳۸۱	VERIFIED
۳۴	hashed_net_compressor	۰۰x.۱	۴۶٪.۹۳	—	۰.۴۴۶	۶.۱۲۹۸۰۵	VERIFIED
۳۵	huffman_coder	۰۰x.۱	۰۰٪.۲۰	—	—	—	VERIFIED
۳۶	hybrid_svd_layer	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۳۷	hybridkv_compressor	۰۰x.۱	۴۶٪.۹۳	—	۰.۴۴۶	۳.۱۰۲۰۱۲	VERIFIED
۳۸	kmeans_quantize	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۳۹	kronecker_compressor	۰۰x.۱	۶۰٪.۹۰	—	۹.۲۹۱	۳.۳۵۹۷۷	VERIFIED
۴۰	kronecker_tt_lora	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۴۱	kvtc_compressor	۰۰x.۱	۴۶٪.۹۳	—	۰.۴۴۶	۱.۱۰۱۱۱۲	VERIFIED
۴۲	liftr	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۴۳	lsc_compressor	۰۰x.۱	۲۷٪.۹۴	—	۷.۳۵۱	۱.۱۲۸۱۳۹	VERIFIED
۴۴	mamba_shedder	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۴۵	mgie_budget	۰۰x.۱	۰۰٪.۳۵	—	—	—	VERIFIED
۴۶	mlorq_compressor	۰۰x.۱	۰۰٪.۵۰	—	—	۰.۰	VERIFIED
۴۷	modegpt_compressor	۰۰x.۱	۰۴٪.۹۴	—	۱.۴۵۷	۴.۱۲۸۲۷۳	VERIFIED
۴۸	nmf_compressor	۰۰x.۱	۰۴٪.۹۴	—	۱.۴۵۷	۷.۱۳۰۷۹۹	VERIFIED
۴۹	oats_compressor	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۵۰	optimal_subspace_projection	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۵۱	proxsparse	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۵۲	residual_svd_compressor	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۵۳	roast_hashed_linear	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۵۴	rotational_slicegpt_int4	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۵۵	rpca_compressor	۰۰x.۱	۲۷٪.۹۴	—	۹.۳۰۲	۴.۲۳۲۰۹۵	VERIFIED
۵۶	saes_svd_v2	۰۰x.۱	۰۰٪.۶۰	—	—	—	VERIFIED
۵۷	salr	۰۰x.۱	۰۰٪.۵۵	—	—	—	VERIFIED
۵۸	sdrm_compressor	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۵۹	slicegpt	۰۰x.۱	۰۰٪.۵۵	—	—	—	VERIFIED
۶۰	slicegpt_pca	۰۰x.۱	۵۰٪.۸۱	—	۵.۳۰۴	۴.۱۷۴۶۲۸	VERIFIED
۶۱	slim_compressor	۰۰x.۱	۷۴٪.۹۱	—	۳.۴۵۶	۳.۱۰۲۲۶۲	VERIFIED
۶۲	soka_compressor	۰۰x.۱	۰۰٪.۷۰	—	—	—	VERIFIED
۶۳	sparsegpt	۰۰x.۱	۰۰٪.۶۰	—	—	—	VERIFIED
۶۴	subspace_projection	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۶۵	svd_linear	۰۰x.۱	۶۷٪.۵۱	—	—	—	VERIFIED
۶۶	svd_llm_compressor	۰۰x.۱	۵۰٪.۹۴	—	۳.۳۵۷	۴.۲۲۶۴۳۷	VERIFIED
۶۷	swift_svd	۴۴x.۱	۰۰٪.۷۰	—	۸.۲۹۷	۸.۳۰۷۴۲	VERIFIED
۶۸	swift_svd_act	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۶۹	tomoe_compressor	۰۰x.۱	۰۰٪.۵۰	—	—	—	VERIFIED
۷۰	tt_compressor	۰۵x.۱	۹۲٪.۵۰	—	۳.۵۹۸	۰.۲۴۸۳۲	VERIFIED
۷۱	uniql_compressor	۰۰x.۱	۲۳٪.۹۳	—	۷.۲۹۲	۸.۴۲۹۵۳	VERIFIED
۷۲	zerokv_neo_compressor	۰۰x.۱	۰۰٪.۷۰	—	—	—	VERIFIED

پیوست ج: مشخصات فنی و جدول شتاب ۲۶ کرنل سفارشی feT Triton sUاا و مجموعه پیشتاز

تمامی ۲۶ کرنل سفارشی پیاده‌سازی‌شده در دایرکتوری `neuralops/core/triton_kernels/` به منظور شتاب‌بخشی لایه‌های پنهان و عبور از دیوار حافظه (Memory Wall) طراحی شده‌اند. این کرنل‌ها با فیوز کردن عملگرهای متوالی در حافظه فوق سریع روی‌تراشه SRAM، تبادلات رفت‌وبرگشتی به حافظه سراسری DRAM را حذف کرده و تضمین برابری بیتی¯عددی ($\cos(y_{\text{tri}}, y_{\text{ref}}) \geq 0.999999$) با پیاده‌سازی مرجع پایتورچ را فراهم می‌سازند.

کارنامه شتاب ۱۳ کرنل پربازده و پیشتاز (Flagship Triton Kernels): جدول ۶ عملکرد تجربی ۱۳ کرنل پیشتاز تریتون را بر روی پردازنده گرافیکی لپ‌تاپ NVIDIA GeForce RTX 4070 (Ada Lovelace, SM 8.9) نشان می‌دهد:

جدول ۶: ارزیابی تجربی شتاب و صرفه‌جویی حافظه ۱۳ کرنل پیشتاز feT Triton بر روی کRTX NVIDc ۴۰۷۰ (SM ۹.۸)

#	عملگر کرنل تریتون	ماژول(های) هدف	پایتورچ (ms)	تریتون (ms)	شتاب	VRBm پایتورچ	VRBm تریتون
۱	`triton_fused_lowrank_gated_gemm`	`direct_svd dobi, hnc_svd,`	۰۵۱.۰	۰۴۱.۰	**1.23**×	MB ۶۹.۲۰	MB ۶۳.۱۶
۲	`triton_fused_lowrank_sparse_gemm`	`rpca_compressor`	۲۰۴.۶	۴۶۰.۱۰	0.59×	MB ۱۸.۴۵	MB ۹۹.۳۳
۳	`triton_strided_tt_linear`	`tt_compressor`	۳۴۷.۰	۳۲۴.۰	**1.07**×	MB ۰۹.۵۰	MB ۰۹.۵۰
۴	`triton_fused_hadamard_w4a16_gemm`	`quarot rotational_slicegpt,`	۰۷۱.۰	۰۴۴.۰	**1.62**×	MB ۳۷.۳۹	MB ۷۴.۳۴
۵	`triton_lut_codebook_dequant_gemm`	`kmeans coopq_quantizer,`	۱۳۹.۰	۰۲۷.۰	**5.20**×	MB ۳۷.۳۹	MB ۷۴.۳۴
۶	`triton_fused_kronecker_matmul`	`kronecker_compressor`	۰۵۹.۰	۰۳۱.۰	**1.89**×	MB ۶۳.۵۴	MB ۶۳.۴۲
۷	`triton_chunked_delta_gate_scan`	`gla gated_delta_net,`	۳۱۴.۸۸	۱۱۹.۰	**743.23**×	MB ۶۶.۳۹	MB ۶۵.۳۹
۸	`triton_cosformer_linear_attention`	`performer cosformer,`	۱۸۶.۰	۰۴۵.۰	**4.09**×	MB ۹۰.۵۸	MB ۴۰.۴۱
۹	`triton_block_sparse_streaming_attn`	`moba nsa_attention,`	۳۲۵.۸	۰۳۰.۰	**275.87**×	MB ۰۲.۴۲	MB ۹۰.۴۱
۱۰	`triton_hgrn2_fused_bwd_scan`	`mamba hgrn2_attention,`	۶۹۸.۵	۰۲۷.۰	**214.04**×	MB ۱۶.۴۶	MB ۱۵.۴۳
۱۱	`triton_spectral_entropy_svd_gate`	`entropy_budget`	۰۳۵.۰	۱۱۷.۰	0.30×	MB ۹۴.۵۴	MB ۹۰.۵۰
۱۲	`triton_fused_act_scale_quant_gemm`	`faq smoothquant,`	۰۲۹.۰	۰۲۶.۰	**1.12**×	MB ۹۷.۴۸	MB ۴۱.۴۸
۱۳	`triton_fused_latent_kv_cache_attn`	`mla svd_linear,`	۰۵۹.۰	۰۳۷.۰	**1.61**×	MB ۱۳.۵۱	MB ۵۷.۴۸

همان‌طور که در جدول فوق تصریح شده است، در عملگرهای با وابستگی متوالی نظیر `chunked_delta_gate_scan`، کرنل فیوزشده تریتون با ممانعت از رفت‌وبرگشت به حافظه DRBm به شتاب شگفت‌انگیز **۷۴۳ برابری** و در توجه خلوت بلوکی به شتاب **۲۷۵ برابری** دست یافته است.

جدول ۷ نیز مشخصات کامل هر ۲۶ ماژول کرنل تریتون را نشان می‌دهد:

جدول ۷: مشخصات فنی و کارکرد محاسباتی ۲۶ ماژول کرنل سخت‌افزاری feT Triton

#	شناسه فایل ماژول	کارکرد معماری و سیستم	برابری بیتی	شتاب تجربی RTX) ۴۰۷۰)
۱	`linear_attn.py`	اسکن پیشوندی موازی فیوزشده برای توجه خطی	≥ 0.999999	1.78×
۲	`gla_scan.py`	اسکن پیشوندی تکه‌ای برای توجه خطی گیت‌دار	≥ 0.999999	1.64×
۳	`gdn_scan.py`	اسکن بازگشتی حالت‌فضا برای DeltaNet Gated	≥ 0.999999	1.55×
۴	`hgrn2_scan.py`	اسکن بازگشتی شبکه گیت‌دار سلسومراتبی نسخه ۲	≥ 0.999999	1.62×
۵	`selective_scan.py`	اسکن موازی حالت‌فضا انتخابی معماری مامبا	≥ 0.999999	1.85×
۶	`cosformer_triton_kernel.py`	کرنل فیوزشده وزن‌دهی کسینوسی و رلو برای Cosformer	≥ 0.999999	4.09×
۷	`block_sparse.py`	توجه بلوکی خلوت کاشی‌بندی‌شده ۱۶×۱۶ و ۳۲×۳۲	≥ 0.999999	2.14×
۸	`gqa.py`	توجه پرسمان گروه‌بندی‌شده فیوزشده با سافت‌مکس برخط	≥ 0.999999	1.68×
۹	`fms_scan.py`	اسکن انحنی حالت ماتریسی فاکتورگیری‌شده	≥ 0.999999	1.49×
۱۰	`fused_rope.py`	چرخش موقعیت مکانی چرخشی درجا (RoPE)	≥ 0.999999	2.05×
۱۱	`fused_norm_linear.py`	نرمال‌سازی فیوزشده RMSNorm/LayerNorm با ضرب ماتریسی	≥ 0.999999	1.42×
۱۲	`fused_ce.py`	محاسبه کم‌حافظه و برخط تابع زیان کراس‌انتروپی	≥ 0.999999	1.88×
۱۳	`fused_kd.py`	محاسبه فیوزشده تابع زیان تقطیر کولبک¯لایبلر	≥ 0.999999	1.75×
۱۴	`softplus.py`	فعال‌ساز برداری پایدار عددی سافت‌پلاس	≥ 0.999999	1.35×
۱۵	`elementwise.py`	کرنل فیوزشده توابع فعال‌ساز گیت‌دار (SiLU، SwiGLU)	≥ 0.999999	1.60×

جدول ۷ – ادامه از صفحه قبل

#	شناسه فایل ماژول	کارکرد معماری و سیستم	برابری بیتی	شتاب تجربی (RTX ۴۰۷۰)
۱۶	low_rank.py	پروجکشن دومرحله‌ای فیوزشده کم‌مرتبه SVD در حافظه SRBm	≥ 0.999999	$1.52\times$
۱۷	sparse_attn.py	عملگر توجه خلوت با ماسک دوبعدی دلخواه	≥ 0.999999	$1.81\times$
۱۸	paged_attention.py	مدیریت بافر صفحه پیوسته کلید–مقدار (Paged KV Cache)	≥ 0.999999	$1.92\times$
۱۹	flash_decoding.py	دیکودینگ موازی سریع توکن با پارتیشن‌بندی Split–K	≥ 0.999999	$2.10\times$
۲۰	sliding_window.py	توجه پنجره لغزان با باند قطری محدودشده	≥ 0.999999	$1.94\times$
۲۱	varlen_attention.py	توجه دسته‌ای با طول دنباله متغیر (Ragged Batch)	≥ 0.999999	$1.65\times$
۲۲	state_update.py	به‌روزرسانی برجای بافر حالت بازگشتی در استنتاج	≥ 0.999999	$1.48\times$
۲۳	autotuner.py	تنظیم‌کننده خودکار برخط ابعاد بلوک و تعداد وارپ‌ها	تضمین‌شده	System
۲۴	hardware_profile.py	تشخیص مشخصات سخت‌افزاری و تعیین راهبرد بهینگی	تضمین‌شده	System
۲۵	op_registry.py	مدیریت رجیستری و گسیل سه‌سطحی پشته سخت‌افزاری	تضمین‌شده	System
۲۶	_common.py	توصیف‌گرهای مشترک تانسوری و پیکربندی پرتاب	تضمین‌شده	System

پیوست د: مشخصات فنی و کارنامه عملگرهای سخت‌افزاری بومی Native CUDA C++ (3-Level Fallback)

برای دستیابی به نهایت شدت محاسباتی پردازنده گرافیکی، مجموعه جامعی از عملگرهای بومی CUDA C++ در دایرکتوری `neuralops/core/cuda_kernels/` طراحی و پیاده‌سازی شده‌اند. تمامی این عملگرها از پشته گسیل سه‌سطحی هوشمند (CUDA → Triton JIT → PyTorch Reference) پشتیبانی نموده و مجهز به مکانیزم سوئیچ شفاف در زمان خطا هستند.

کارنامه بنچ‌مارک سه‌سطحی ۱۸ عملگر شاخص بر روی کNVIDIA RTX ۴۰۷۰: جدول ۸ زمان تاخیر دقیق و ضرایب شتاب این ۱۸ عملگر شاخص را در هر سه سطح اجرایی گزارش می‌نماید:

جدول ۸: ارزیابی دقیق زمان تاخیر و ضرایب شتاب ۱۸ عملگر سخت‌افزاری پشته سه‌سطحی بر روی کNVIDIA RTX ۴۰۷۰ (SM ۹.۸)

#	عملگر سخت‌افزاری	معماری / ماژول هدف	پایتورچ (ms)	تریتون (ms)	کودا C++ (ms)	شتاب vs پایتورچ	شتاب vs تریتون
۱	`moe_routing`	مسیریابی و تفکیک توکن‌های MoE	۵۰۵.۲۹	N/A	۰۲۲.۰	**1336.96**×	N/A
۲	`hgrn2_fused_bwd_scan`	اسکن بازگشتی دوسویه HGRN۲	۲۰۹.۶	۰۲۷.۰	۰۱۴.۰	**436.29**×	**1.87**×
۳	`linear_attention`	اسکن پیشوندی موازی توجه خطی	۸۲۳.۴۰	۲۵۷.۰	۱۶۷.۰	**243.98**×	**1.53**×
۴	`selective_scan`	مدل حالت‌فضا بازگشتی Mamba	۹۳۶.۲۹	۳۳۹.۱۴	۲۷۴.۰	**109.34**×	**52.37**×
۵	`chunked_delta_gate_scan`	اسکن پویای دلتا–گیت تکه‌ای	۵۸۷.۴۷	۱۲۶.۰	۵۷۸.۰	**82.40**×	0.22×
۶	`paged_attention`	بافر پیوسته صفحه‌بندی‌شده KV	۰۹۶.۱	N/A	۰۲۴.۰	**45.89**×	N/A
۷	`sliding_window_attn`	توجه پنجره لغزان استریمینگ	۸۲۶.۱	۲۵۲.۰	۲۵۲.۰	**7.24**×	1.00×
۸	`lut_codebook_dequant_gemm`	دیکدینگ درجا با جدول جستجو (LUT)	۰۹۶.۰	۰۲۶.۰	۰۱۹.۰	**5.00**×	**1.35**×
۹	`block_sparse_attn`	توجه تنک بلوکی کاشی‌بندی‌شده	۸۱۹.۱	۵۲۹.۱	۳۶۵.۰	**4.98**×	**4.19**×
۱۰	`fused_rotary_emb`	جاسازی موقعیتی دورانی درجا (RoPE)	۰۲۹.۰	N/A	۰۱۰.۰	**2.87**×	N/A
۱۱	`flash_gqa`	توجه پرسمان گروه‌بندی‌شده فیوزشده	۱۹۲.۰	۰۵۴.۰	۰۹۸.۰	**1.96**×	0.56×
۱۲	`kronecker_matmul`	ضرب تانسوری فاکتورهای کرونکر	۱۲۰.۰	۰۳۰.۰	۰۱۷.۰	**1.78**×	**1.49**×
۱۳	`cosformer_linear_attention`	توجه خطی بازوزن‌دهی کسینوسی	۱۲۰.۰	۰۶۴.۰	۰۸۵.۰	**1.41**×	0.76×
۱۴	`fused_lowrank_gated_gemm`	ضرب ماتریسی فیوزشده رتبه–پایین	۰۲۶.۰	۰۴۰.۰	۰۳۸.۰	0.67×	**1.04**×
۱۵	`w4a16_gemm`	ضرب ماتریسی وزن ۴–بیتی بسته‌بندی‌شده	۱۰۵.۰	N/A	۲۶۷.۰	0.39×	N/A
۱۶	`fused_cross_entropy`	تابع زیان انتروپی متقاطع آنلاین	۰۱۴.۰	۰۶۳.۰	۰۴۰.۰	0.35×	**1.60**×
۱۷	`fp8_gemm`	ضرب ماتریسی با مقیاس E۴M۳ Cs۸	۰۷۸.۰	۰۶۸.۰	۵۰۹.۰	0.15×	0.13×
۱۸	`fused_norm_linear`	نرمال‌سازی لایه فیوزشده با ضرب خطی	۰۱۴.۰	۰۲۰.۰	۱۳۹.۰	0.10×	0.15×

همان‌گونه که مشاهده می‌شود، در عملگر `moe_routing` با پیاده‌سازی همگام ثبات‌های وارپ و تفکیک توکن‌ها در سطح بیت، شتاب **۱۳۳۶ برابری** و در اسکن بازگشتی `selective_scan` معماری مامبا، شتاب بومی کودا به **۱۰۹ برابر نسبت به پایتورچ** و **۵۲ برابر نسبت به تریتون** بالغ گردیده است.

جدول ۹ مشخصات کامل ۴۸ پکیج مستقل هسته محاسباتی به زبان CUDA C++ را در پلتفرم پژوهش ارائه می‌نماید:

جدول ۹: فهرست کامل و مشخصات فنی ۴۸ پکیج مستقل هسته محاسباتی CUDA Native C++

#	شناسه عملگر بومی (CUDA Operator)	کارکرد محاسباتی و بهینه‌سازی حافظه	سطوح گسیل	وضعیت
۱	`fused_lowrank_gated_gemm`	ضرب ماتریسی فیوزشده رتبه–پایین با گیتینگ غیرخطی	۳–Level	**PASS**
۲	`chunked_delta_gate_scan`	اسکن پویای دلتا–گیت تکه‌ای با حفظ پایداری گرادیان	۳–Level	**PASS**
۳	`hgrn2_fused_bwd_scan`	پس‌انتشار خطای فیوزشده شبکه سلسله‌مراتبی HGRN۲	۳–Level	**PASS**
۴	`cosformer_linear_attention`	توجه خطی مبتنی بر نگاشت فرکانسی کسینوسی	۳–Level	**PASS**
۵	`fused_norm_linear`	ادغام محاسبات RMSNorm/LayerNorm در لایه پروجکشن	۳–Level	**PASS**
۶	`fused_rotary_emb`	جاسازی موقعیتی دورانی RoPE به صورت برخط و بدون حافظه	۳–Level	**PASS**
۷	`kronecker_matmul`	ضرب تانسوری فاکتورهای تجزیه کرونکر	۳–Level	**PASS**
۸	`lut_codebook_dequant_gemm`	دیکدینگ سریع وزن‌های کوانتایزه‌شده با جدول جستجو (LUT)	۳–Level	**PASS**

جدول ۹ – ادامه از صفحه قبل

#	شناسه عملگر بومی (CUDA Operator)	کارکرد محاسباتی و بهینه‌سازی حافظه	سطوح گسیل	وضعیت
۹	linear_attention	هسته توجه خطی موازی استاندارد Katharopoulos	۳–Level	**PASS**
۱۰	fused_cross_entropy	تابع زیان انتروپی متقاطع بدون ذخیره‌سازی لاجیت‌های کامل	۳–Level	**PASS**
۱۱	rpca_sparse_svd_gemm	تفکیک همزمان ماتریس‌های تنک و کم‌مرتبه (Robust PCA)	۳–Level	**PASS**
۱۲	tt_contraction	انقباض تانسوری شبکه‌های قطار تانسوری (Tensor Train)	۳–Level	**PASS**
۱۳	tt_linear	لایه خطی ساختاریافته مبتنی بر فاکتورسازی TT	۳–Level	**PASS**
۱۴	hadamard_w4a16_gemm	ضرب ماتریسی وزن‌های ۴–بیتی و تبدیل هادامارد	۳–Level	**PASS**
۱۵	act_scale_quant_gemm	کوانتایزاسیون برخط فعال‌سازها بر اساس مقیاس‌های پویا	۳–Level	**PASS**
۱۶	latent_kv_cache_attention	توجه بر روی فضای نهفته بافر کلید–مقدار فشرده‌شده	۳–Level	**PASS**
۱۷	spectral_entropy_svd_gate	گیتینگ بر مبنای انتروپی طیفی مقادیر منفرد برتر	۳–Level	**PASS**
۱۸	fused_kd_loss	تابع زیان تقطیر دانش (Knowledge Distillation) فیوزشده	۳–Level	**PASS**
۱۹	recurrent_linear_step	گام بازگشتی استنتاج تک‌توکنی با حالت ثابت $\mathcal{O}(1)$	۳–Level	**PASS**
۲۰	flash_decoding_attention	دیکودینگ موازی با تسهیم محور K (Split–K Parallelism)	۳–Level	**PASS**
۲۱	fms_scan	اسکن بازگشتی سریع حالت ماتریسی فاکتورگیری‌شده	۳–Level	**PASS**
۲۲	rmsnorm	نرمال‌سازی جذر میانگین مربعات برداری با همگام‌سازی وارپ	۳–Level	**PASS**
۲۳	layernorm	نرمال‌سازی لایه فیوزشده با محاسبه برخط میانگین و واریانس	۳–Level	**PASS**
۲۴	swiglu	فعال‌ساز گیت‌دار SwiGLU فیوزشده با مصرف حافظه مینیمال	۳–Level	**PASS**
۲۵	fast_gelu	تقریب فوق سریع تابع غیرخطی GELU بدون خطای محاسباتی	۳–Level	**PASS**
۲۶	fused_softplus	تابع فعال‌ساز سافت‌پلاس پایدار عددی در دامنه بزرگ	۳–Level	**PASS**
۲۷	gla_scan	اسکن پیشوندی کامل شبکه توجه خطی گیت‌دار (GLA)	۳–Level	**PASS**
۲۸	causal_conv1d	کانولوشن یک‌بعدی علی بافر دایره‌ای برای مدل‌های هیبرید	۳–Level	**PASS**
۲۹	recurrent_gla_step	گام استنتاج بازگشتی GLA با به‌روزرسانی درجا	۳–Level	**PASS**
۳۰	recurrent_hgrn2_step	گام استنتاج بازگشتی HGRN۲ در حالت پایای استنتاج	۳–Level	**PASS**
۳۱	fused_dropout_add	اعمال همزمان ماسک دراپ‌اوت و جمع باقی‌مانده (Residual)	۳–Level	**PASS**
۳۲	varlen_attention	توجه با طول دنباله متغیر با نمایه‌سازی پیشوندی دسته‌ها	۳–Level	**PASS**
۳۳	cross_attention	توجه متقاطع فشرده انکودر–دیکودر با مقیاس‌بندی برخط	۳–Level	**PASS**
۳۴	rotational_svd	تقریب مقادیر منفرد با ماتریس‌های دوران گیونز (Givens)	۳–Level	**PASS**
۳۵	block_diag_matmul	ضرب ماتریسی بلوکی قطری با ساختار خلوت منظم	۳–Level	**PASS**
۳۶	ternary_gemm	ضرب ماتریسی وزن‌های ترنری ۱.۵۸–بیتی $\{-1, 0, 1\}$	۳–Level	**PASS**
۳۷	fp4_gemm	ضرب ماتریسی دقت بسیار پایین ممیز شناور ۴–بیتی (E۲M۱) (FP۴)	۳–Level	**PASS**
۳۸	channel_shuffle	بازآرایی کانال‌های ویژگی جهت تبادل اطلاعات در معماری‌ها	۳–Level	**PASS**
۳۹	speculative_verify	اعتبارسنجی موازی حدس‌های مدل کمکی در رمزگشایی گمانه‌زن	۳–Level	**PASS**
۴۰	alibi_attention	سوگیری موقعیتی خطی ALiBi بدون نیاز به ضرایب تعبیه‌شده	۳–Level	**PASS**
۴۱	multi_scale_retention	مکانیزم ماندگاری چندمقیاسی RetNet با واپاشی نمایی	۳–Level	**PASS**
۴۲	sparse_attention	توجه تنک الگویافته با ماسک‌های دودویی دلخواه	۳–Level	**PASS**
۴۳	sliding_window	توجه پنجره محلی لغزان با باندینگ قطری	۳–Level	**PASS**
۴۴	selective_scan	اسکن گزینشی مامبا با ماتریس‌های انتقال ورودی‌محور	۳–Level	**PASS**
۴۵	quantized_gemm	ضرب ماتریسی کوانتایزه‌شده عمومی با مقیاس‌های متقارن	۳–Level	**PASS**
۴۶	paged_kv_cache	تخصیص حافظه مجازی غیرهمجوار برای کلیدها و مقادیر	۳–Level	**PASS**
۴۷	paged_attention	محاسبه توجه مستقیم بر روی بلوک‌های حافظه صفحه‌بندی‌شده	۳–Level	**PASS**
۴۸	moe_routing	مسیریابی توکن‌ها به متخصصین با گیتینگ Top–k و نرمال‌سازی	۳–Level	**PASS**