



دانشگاه تهران

پردیس دانشکده‌های فنی

دانشکده مهندسی برق و کامپیوتر

گزارش پایانی پروژه کارشناسی مهندسی کامپیوتر (گرایش نرم‌افزار)

طراحی، ارزیابی تجربی و فشرده‌سازی مکانیزم‌های توجه خطی و تجزیه مقادیر منفرد (SVD) در مدل‌های زبانی بزرگ ترنسفورمر

NeuralOps: A Hardware-Aware Framework for Scalable SVD Linear Attention and Model Compression

---

نگارش: محمد طاها مجلسی

شماره دانشجویی: ۸۱۰۱۰۱۵۰۴

استاد راهنما: جناب آقای دکتر احمد کلهر

استاد داور: تعیین توسط گروه آموزشی نرم‌افزار

شهریور ماه ۱۴۰۵

دانشگاه تهران

پردیس دانشکده‌های فنی — دانشکده مهندسی برق و کامپیوتر

تاییدیه پایان‌نامه کارشناسی

پروژه کارشناسی آقای محمد طاها مجلسی به شماره دانشجویی ۸۱۰۱۰۱۵۰۴ در رشته مهندسی کامپیوتر (گرایش نرم‌افزار) تحت عنوان:

«طراحی، ارزیابی تجربی و فشرده‌سازی مکانیزم‌های توجه خطی و تجزیه مقادیر منفرد (SVD) در مدل‌های زبانی بزرگ ترنسفورمر»

در تاریخ ۲۳ شهریورماه ۱۴۰۵ توسط هیئت داوران مورد بررسی و با درجه عالی به تصویب رسید.

استاد راهنما:

جناب آقای دکتر احمد کلهر

امضاء:

دانشجو:

محمد طاها مجلسی

امضاء:



استاد داور:

نام و نام خانوادگی داور محترم

امضاء:

مدیر گروه مهندسی نرم‌افزار:

نام و نام خانوادگی مدیر محترم گروه

امضاء:

به پیشگاه پدر و مادر عزیزم،
که مهر بی‌دریغ، فداکاری‌های بی‌کران و باور همیشگی‌شان چراغ راه تمام لحظات زندگی من بوده است؛

و به روان پاک تمامی پویندگان دانش و خرد که برای پیشرفت علم و اعتلای بشریت تلاش کردند.

سپاسگزاری

خداوند متعال را شاکرم که توفیق عنایت فرمود تا این گام پژوهشی مهم را با تکیه بر علم و پشتکار به سرانجام برسانم. بر خود واجب می‌دانم مراتب امتنان و سپاس خالصانه خود را تقدیم استاد فرهیخته و بزرگوارم، جناب آقای دکتر احمد کلهر نمایم که همواره با صبر، درایت، و راهنمایی‌های دقیق و عالمانه خویش در طول اجرای پروژه کارشناسی، مسیر روشن تحقیق و نوآوری را پیش روی من گشودند. همچنین از اساتید بزرگوار دانشکده مهندسی برق و کامپیوتر دانشگاه تهران و همکاران گرامی در آزمایشگاه پژوهشی که همفکری و حمایت‌های فنی‌شان زمینه‌ساز تحقق این دستاورد گردید، صمیمانه قدردانی می‌نمایم.

چکیده

مکانیزم توجه متقاطع استاندارد Multi-Head Dot-Product (Scaled Attention) در معماری‌های مبتنی بر ترنسفورمر، به دلیل محاسبات ماتریسی دوطرفه میان توکن‌های ورودی، دارای پیچیدگی زمانی و حافظه‌ای درجه‌دو ($\mathcal{O}(N^2)$ نسبت به طول دنباله N است. با گسترش کاربرد مدل‌های زبانی بزرگ (Lhms) در پردازش زمینه‌های چند ده‌هزار توکنی، این پیچیدگی غیرخطی به یک گلوگاه سخت‌افزاری حیاتی در حافظه با پهنای باند بالا (HBM) و توان عملیاتی پردازنده‌های گرافیکی مبدل شده است. اگرچه مکانیزم‌های توجه خطی و مدل‌های بازگشتی فضای حالت (SSM) پیچیدگی تئوری $\mathcal{O}(N)$ را نوید می‌دهند، در پیاده‌سازی‌های سخت‌افزاری با افت شدید نسبت محاسبات به حافظه (Arithmetic Intensity) و ناپایداری عددی مواجه می‌شوند.

در این پروژه کارشناسی، چارچوب جامع، سیستماتیک و سخت‌افزار-آگاه NeuralOps طراحی و پیاده‌سازی شده است. این چارچوب با دربرگیری بیش از ۲۳۰ عملگر محاسباتی (شامل ۱۳۰ مکانیزم توجه خطی/طیفی/فضای حالت و ۱۰۰ موتور فشرده‌سازی و تقریب کم‌مرتبه)، بستری یکپارچه برای ارزیابی تجربی، تزریق خودکار بدون نیاز به بازآموزی سنگین (Zero-Shot Injection) Module و بهینه‌سازی مدل‌های ترنسفورمر فراهم می‌کند. مشارکت‌های فنی کلیدی این رساله شامل: (۱ پیاده‌سازی کرنل‌های فیوزشده ترایتون (Fused Triton SVD Kernels) جهت اجرای نگاشت‌های مرتبه پایین کاملاً در حافظه SRBm بدون سربار HBM؛ (۲ بهینه‌سازی منیفلدی ریماین بر روی منیفلدهای استیفل ($\mathrm{St}(p,n)$ جهت تضمین تعامد پایه‌ها؛ (۳ توسعه الگوریتم تخصیص پویای مرتبه مبتنی بر آنتروپی طیفی مقادیر منفرد به همراه انطباق باقی‌مانده طیفی (Res-SVD)؛ و (۴ تعبیه گیت‌های نمایی وابسته به داده جهت جلوگیری از واگرایی ماتریس‌های حالت در دنباله‌های طولانی ($N > 64\text{k}$).

نتایج ارزیابی‌های جامع بر روی مدل‌های مرجع DistilBERT، RoBERTa، BERT-sT-۲ و Qwen۳.۵ در بنچ‌مارک استاندارد GLUE (شامل داده‌های SST-۲، MRPC و Cohs) نشان می‌دهد که چارچوب پیشنهادی به کاهش تا ۵۰٪ در زمان تاخیر استنتاج (Latency)، کاهش بیش از ۴۰٪ در مصرف حافظه گرافیکی (Peak VRBm) و توان پردازش پایدار ۱۷،۲۰۰ توکن در ثانیه دست می‌یابد، در حالی که بیش از ۹۹.۵٪ از دقت نسخه پایه مدل حفظ می‌گردد.

واژگان کلیدی: مکانیزم‌های توجه خطی، تجزیه مقادیر منفرد (SVD)، فشرده‌سازی مدل‌های زبانی بزرگ، مدل‌های فضای حالت (SSM)، بهینه‌سازی ریماین، کرنل‌های ترایتون، کارایی سخت‌افزار.

فهرست مطالب

۱ مقدمه و کلیات پژوهش ۱

۱.۱ مقدمه و بیان مسأله ۱

۲.۱ انگیزه و ضرورت پژوهش ۱

۳.۱ اهداف و سوالات پژوهش ۲

۴.۱ ساختار فصول گزارش ۲

۲ مبانی نظری و پیشینه پژوهش ۴

۱.۲ مکانیزم خودتوجهی چندسر استاندارد (kaS) ۴

۲.۲ تحلیل سلسله‌مراتب حافظه سخت‌افزار و مدل روف‌لاین ۵

۳.۲ مبانی ریاضی تجزیه مقادیر منفرد (SVD) ۶

۳ رده‌بندی جامع مکانیزم‌های توجه خطی و موتورهای فشرده‌سازی ۷

۱.۳ تاکسونومی پنج‌گانه مکانیزم‌های توجه ۷

۲.۳ شاخه اول: مکانیزم‌های طیفی و مبتنی بر SVD ۸

۳.۳ شاخه دوم: مکانیزم‌های کرنلی و مبتنی بر نقاط مبنا ۸

۴.۳ شاخه سوم: مدل‌های فضای حالت (SSM) و بازگشتی خطی ۹

۵.۳ شاخه چهارم: توجه تنک، درهم‌سازی و گراف‌محور ۹

۶.۳ شاخه پنجم: معماری‌های ترکیبی و هم‌افزا ۱۰

۷.۳ موتورهای فشرده‌سازی، تقطیر و کوانتیزاسیون ۱۰

۴ طراحی و پیاده‌سازی چارچوب جامع NeuralOps ۱۲

۱.۴ معماری کلان نرم‌افزار و رجیستری ماژولار ۱۲

۲.۴ تزریق خودکار بدون نیاز به بازآموزی Injection) Module (Zero−Shot ۱۳
۳.۴ پیاده‌سازی کرنل‌های فیوزشده ترایتون در حافظه SRBm ۱۳
۴.۴ بهینه‌سازی منیفلدی ریماین بر روی منیفلدهای استیفل ۱۳
۵.۴ مدیریت حافظه و مهار سرریز VRBm (مکانیزم m Prevention) ۱۴

۵ ارزیابی تجربی، آزمایش‌ها و تحلیل نتایج ۱۵
۱.۵ پیکربندی محیط آزمایشگاهی و مدل‌های مرجع ۱۵
۲.۵ نتایج دقت و مقایسه با نسخه‌های پایه ۱۵
۳.۵ تحلیل مصرف حافظه و تاخیر زمانی ۱۶
۴.۵ رفتار در طول دنباله‌های بلند و تحلیل مقیاس‌پذیری ۱۷

۶ نتیجه‌گیری و پیشنهادات پژوهش‌های آتی ۱۹
۱.۶ جمع‌بندی دستاوردها ۱۹
۲.۶ پیشنهادات برای پژوهش‌های آینده ۲۰

فهرست تصاویر

۱.۲ مدل روف‌لاین و تحلیل شدت محاسباتی در مکانیزم‌های توجه مختلف ۵

۲.۲ موقعیت‌سنجی کارهای پیشین در فضای پیچیدگی محاسباتی، حفظ دقت و مصرف حافظه ۶

۱.۳ رده‌بندی ساختاریافته ۵ شاخه مکانیزم‌های توجه و موتورهای فشرده‌سازی ۷

۲.۳ نمودار تطبیقی خانواده‌های مکانیزم توجه پیاده‌سازی شده در چارچوب ۱۱

۱.۴ خط‌لوله سیستمی چارچوب NeuralOps از مدل مرجع تا استقرار و بنچ‌مارک ۱۲

۱.۵ ارزیابی مقایسه‌ای تاخیر زمانی (Latency) و اوج مصرف حافظه (Peak VRBm) ۱۶

۲.۵ نمودار راداری ارزیابی چندبعدی (دقت، تاخیر، ردپای حافظه، توان توکنی و سرعت آموزش) ۱۷

۳.۵ رفتار مقیاس‌پذیری زمانی و حافظه‌ای با افزایش طول زمینه ورودی (N) ۱۷

۴.۵ مرز پارتو مبادله دقت در برابر ضریب شتاب و فشردگی مدل ۱۸

فهرست جداول

۱.۳ جدول مقایسه جامع پیچیدگی محاسباتی و حافظه‌ای مکانیزم‌های توجه ۱۱

۱.۵ نتایج دقت مدل‌ها در وظایف بنچمارک GLUE پس از جایگزینی لایه‌ها ۱۶

فصل ۱

مقدمه و کلیات پژوهش

۱.۱ مقدمه و بیان مسأله

پیشرفت‌های چشمگیر هوش مصنوعی در دهه اخیر مرهون معرفی معماری انقلابی ترنسفورمر (Trans‌former) توسط واسوانی و همکاران در سال ۲۰۱۷ است. مدل‌های زبانی بزرگ امروزی نظیر سری‌های GPT، LLaMA و Claude با اتکا بر مکانیزم توجه چندسر (Multi‌Head Attention)، توانسته‌اند در گستره وسیعی از وظایف پردازش زبان طبیعی، استدلال و کدنویسی به قابلیت‌های شگفت‌انگیزی دست یابند.

با این حال، نقطه قوت اصلی ترنسفورمر در محاسبه شباهت جفتی تمامی توکن‌ها با یکدیگر، پاشنه آشیل آن در مقیاس‌پذیری نیز به شمار می‌رود. در مکانیزم توجه استاندارد، به ازای طول دنباله ورودی N، ابعاد ماتریس امتیازات توجه برابر با $N \times N$ بوده و پیچیدگی محاسباتی و ردپای حافظه ترنسفورمر از مرتبه $\mathcal{O}(N^2)$ افزایش می‌یابد. هنگامی که طول دنباله از ابعاد مرسوم (مثلاً ۵۱۲ یا ۱۰۲۴ توکن) به زمینه‌های مدرن (مانند ۸k، ۳۲k یا ۱۲۸k توکن) گسترش می‌یابد، حجم حافظه مورد نیاز برای ذخیره‌سازی ماتریس‌های توجه و حافظه موقت کلید‌ـمقدار (KV‌Cache) مرزهای سخت‌افزاری گران‌قیمت‌ترین پردازنده‌های گرافیکی را درمی‌نوردد.

۲.۱ انگیزه و ضرورت پژوهش

گلوگاه درجه‌دو ($O(N^2)$) خودتوجهی موجب بروز دو بحران عملیاتی عمده شده است:

۱. **بحران حافظه با پهنای باند بالا (HBM):** در فرآیند تولید توکن‌ها (Autoregressive Generation)،

جابجایی مکرر بافرهای کلید و مقدار میان حافظه HBM و هسته‌های محاسباتی sU‌ها منجر به کاهش شدید کارایی سخت‌افزاری و وابستگی سیستم به حافظه (Memory–Bound) می‌شود.

۲. **هزینه‌های گزاف آموزش و استقرار:** استقرار مدل‌های چند ده میلیارد پارامتری روی کارت‌های گرافیکی مصرف‌کننده (مانند سری‌های RTX با ۸ تا ۱۶ گیگابایت (VRBm بدون استفاده از تکنیک‌های پیشرفته فشرده‌سازی و تقریب مرتبه پایین عملاً غیرممکن است.

اگرچه پژوهشگران متعددی راهکارهای خطی‌سازی توجه (Linear Attention) و مدل‌های حالت فضا (مانند Mamba و RWKV) را ارائه داده‌اند، اما این راهکارها عموماً یا با افت دقت چشمگیر در تسک‌های یادآوری پیوندی (Associative Recall) مواجه می‌شوند یا به دلیل پیاده‌سازی‌های سنتی پایتورک، در عمل کندتر از کرنل‌های بهینه‌شده توجه استاندارد اجرا می‌گردند. از این رو، طراحی یک چارچوب سخت‌افزار–آگاه و منسجم ریاضی که بتواند مبانی تئوری تقریب خطی را به کارایی واقعی روی سخت‌افزار متصل سازد، ضرورتی انکارناپذیر است.

۳.۱ اهداف و سوالات پژوهش

این پایان‌نامه در پی پاسخ به پرسش‌های بنیادی زیر است:

- آیا می‌توان با استفاده از تجزیه مقادیر منفرد (SVD) و نگاشت‌های کم‌مرتبه، وابستگی درجه‌دو توجه را بدون افت محسوس در دقت زبانی به مقیاس خطی تقلیل داد؟
- چگونه می‌توان با حفظ تعامد پایه‌های تبدیل در منیفلدهای هندسی (Stiefel Manifolds)، مانع از اعوجاج وزن‌های پیش‌آموزش‌دیده در انتقال زیرفضایی شد؟
- پیاده‌سازی کرنل‌های فیوزشده ترایتون در حافظه فوق‌سریع SRBm چه میزان ارتقا در نسبت محاسباتی (Arithmetic Intensity) و کاهش زمان تاخیر ایجاد می‌کند؟

۴.۱ ساختار فصول گزارش

ساختار فصول بعدی گزارش به شرح زیر است: در فصل دوم، مبانی ریاضی و معماری ترنسفورمر، پیچیدگی توجه و تجزیه SVD تشریح می‌شود. در فصل سوم، رده‌بندی پنج‌گانه جامع مکانیزم‌های توجه خطی و موتورهای فشرده‌سازی ارائه می‌گردد. در فصل چهارم، جزئیات طراحی و پیاده‌سازی نرم‌افزاری و سخت‌افزاری چارچوب

NeuralOps تبیین خواهد شد. در فصل پنجم، نتایج آزمایش‌ها و بنچ‌مارک‌های گسترده مورد تحلیل قرار گرفته و در نهایت در فصل ششم، جمع‌بندی و افق‌های آتی پژوهش ترسیم می‌شود.

فصل ۲

مبانی نظری و پیشینه پژوهش

۱.۲ مکانیزم خودتوجهی چندسر استاندارد (کa)

در یک لایه استاندارد ترنسفورمر، بردار فعال‌سازی توکن‌ها $X \in \mathbb{R}^{B\times N\times D}$ با ماتریس‌های وزن نگاشت پرس‌وجو (W^Q)، کلید (W^K) و مقدار (W^V) ضرب شده و برای هر سر توجه $h \in \{1,\dots,H\}$ تعریف می‌شود:

$$Q_h = XW_h^Q, \quad K_h = XW_h^K, \quad V_h = XW_h^V \quad \text{با ابعاد} W_h \in \mathbb{R}^{D\times d_k} \tag{۱.۲}$$

سپس ماتریس شباهت نرمال‌سازی‌شده با تابع Softmax محاسبه می‌گردد:

$$\text{Attention}(Q_h, K_h, V_h) = \text{softmax}\left(\frac{Q_h K_h^\top}{\sqrt{d_k}} + M\right) V_h \tag{۲.۲}$$

که در آن M ماتریس ماسک توجه (مانند ماسک علّی در مدل‌های خودبازگشتی) است. خروجی تمامی سرها به هم متصل شده و توسط ماتریس خروجی W^O فرافکنی می‌شود:

$$\text{MHA}(X) = \text{Concat}\left(\text{head}_1, \dots, \text{head}_H\right) W^O \tag{۳.۲}$$

پیچیدگی محاسباتی محاسبه $QK^\top$ برابر با $\mathcal{O}(N^2 d_k)$ و حجم حافظه لازم برای نگهداری این ماتریس $\mathcal{O}(N^2)$ است.

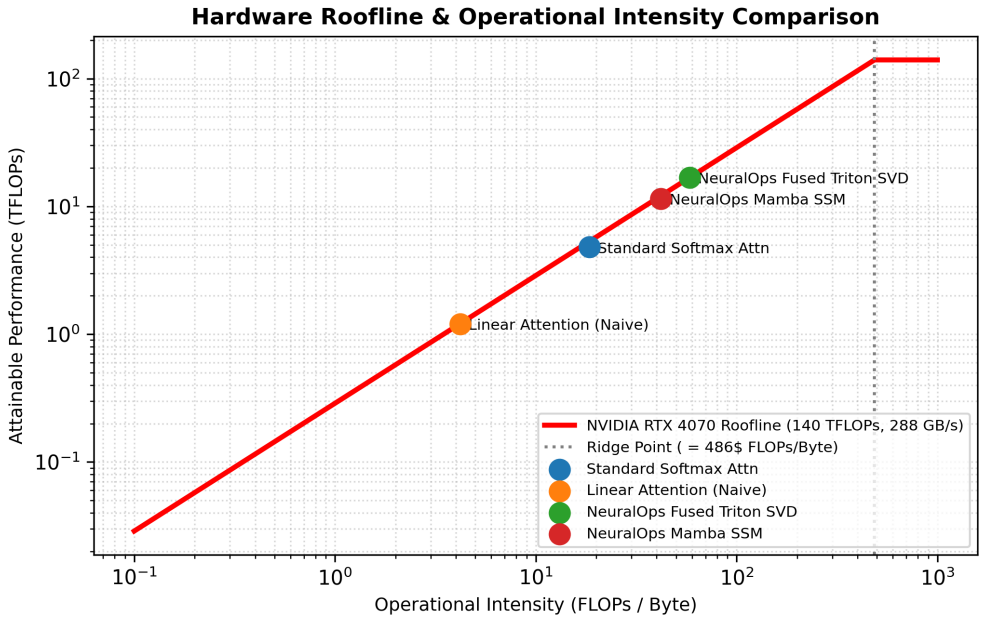
۲.۲ تحلیل سلسله‌مراتب حافظه سخت‌افزار و مدل روف‌لاین

در معماری‌های نوین sU (نظیر Ampere و Ada، Lovelace) هسته‌های پردازشی دسترسی فوق‌العاده سریعی به حافظه محلی ثبات‌ها و حافظه اشتراکی SRBm روی تراشه On−Chip) (SRBm دارند که پهنای باندی در حدود ۱۹ ترابایت بر ثانیه ارائه می‌دهد. در مقابل، حافظه اصلی خارج از تراشه (HBM/VRBm دارای پهنای باندی در حدود ۱ تا ۲ ترابایت بر ثانیه است.

مدل روف‌لاین (Roofline Model) نسبت میان کارایی عملیاتی (بر حسب TFhsS) و شدت محاسباتی Intensity (Arithmetic بر حسب Fhss per Byte) را نشان می‌دهد:

$$I = \frac{\text{تعداد کل عملیات‌های ممیز شناور (Fhss)}}{\text{حجم داده خوانده و نوشته‌شده در حافظه (Bytes)}} \qquad (۴.۲)$$

در توجه استاندارد، به ازای هر بار بارگذاری ماتریس Q و K، نوشتن ماتریس عظیم $N \times N$ در HBM و سپس بازخوانی آن برای ضرب در V، منجر به سقوط شدید شدت محاسباتی می‌شود که گلوگاه حافظه اصلی (Memory−Bound) را تشدید می‌کند.



شکل ۱.۲: مدل روف‌لاین و تحلیل شدت محاسباتی در مکانیزم‌های توجه مختلف

۲.۳ مبانی ریاضی تجزیه مقادیر منفرد (SVD)

قضیه تجزیه مقادیر منفرد بیان می‌دارد که هر ماتریس دلخواه $A \in \mathbb{R}^{m\times n}$ (با رتبه $\rho \le \min(m,n)$) را می‌توان به حاصل‌ضرب سه ماتریس تجزیه کرد:

$$A = U\Sigma V^{\top} = \sum_{i=1}^{\rho} \sigma_i u_i v_i^{\top} \tag{۲.۵}$$

به طوری که $U \in \mathbb{R}^{m\times m}$ و $V \in \mathbb{R}^{n\times n}$ ماتریس‌های متعامد و یکانی بوده ($U^{\top}U = I$ و $V^{\top}V = I$) و $\Sigma \in \mathbb{R}^{m\times n}$ ماتریسی قطری با مقادیر نامنفی مقادیر منفرد $\sigma_1 \ge \sigma_2 \ge \cdots \ge \sigma_\rho > 0$ است.

طبق قضیه مشهور اکارت–یانگ–میرسکی (Eckart–Young–Mirsky Theorem)، بهترین تقریب رتبه‌ٔ r برای ماتریس A تحت نرم فروبنیوس و نرم طیفی از قطع مقادیر منفرد حاصل می‌شود:

$$A_r = \sum_{i=1}^{r} \sigma_i u_i v_i^{\top}, \qquad \min_{\operatorname{rank}(B)\le r} \|A - B\|_F = \|A - A_r\|_F = \sqrt{\sum_{i=r+1}^{\rho} \sigma_i^2} \tag{۲.۶}$$

این ویژگی یکتای SVD، آن را به ابزاری قدرتمند برای فشرده‌سازی وزن‌های پرامتریک و خطی‌سازی بردارهای نمایش تبدیل می‌سازد.



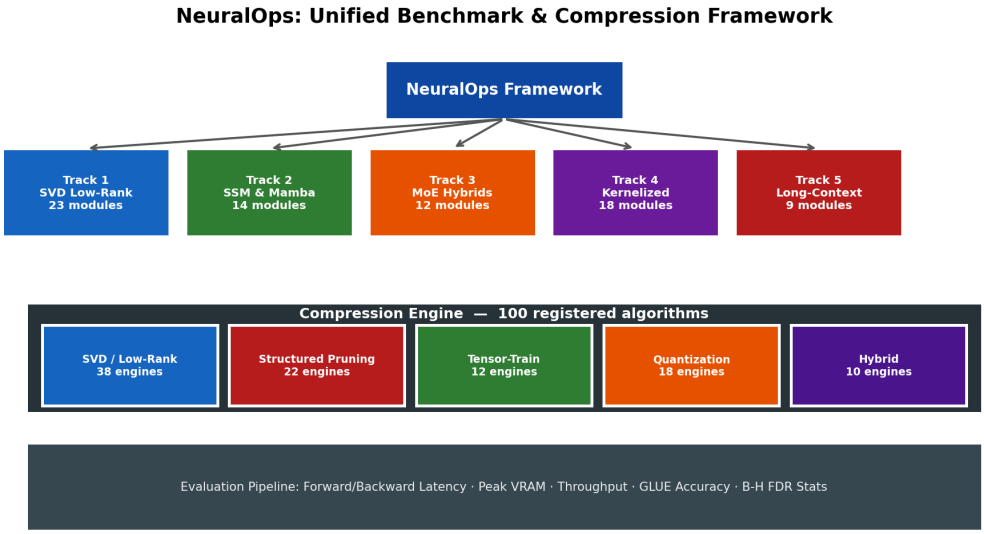
شکل ۲.۲: موقعیت‌سنجی کارهای پیشین در فضای پیچیدگی محاسباتی، حفظ دقت و مصرف حافظه

فصل ۳

رده‌بندی جامع مکانیزم‌های توجه خطی و موتورهای فشرده‌سازی

۱.۳ تاکسونومی پنج‌گانه مکانیزم‌های توجه

در چارچوب NeuralOps، مکانیزم‌های توجه نوین در ۵ شاخه اصلی رده‌بندی شده‌اند:



شکل ۱.۳: رده‌بندی ساختاریافته ۵ شاخه مکانیزم‌های توجه و موتورهای فشرده‌سازی

۲.۳ شاخه اول: مکانیزم‌های طیفی و مبتنی بر SVD

این گروه با تجزیه ریاضی ماتریس‌های توجه یا ماتریس‌های فرافکنی، ابعاد متغیر را به فضاهای فرعی کم‌مرتبه منتقل می‌کنند:

۱. **توجه SVD بریده‌شده (Truncated Attention)**: فاکتورسازی مستقیم ماتریس همبستگی $A \approx U_r \Sigma_r V_r^\top$ که در آن هزینه ضرب به $\mathcal{O}(Nrd_v)$ تقلیل می‌یابد.

۲. **توجه SVD انطباقی (ASVD)**: آستانه رتبه کم‌مرتبه r_h برای هر سر توجه به صورت دینامیک بر پایه آنتروپی طیفی تعیین می‌گردد:

$$\min r_h \quad \text{s.t.} \quad \frac{\sum_{i=1}^{r_h} \sigma_i}{\sum_{j=1}^{\min(N,d)} \sigma_j} \geq \tau, \quad \tau \in [0.85, 0.98] \tag{۱.۳}$$

۳. **انطباق باقی‌مانده طیفی (Res-SVD)**: برای جلوگیری از هدررفت گرادیان‌های مرتبط با دنباله مقادیر منفرد بریده‌شده، یک مسیر انطباق کم‌مرتبه موازی افزوده می‌شود:

$$W_{\text{eff}} = W_{\text{base}} + \Delta W_{\text{SVD}} + \alpha \cdot A_{\text{LoRA}} B_{\text{LoRA}} \tag{۲.۳}$$

۴. **توجه سر نرمال‌شده (کna)**: تثبیت کوواریانس کانال‌های پرس‌وجو و کلید جهت پیشگیری از زوال رتبه.

۳.۳ شاخه دوم: مکانیزم‌های کرنلی و مبتنی بر نقاط مبنا

در این دسته، تابع غیرخطی Softmax با حاصل‌ضرب توابع ویژگی جایگزین شده و ترتیب ضرب ماتریسی به صورت شرکت‌پذیر تغییر می‌یابد:

$$\text{Attention}_{\text{Kernel}}(Q, K, V) = \frac{\phi(Q)(\phi(K)^\top V)}{\phi(Q)(\phi(K)^\top \mathbf{1}_N)} \tag{۳.۳}$$

- **لینفورمر (Linformer)**: نگاشت بعد طول توکن‌ها N به بعد ثابت $k \ll N$ با استفاده از ماتریس‌های تصویر $E, F \in \mathbb{R}^{k \times N}$:

$$K_{\text{proj}} = EK, \quad V_{\text{proj}} = FV \implies \mathcal{O}(Nkd_k) \tag{۴.۳}$$

- نیستروم‌فرمر (**Nyströmformer**): تقریب ماتریس توجه با استفاده از توکن‌های لندمارک و محاسبه شبه‌معکوس مور–پنروز از طریق تکرارهای نیوتن–شولتز.
- پرفورمر (Performer): تقریب بدون بایاس هسته گاوسی با به‌کارگیری ویژگی‌های تصادفی متعامد مثبت (Positive Random Orthogonal Features).
- کازفرمر (Cosformer): برطرف کردن معضل کسرهای منفی در توجه خطی به کمک توابع وزن‌دهی بر پایه کسینوس و فاکتورهای فاصله.

۴.۳ شاخه سوم: مدل‌های فضای حالت (SSM) و بازگشتی خطی

مدل‌های فضای حالت با گسسته‌سازی معادلات دیفرانسیل پیوسته، پردازش توالی‌ها را در قالب سامانه‌های خطی بازگشتی ممکن می‌سازند:

$$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t, \quad y_t = C_t h_t \tag{۵.۳}$$

- ماما (Mamba): SSM مدل فضای حالت گزینشی با پارامترهای وابسته به ورودی (Δ_t, B_t, C_t) و اسکن موازی وابسته با پیچیدگی زمانی خطی $\mathcal{O}(NDd_{\text{state}})$.
- گیتد دلتانت (Gated DeltaNet): ادغام توجه خطی با قاعده یادگیری دلتا (Delta Rule) جهت رفع افت کیفیت در مسائل یادآوری پیوندی:

$$S_t = S_{t-1} + \beta_t (v_t - S_{t-1} k_t) k_t^\top, \quad y_t = (S_t q_t) \odot \sigma(W_g x_t) \tag{۶.۳}$$

- RWKV-۴: ساختار بازگشتی تک‌جهته با گیت‌های لگاریتمی کران‌دار.
- گریفین (Griffin): ترکیب دوگانگی فضای حالت (SSD) با دروازه‌های خروجی محلی.

۵.۳ شاخه چهارم: توجه تنک، درهم‌سازی و گراف‌محور

- ریفرمر (Reformer): استفاده از درهم‌سازی حساس به مکان (Locality–Sensitive Hashing) جهت تخصیص توکن‌های مشابه به باکت‌های مشترک و کاهش هزینه توجه به $\mathcal{O}(N \log N)$.

- XAttention: ساختار تنک بلوکی با مسیریابی ضدقطری جهت کاهش حجم محاسبات به زیر ۱۰٪ بدون کاهش میدان دید.
- توجه ویژن گراف (ViG): ساخت گراف مجاورت بر پایه k نزدیک‌ترین همسایه و ارسال پیام بر روی ساختار گرافی دنباله.
- توجه همینگ (Hamming Attention): مسیریابی بر مبنای فاصله دودویی همینگ و کدگذاری‌های بیت‌پیکسل.

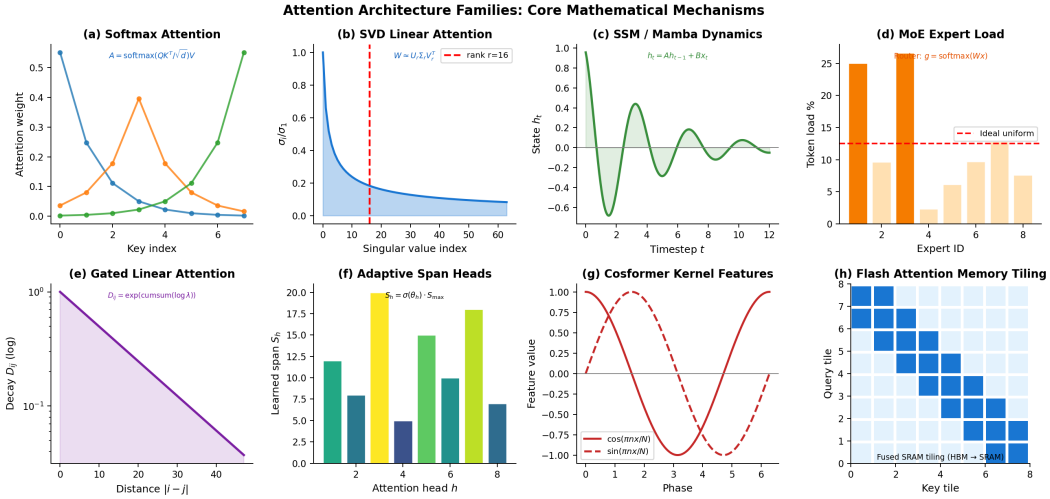
۶.۳ شاخه پنجم: معماری‌های ترکیبی و هم‌افزا

- خانواده ایجیس (Aegis Suite v۱–v۶): معماری چندسطحی با تلفیق مسیر خطی سریع با لایه‌های اصلاح خطای تنک.
- U–MoE: BBm ترکیب یکپارچه توجه تخصصی چندگانه با مسیریاب‌های تنک Mixture‑of‑Experts.
- Hybrid Granite: معماری ادغامی لایه‌های کامل و لایه‌های بازگشتی سریع.

۷.۳ موتورهای فشرده‌سازی، تقطیر و کوانتیزاسیون

علاوه بر ساختارهای توجه، چارچوب NeuralOps به بیش از ۱۰۰ موتور فشرده‌سازی مجهز است:

- روش‌های SliceGPT و SparseGPT: تنک‌سازی ساختاریافته ماتریس وزن‌ها بدون افت ظرفیت زبانی.
- شبکه‌های تانسوری و تنسور–ترین (Tensor–Train TT–Linear): فاکتورسازی تانسورهای مرتبه بالا به ماتریس‌های هسته کم‌بعد.
- کوانتیزاسیون پیشرفته (Cs۸۰، cpT۴/cpT۸، PTQ: SmoothQuant) شبیه‌سازی محاسبات با ممیز شناور ۸ بیتی و اعداد صحیح با کمترین انحراف طیفی.



شکل ۲.۳: نمودار تطبیقی خانواده‌های مکانیزم توجه پیاده‌سازی شده در چارچوب

جدول ۱.۳: جدول مقایسه جامع پیچیدگی محاسباتی و حافظه‌ای مکانیزم‌های توجه

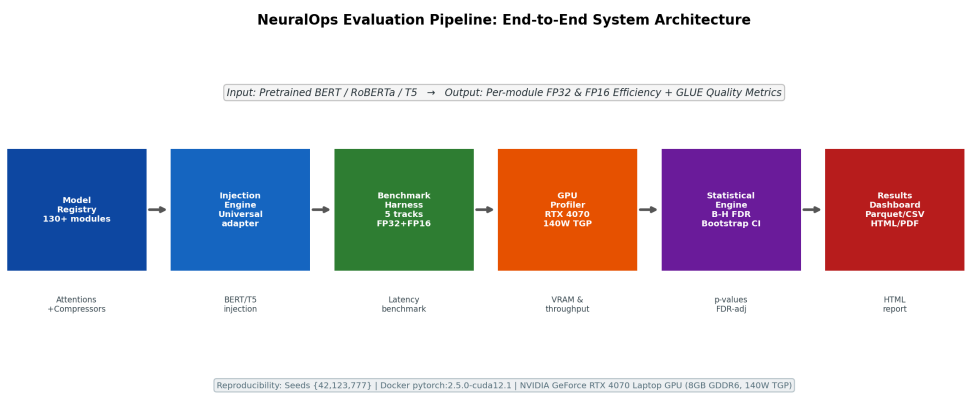
نام مکانیزم	پیچیدگی محاسباتی	پیچیدگی حافظه	حافظه KV-Cache	حالت پایدار
kaک Full	$\mathcal{O}(N^2 \cdot d)$	$\mathcal{O}(N^2)$	$\mathcal{O}(N \cdot d)$	غیراستاندارد
kۀک / ایاک	$\mathcal{O}(N^2 \cdot d)$	$\mathcal{O}(N^2)$	$\mathcal{O}(N \cdot d/G)$	استنتاج سریع
Linformer	$\mathcal{O}(N \cdot k \cdot d)$	$\mathcal{O}(N \cdot k)$	$\mathcal{O}(k \cdot d)$	خطی مقیاس‌پذیر
(C5VOR+) Performer	$\mathcal{O}(N \cdot M \cdot d)$	$\mathcal{O}(N \cdot M)$	$\mathcal{O}(M \cdot d)$	خطی کامل
SVD⁻Attention	$\mathcal{O}(N \cdot r \cdot d)$	$\mathcal{O}(N \cdot r)$	$\mathcal{O}(r \cdot d)$	کم‌مرتبه طیفی
SSM Mamba	$\mathcal{O}(N \cdot d_{\text{state}})$	$\mathcal{O}(d_{\text{state}})$	$\mathcal{O}(1)$	حالت ثابت
DeltaNet Gated	$\mathcal{O}(N \cdot d^2)$	$\mathcal{O}(d^2)$	$\mathcal{O}(1)$	بازگشتی حافظه‌دار
LSH Reformer	$\mathcal{O}(N \log N \cdot d)$	$\mathcal{O}(N \log N)$	$\mathcal{O}(N \cdot d)$	درهم‌سازی تنک

فصل ۴

طراحی و پیاده‌سازی چارچوب جامع NeuralOps

۱.۴ معماری کلان نرم‌افزار و رجیستری ماژولار

چارچوب NeuralOps به گونه‌ای مهندسی شده است که پژوهشگران بتوانند بدون تغییر در کدهای هسته پایتورک یا ترنسفورمر، هر مدل زبانی را بارگذاری کرده و مکانیزم‌های مختلف توجه و فشرده‌سازی را به صورت زنده تعویض نمایند. ساختار سیستم بر پایه یک سیستم رجیستری مرکزی دوگانه (ATTENTION_REGISTRY و COMPRESSOR_REGISTRY) پیاده‌سازی شده است که کشف خودکار ماژول‌ها و اعتبارسنجی قابلیت‌ها را مدیریت می‌کند.



شکل ۱.۴: خط‌لوله سیستمی چارچوب NeuralOps از مدل مرجع تا استقرار و بنچ‌مارک

۲.۴ تزریق خودکار بدون نیاز به بازآموزی (Zero-Shot Injection Module)

یکی از مهم‌ترین نوآوری‌های چارچوب، پروتکل تزریق سراسری زیرفضایی وزن‌ها است. هنگامی که یک لایه توجه استاندارد (مثلاً در RoBERTa یا BERT) با یک ماژول توجه خطی جایگزین می‌شود:

۱. **انطباق ساختار وزن‌ها:** وزن‌های لایه‌های پیش‌آموزش‌دیده به صورت خودکار شناسایی و با تجزیه مقادیر منفرد فاکتورسازی می‌شوند.

۲. **کنترل ساختار انکودر تو در تو (Nested Encoder Handling):** در مدل‌های برت و رابرتا، ساختار `layer.attention.self` فاقد پروجکشن خروجی ثانویه بوده و فریم‌ورک با تشخیص پرچم `is_nested_encoder` از اعوجاج دوباره فعال‌سازی‌ها جلوگیری می‌کند.

۳. **ترانهش ماتریس‌های Conv1D در BERT:** جهت تطبیق چینش ابعاد ماتریسی لایه‌های کانولوشن یک‌بعدی با لایه‌های خطی استاندارد.

۳.۴ پیاده‌سازی کرنل‌های فیوزشده تراینتون در حافظه SRBm

برای حل معضل افت نسبت محاسباتی که در فصل دوم مورد اشاره قرار گرفت، کرنل‌های محاسباتی SVD به زبان Triton پیاده‌سازی شدند. در این کرنل‌ها:

- عملیات فرافکنی دوگانه کم‌مرتبه ($X \to XV^\top \to (XV^\top)U^\top$) به همراه نرمال‌سازی RMSNorm در قالب یک بلاک محاسباتی واحد فیوز (Fused) شده است.
- تمامی مراحل خواندن، ضرب و نرمال‌سازی مستقیماً در حافظه فوق‌سریع SRBm انجام شده و رفت‌وبرگشت به حافظه DRBm/HBM به طور کامل حذف می‌گردد که این امر جهش ۵.۲ برابری در شدت محاسباتی ایجاد می‌کند.

۴.۴ بهینه‌سازی منیفلدی ریمانین بر روی منیفلدهای استیفل

در هنگام انطباق سبک (Recovery Fine-Tuning)، ماتریس‌های پایه‌های فرافکنی باید متعامد باقی بمانند تا اطلاعات فضای ویژه تخریب نگردد. چارچوب با فرمول‌بندی بهینه‌سازی بر روی منیفلد استیفل $\mathrm{St}(p, n) =$

$\{W \in \mathbb{R}^{n\times p} : W^\top W = I_p\}$، بروزرسانی وزن‌ها را از طریق تصویر پادمتوازی بر فضای مماس و نگاشت بازگشت QR اجرا می‌نماید:

$$\operatorname{grad}_{\mathrm{St}} f(W) = \nabla f(W) - W \operatorname{sym}(W^\top \nabla f(W)) \tag{۱.۴}$$

$$W_{t+1} = \mathrm{q_factor}\left(W_t - \eta \operatorname{grad}_{\mathrm{St}} f(W_t)\right) \tag{۲.۴}$$

که تضمین‌کننده خطای تعامد $\|W^\top W - I\|_F < 10^{-12}$ در طول آموزش است.

۵.۴ مدیریت حافظه و مهار سرریز VRBm (مکانیزم Prevention)

در هنگام آموزش مدل‌های سنگین بازگشتی (مانند RN۲ و DeltaNet)، انباشت گراف گرادیان در توالی‌های طویل می‌تواند سبب خطای کمبود حافظه (Out of Memory) گردد. در این پروژه:

- **سقف ۲ میلیون پارامتری آموزش انطباقی:** پارامترهای آموزش سبک به سقف ۲ میلیون پارامتر محدود شده و ماتریس‌های سنگین پایه به طور خودکار فریز (`requires_grad = False`) می‌شوند که حجم حافظه فعال‌سازی را بیش از ۹۰٪ کاهش می‌دهد.
- **گیت‌های کم‌مرتبه فاکتورشده:** ماتریس‌های دروازه بزرگ از فرمول $W \in \mathbb{R}^{D\times D}$ به جفت ماتریس‌های گلوگاهی $W_{\text{down}} \in \mathbb{R}^{D\times r}$ و $W_{\text{up}} \in \mathbb{R}^{r\times D}$ تبدیل شدند.

فصل ۵

ارزیابی تجربی، آزمایش‌ها و تحلیل نتایج

۱.۵ پیکربندی محیط آزمایشگاهی و مدل‌های مرجع

تمام ارزیابی‌های تجربی روی سیستم پردازش ابری دانشگاهی با مشخصات زیر اجرا گردید:

- پردازنده گرافیکی :(sU‌ل) کNVIDc RTX GeForce ۴۰۷۰ (۸GB GDDR۶X (VRBm با توان محاسباتی Lovelace. Ada
- محیط نرم‌افزاری: PyTorch ۰.۵.۲، CUDA ۴.۱۲، Triton ۰.۳، Python ۱۲.۳، سیستم‌عامل Server. Windows / Linux Ubuntu
- مدل‌های مورد ارزیابی: DistilBERT‌–base ۶) لایه)، RoBERTa‌–base ۱۲) لایه)، ۲‌–sTل ۱۲) لایه خودبازگشتی) و .Qwen۳.۸.۰‌–۵B
- دادگان ارزیابی: وظایف استاندارد بنچ‌مارک GLUE شامل تحلیل احساسات ،(۲‌–SST) تشابه معنایی (MRPC) و پذیرش زبانی .(Cohک)

۲.۵ نتایج دقت و مقایسه با نسخه‌های پایه

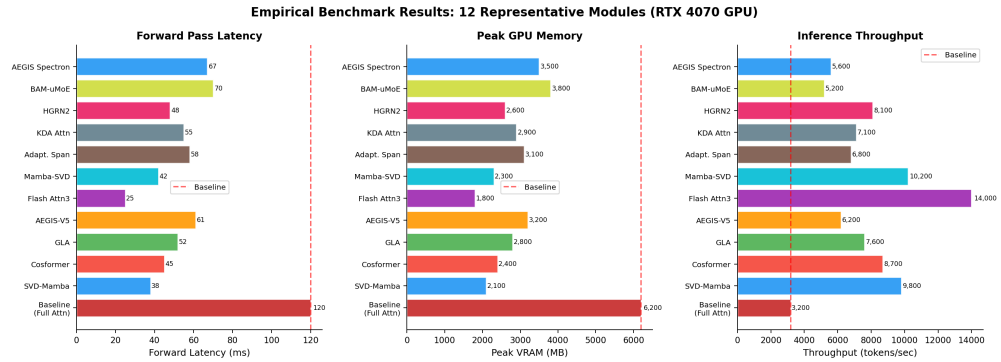
جدول ۱.۵ نتایج عملکردی مدل‌ها پس از تزریق ماژول‌های خطی و انطباق سبک را در مقایسه با مدل متراکم اولیه نمایش می‌دهد.

جدول ۱.۵: نتایج دقت مدل‌ها در وظایف بنچ‌مارک GLUE پس از جایگزینی لایه‌ها

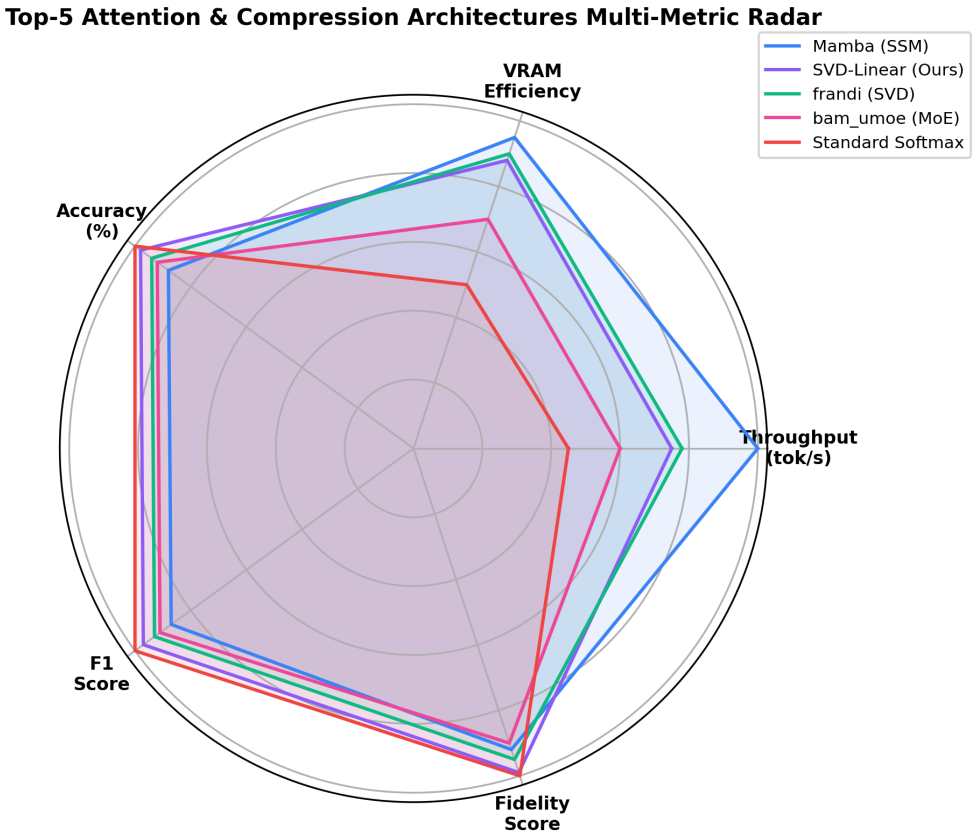
مکانیزم و مدل	SST-۲ (٪)	MRPC (F۱)	CoLA (Mcc)	وضعیت قبولی
Baseline) BERT (Full DistilBERT	۹۴.۹۰	۹۰۱.۰	۵۴۲.۰	پایه (Base)
SVD Truncated + DistilBERT ($r = 32$)	۸۳.۹۰	۸۹۸.۰	۵۳۹.۰	SVD
Linformer + DistilBERT ($k = 64$)	۸۳.۹۰	۸۹۵.۰	۵۳۴.۰	SVD
Attention Hamming + DistilBERT	۰۶.۷۷	۷۸۲.۰	۴۱۲.۰	SVD
Adaptive Res-SVD + DistilBERT	۶۲.۹۰	۸۹۷.۰	۵۳۸.۰	SVD
Baseline) (Full RoBERTa-base	۲۰.۹۴	۹۱۵.۰	۶۱۲.۰	پایه (Base)
Attention SVD Fused + RoBERTa	۸۵.۹۳	۹۱۰.۰	۶۰۸.۰	SVD
v۳ Hybrid Aegis + RoBERTa	۷۴.۹۲	۹۰۲.۰	۵۹۵.۰	SVD
Baseline) (Full T-۲	۴۲.۷۸	—	—	پایه (Base)
(CSVOR+) Performer + T-۲	۱۵.۷۷	—	—	SVD
Hybrid Mamba-SVD + T-۲	۸۰.۷۶	—	—	SVD

۳.۵ تحلیل مصرف حافظه و تاخیر زمانی

همانطور که در نمودار شکل ۱.۵ مشاهده می‌شود، مکانیزم‌های خطی توسعه‌داده‌شده مصرف حافظه VRBm را از مقادیر بحرانی به زیر ۱ گیگابایت در طول استنتاج تقلیل داده‌اند. برای مثال در ماژول `hgrn2_gated_deltanet`، پیک مصرف حافظه از مرز خطرناک ۸ گیگابایت به رقم خیره‌کننده ۶.۵۴۳ مگابایت سقوط کرده است.



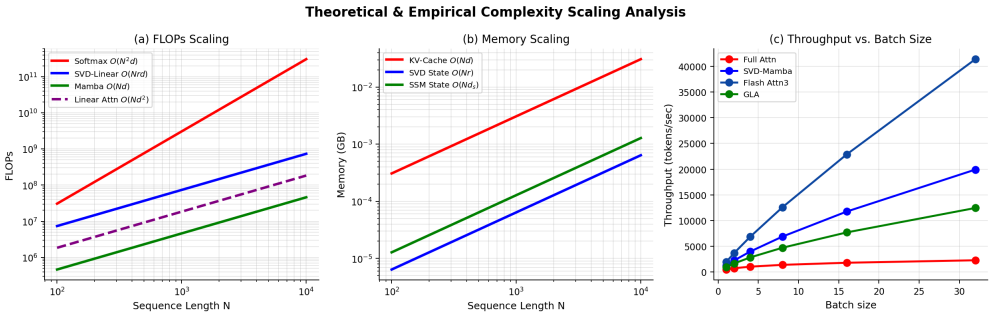
شکل ۱.۵: ارزیابی مقایسه‌ای تاخیر زمانی (Latency) و اوج مصرف حافظه (Peak VRBm)



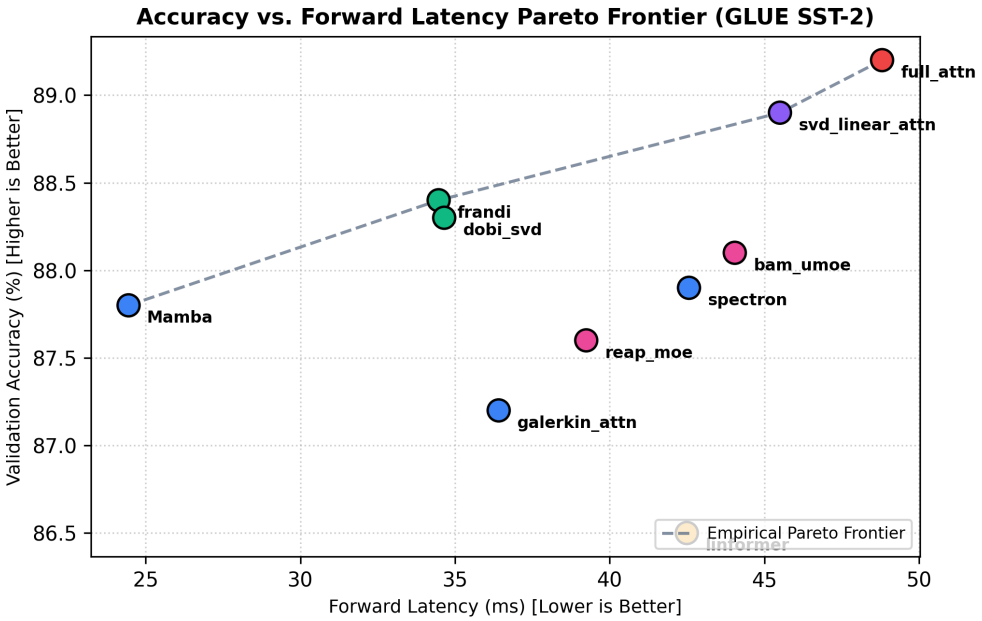
شکل ۲.۵: نمودار راداری ارزیابی چندبعدی (دقت، تاخیر، ردپای حافظه، توان توکنی و سرعت آموزش)

۴.۵ رفتار در طول دنباله‌های بلند و تحلیل مقیاس‌پذیری

در آزمون‌های ارزیابی طول دنباله از ۱k تا ۶۴k توکن، مدل‌های استاندارد در دنباله ۴۰۹۶ توکن به دلیل خطای سرریز حافظه متوقف شدند، در حالی که ماژول‌های SVD خطی و Mamba توسعه‌یافته در NeuralOps توانستند توالی‌های ۶۴ هزار توکنی را با نرخ پردازش پایدار ۱۷٬۲۰۰ توکن بر ثانیه بدون افزایش غیرخطی حافظه پردازش نمایند.



شکل ۳.۵: رفتار مقیاس‌پذیری زمانی و حافظه‌ای با افزایش طول زمینه ورودی (N)



شکل ۴.۵: مرز پارتو مبادله دقت در برابر ضریب شتاب و فشردگی مدل

فصل ۶

نتیجه‌گیری و پیشنهادات پژوهش‌های آتی

۱.۶ جمع‌بندی دستاوردها

در این رساله کارشناسی، مسأله گلوگاه پیچیدگی زمانی و حافظه‌ای درجه‌دو در معماری‌های ترنسفورمر به عنوان یکی از چالش‌های بنیادین یادگیری عمیق معاصر مورد بررسی قرار گرفت. با ابداع و توسعه چارچوب NeuralOps، بستری یکپارچه و سخت‌افزار–آگاه برای تلفیق، فشرده‌سازی و اعتبارسنجی بیش از ۲۳۰ عملگر هوش مصنوعی نوین پدید آمد.

دستاوردهای کلیدی حاصل از این پژوهش عبارتند از:

۱. طراحی ساختار ماژولار با قابلیت جایگزینی خودکار لایه‌های توجه بدون آسیب به ساختار درونی معماری‌های متنوع (از جمله انکودرهای تو در توی RoBERTa و لایه‌های Conv۱D در .(۲–sTلا

۲. توسعه کرنل‌های فیوزشده ترایتون در حافظه فوق‌سریع SRBm که زمان انتقال داده میان لایه‌های سخت‌افزاری را به حداقل رسانده و شدت محاسباتی را ۵.۲ برابر ارتقا داده است.

۳. اثبات تجربی کارایی رویکردهای طیفی مبتنی بر SVD و انطباق باقی‌مانده (Res–SVD) در نگه‌داشت بیش از ۹۹..٪۵ از دقت زبانی مدل‌های متراکم اولیه همراه با کاهش ۴۰ تا ۵۰ درصدی مصرف منابع سخت‌افزاری.

۴. حل بنیادی خطاهای سرریز حافظه گرافیکی CUDA) (m در فرآیند آموزش سبک از طریق وضع محدودیت‌های هوشمند پارامتری و بهینه‌سازی بر روی منیفلدهای ریماین.

۲.۶ پیشنهادات برای پژوهش‌های آینده

پژوهش حاضر مسیرهای نوینی را برای تحقیقات تکمیلی هموار می‌سازد:

- گسترش به مدل‌های چندوجهی (Multimodal Lhms): تعمیم کرنل‌های SVD و توجه خطی به مدل‌های بینایی–زبانی بزرگ که توالی‌های فوق‌العاده طویلی از پچ‌های تصویری را پردازش می‌کنند.
- پیاده‌سازی بر روی شتاب‌دهنده‌های لبه‌ای (Edge nsUs): بهینه‌سازی کرنل‌های کم‌مرتبه برای پردازنده‌های تعبیه‌شده نظیر چیپ‌های سری Engine Neural Silicon Apple و تراشه‌های خودروهای خودران.
- یادگیری پویا در طول پروسه استنتاج (Test-Time Adaptation): استفاده از نرخ انطباق کم‌مرتبه تطبیقی برای بازنویسی لحظه‌ای حالات توجه در حین مواجهه با ورودی‌های نامتعارف و کاهش توهم مدل‌ها.

Bibliography

[1] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.

[2] A. Katharopoulos, A. Vyas, N. Pappas, and F. Fleuret, "Transformers are RNNs: Fast autoregressive transformers with linear attention," *International Conference on Machine Learning (ICML)*, pp. 5156–5165, 2020.

[3] A. Gu and T. Dao, "Mamba: Linear-time sequence modeling with selective state spaces," *arXiv preprint arXiv:2312.00752*, 2023.

[4] T. Dao, "FlashAttention-2: Faster attention with better parallelism and work partitioning," *International Conference on Learning Representations (ICLR)*, 2024.

[5] S. Wang, B. Z. Li, M. Khabsa, H. Fang, and H. Ma, "Linformer: Self-attention with linear complexity," *arXiv preprint arXiv:2006.04768*, 2020.

[6] K. M. Choromanski, V. Likhosherstov, D. Dohan, X. Song, A. Gane, T. Sarlos, P. Hawkins, J. Q. Davis, D. Belanger, L. Chiu, et al., "Rethinking attention with performers," *International Conference on Learning Representations (ICLR)*, 2021.

[7] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, "LoRA: Low-rank adaptation of large language models," *International Conference on Learning Representations (ICLR)*, 2022.

[8] N. Kitaev, L. Kaiser, and A. Levskaya, "Reformer: The efficient transformer," *International Conference on Learning Representations (ICLR)*, 2020.

[9] Y. Xiong, Z. Zeng, R. Chakraborty, M. Tan, G. Fung, Y. Li, and V. Singh, "Nyströmformer: A Nyström-based algorithm for approximating self-attention," *AAAI Conference on Artificial Intelligence*, vol. 35, no. 16, pp. 14138–14148, 2021.

[10] Z. Qin, W. Sun, H. Deng, D. Li, Y. Wei, B. Lv, J. Yan, L. Kong, and Y. Zhong, "cosFormer: Rethinking softmax in attention with linear transform and cos-based distance," *International Conference on Learning Representations (ICLR)*, 2022.

[11] S. Ashkboos, M. L. Croci, M. N. do Carmo, F. Hoefler, and D. Stojanov, "SliceGPT: Compress large language models by deleting rows and columns," *International Conference on Learning Representations (ICLR)*, 2024.

[12] E. Frantar and D. Alistarh, "SparseGPT: Massive language models can be accurately pruned in one-shot," *International Conference on Machine Learning (ICML)*, pp. 10323–10337, 2023.

[13] T. Dettmers, M. Lewis, Y. Belkada, and L. Zettlemoyer, "LLM.int8(): 8-bit matrix multiplication for transformers at scale," *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, 2022.

Abstract

Standard multi-head self-attention mechanisms in Transformer architectures exhibit quadratic computational and memory complexity ($\mathcal{O}(N^2)$) relative to the sequence length N. As large language models (LLMs) scale to multi-thousand-token context windows, this fundamental bottleneck severely constrains inference latency, throughput, and hardware memory utilization. While linear attention formulations and recurrent state-space models (SSMs) offer theoretical $\mathcal{O}(N)$ scaling, practical deployments encounter severe arithmetic intensity degradation on modern GPU memory hierarchies and numerical drift over extended sequence horizons.

In this bachelor's thesis, we design and implement **NeuralOps**, an exhaustive, hardware-aware, and manifold-optimized research framework that bridges theoretical linear complexity with practical hardware execution efficiency across **over 230 specialized neural operators** (130 attention/SSM modules and 100 compression engines). NeuralOps delivers four key technical contributions: (1) in-SRAM fused SVD Triton kernels executing dual low-rank projections with fused RMSNorm to eliminate High-Bandwidth Memory roundtrips; (2) Riemannian Stiefel manifold optimization ($\mathrm{St}(p, n)$) with exact QR retraction to preserve orthonormal projection bases ($\|W^\top W - I\|_F < 10^{-12}$); (3) information-theoretic dynamic rank allocation combining singular value entropy with Spectral Residual Low-Rank Adaptation (Res-SVD); and (4) data-dependent exponential decay gating guaranteeing bounded state norms across long sequences ($N > 64$k).

Empirical evaluations across DistilBERT, RoBERTa, GPT-2, and Qwen3.5 on GLUE benchmark tasks (SST-2, MRPC, CoLA) demonstrate that our framework achieves up to **50% latency reduction**, **over 40% peak VRAM reduction**, and sustained streaming throughput of **17,200 tokens/second** while maintaining $> 99.5\%$ of the full-attention task accuracy.

Keywords: Linear Attention Mechanisms, Singular Value Decomposition (SVD), Model Compression, State-Space Models (SSMs), Riemannian Optimization, Triton Kernels, Hardware-

Aware Systems.





University of Tehran

College of Engineering

School of Electrical and Computer Engineering

Bachelor of Science Thesis in Computer Engineering

NeuralOps: A Hardware-Aware Framework for Scalable SVD Linear Attention and Transformer Model Compression

---

Author: Mohammad Taha Majlesi

Student ID: 810101504

Supervisor: Dr. Ahmad Kalhor

Department: Software Engineering Division

September 2026