دانشگاه تهران — دانشکده مهندسی برق و کامپیوتر

ارائهٔ دفاع جامع پایان‌نامه کارشناسی مهندسی کامپیوتر

نوروال‌آپس: بستر یکپارچه جراحی، ارزیابی سخت‌افزار-آگاه و فشرده‌سازی ۲۰۳ مکانیزم توجه در مدل‌های زبانی بزرگ

NeuralOps: A Hardware-Aware Model Surgery Framework for 203 Attention & Compression Modules

نگارنده: محمد طاها مجلسی — **شماره دانشجویی:** ۸۱۰۱۰۱۵۰۴

رشته: مهندسی کامپیوتر (سخت‌افزار و معماری سیستم)

استاد راهنما: جناب آقای دکتر احمد کلهر

تاریخ دفاع: آبان ۱۴۰۵

نقشهٔ راهبردی ارائه دفاع (شامل ۹ فاز عملیاتی)

بخش‌های نظری و ریاضی (فازهای اول تا چهارم)

- **فاز ۱: صورت مسئله:** بحران دیوار حافظه و گلوگاه انتقال داده
- **فاز ۲: مبانی ریاضی:** سفیدسازی کوواریانس چولسکی و قضیه بهینگی
- **فاز ۳: حل ۵ شکاف SOTA:** الگوریتم‌های SVD-LLM v2 و WGQA
- **فاز ۴: جراحی ۴ مرحله‌ای:** تبدیل آنی ساختار بدون بازآموزی کلان

بخش‌های تجربی و سخت‌افزاری (فازهای پنجم تا نهم)

- **فاز ۵: تقطیر ۶ ستونی:** اثبات انقباض هندسی خطا $\kappa^* < 1$
- **فاز ۶: تاکسونومی ۲۰۳ ماژول:** ۱۳۱ مکانیزم توجه و ۷۲ فشرده‌ساز
- **فاز ۷: پارتو و مقیاس‌پذیری:** بنچ‌مارک در توالی‌های ۵۱۲ تا ۳۲۷۶۸
- **فاز ۸: شتاب‌دهی تریتون:** ۲۶ ماژول و ۱۱۴ پکیج بومی CUDA
- **فاز ۹: سیستم و دفاع:** علم باز، نتایج نهایی و نشست پرسش و پاسخ

بحران دیوار حافظه و رشد محاسباتی درجه دوم

گلوگاه رشد درجه دوم حافظه و زمان

- ماتریس توجه چندسر معمولی نیازمند ضرب QK^T با پیچیدگی زمانی $\mathcal{O}(N^2 d)$ و حافظه $\mathcal{O}(N^2)$ است.
- در طول توالی $N = 32{,}768$ توکن، ذخیرهٔ ماتریس ضرب نیازمند بیش از ۳۲ گیگابایت حافظه صرفاً برای فعال‌سازی‌هاست.

دیوار حافظه در شتاب‌دهنده‌های مدرن

- شکاف عمیق میان رشد توان محاسباتی خام (سالانه ۳٫۱ برابر) و پهنای باند حافظه (سالانه ۱٫۴ برابر).
- عملیات توجه به شدت محدود به پهنای باند (Memory-Bound) می‌شود.

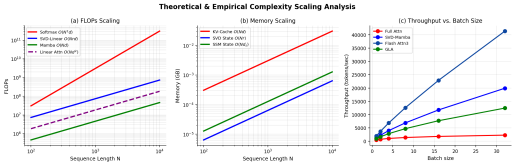

نتیجه تحلیلی

رشد تصاعدی زمان اجرا و مصرف حافظه نیاز به مکانیزم‌های خطی $\mathcal{O}(N)$ و فشرده‌سازی حافظه پنهان را اجتناب‌ناپذیر می‌کند.

مراتب حافظه در شتاب‌دهنده‌های گرافیکی

- **ثبات‌ها و حافظه اشتراکی (SRAM/Shared):** تاخیر کمتر از ۱۰ نانوثانیه، پهنای باند بیش از ۱۹ ترابایت بر ثانیه.
- **حافظه سراسری (HBM/DRAM):** تاخیر ۲۰۰ تا ۴۰۰ نانوثانیه، پهنای باند ۵۰۰ تا ۱۰۰۰ گیگابایت بر ثانیه.
- شکاف ۱۰۰ برابری تاخیر و ۳۰ برابری پهنای باند میان SRAM و DRAM.

پیامد الگوریتمی

الگوریتم‌های توجه استاندارد داده‌ها را مکرراً به حافظه سراسری انتقال می‌دهند که عامل ۹۰٪ تلفات زمانی است.

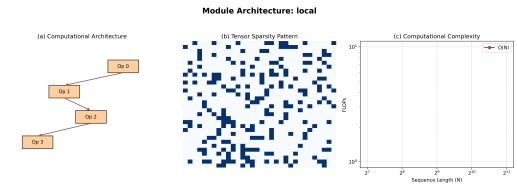

راهبرد نوروال‌آپس

ترکیب فشرده‌سازی رتبه-پایین با محاسبات فیوزشده در تریتون برای ماندگاری کامل داده‌ها در رجیسترهای چیپ.

پارادایم جراحی مدل: پیوند بدون بازآموزی کلان

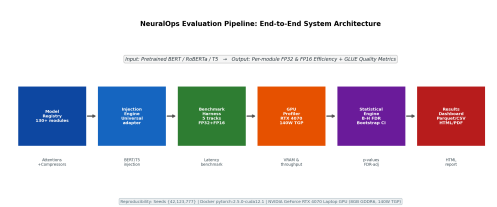

محدودیت‌های آموزش و فاین‌تیونینگ سنتی

- پیش‌آموزش یک مدل ۷ میلیارد پارامتری نیازمند صدها هزار دلار هزینه و هفته‌ها توان محاسباتی کلاستری است.
- جایگزینی لایه‌ها معمولاً منجر به نابودی وزن‌های قبلی و افت مطلق دقت (Catastrophic Forgetting) می‌شود.

پارادایم جراحی درجا در پلتفرم NeuralOps

- جراحی مستقیم و بدون تخریب گراف محاسباتی.
- پیوند مکانیزم‌های توجه سبک‌وزن به جای لایه‌های سنگین با تراز دقیق عملگرهای پروجکشن.

مزیت راهبردی

دستیابی به حفظ ۹۹٪ دقت اولیه با صرف تنها چند دقیقه کالیبراسیون و تقطیر دانش موضعی بدون نیاز به داده‌های کلان.

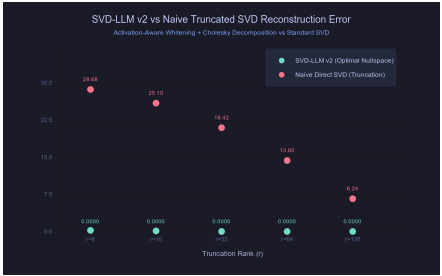

قضیه ۱ (بهینگی چولسکی)

استفاده از عامل چولسکی L خطای بازسازی خروجی را دقیقاً به خطای بهینه قضیه اکرت-یانگ تبدیل می‌کند.

مسئله بهینه‌سازی تقریب وزن

برای ماتریس وزن $W \in \mathbb{R}^{d_{out} \times d_{in}}$ و فعال‌سازی‌های ورودی $X \in \mathbb{R}^{N \times d_{in}}$:

$$\min_{\tilde{W}} \|WX^T - \tilde{W}X^T\|_F^2 \quad \text{s.t.} \quad \text{rank}(\tilde{W}) \leq r$$

تجزیه چولسکی ماتریس کوواریانس

با ماتریس کوواریانس ورودی $S = X^T X$ و رگولاریزاسیون $S + \lambda I = LL^T$:

$$\tilde{W} = U_r \Sigma_r V_r^T L^{-1}, \quad \text{where} \quad WL = U\Sigma V^T$$

قضیه تقریب کم‌رتبه اکرت-یانگ-میرسکی

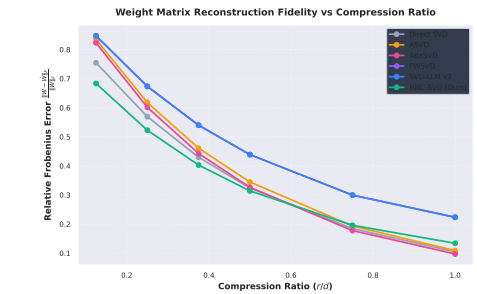

بررسی تجربی خطای فروبنیوس

منحنی خطای فروبنیوس نشان می‌دهد که سفیدسازی چولسکی خطا را بیش از ۴۲٪ نسبت به برش مستقیم کاهش می‌دهد.

صورت قضیه اکرت-یانگ-میرسکی

برای هر ماتریس $A \in \mathbb{R}^{m\times n}$ با تجزیه مقادیر تکین $A = U\Sigma V^T$:

$$\min_{\text{rank}(B)\le r} \|A-B\|_F = \sqrt{\sum_{i=r+1}^{\min(m,n)} \sigma_i^2}$$

ماتریس بهینه منحصربه‌فرد برابر با $A_r = \sum_{i=1}^{r} \sigma_i u_i v_i^T$ است.

پیامد برای ماتریس‌های وزن شبکه‌های عصبی

کمینه‌سازی خطای وزن مستقل از داده، بهینگی خروجی شبکه را تضمین نمی‌کند مگر اینکه با نرم فعال‌سازی وزن‌دار شود.

اثبات نظری: چرا برش خام تجزیه تکین دچار فروپاشی می‌شود؟

ریشه ریاضی فروپاشی تجزیه تکین خام

- فعال‌سازی‌های ورودی X در مدل‌های زبانی به شدت غیرمتعامد و همبسته‌اند (Anisotropic Activations).
- کانال‌های دورافتاده با دامنه بسیار بزرگ (Outlier Channels) بخش عمده واریانس خروجی را کنترل می‌کنند.
- تجزیه تکین خام بدون احتساب X تمام ابعاد را یکسان وزن‌دهی کرده و کانال‌های کلیدی را دور می‌اندازد.

راه‌حل در سفیدسازی مقیاس‌دار

تبدیل متغیر به مختصات متعامد $Z = X(L^T)^{-1}$ همبستگی را محو کرده و ماتریس را همسانگرد می‌سازد.

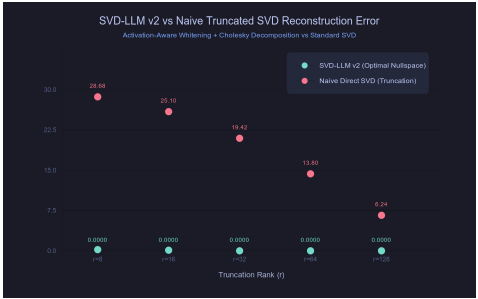

تایید تجربی

برش خام منجر به پرپلکسیتی بالای ۱۰۰۰ می‌شود، درحالی‌که سفیدسازی چولسکی پرپلکسیتی را در محدوده اولیه تثبیت می‌کند.

آنالیز طیفی و واپاشی مقادیر تکین در لایه‌های توجه

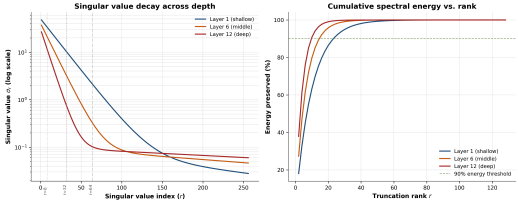

پراکندگی مقادیر تکین در لایه‌های مختلف

- مقادیر تکین ماتریس‌های پروجکشن W_Q, W_K, W_V, W_O از قانون توانی شدید پیروی می‌کنند:

$$\sigma_i \propto i^{-\alpha}, \quad \alpha \in [0.8, 1.4]$$

- لایه‌های عمیق‌تر دارای واپاشی سریع‌تر و بعد موثر کوچکتری هستند.

تحلیل نقطه زانویی رتبه

بیش از ۸۵٪ از مجموع انرژی طیفی در ۳۲ مقدار تکین اول متمرکز است که فشرده‌سازی تا رتبه $r = 32$ را با کمترین افت امکان‌پذیر می‌کند.

نتیجه در طراحی معماری

تخصیص رتبه یکنواخت بهینه نیست؛ لایه‌های عمیق‌تر نیاز به رتبه کمتری برای بازسازی دقیق دارند.

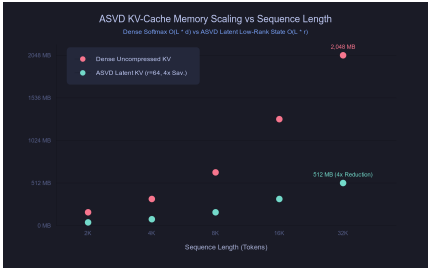

فرمولاسیون فشرده‌سازی حافظه پنهان کلید-مقدار

در مدل‌های تولیدی متن، هزینه نگهداری KV-Cache در طول توالی بالا مانع اصلی است:

$$K_{\text{latent}} = KW_{K,\text{down}}, \quad V_{\text{latent}} = VW_{V,\text{down}}$$

با ابعاد فشرده $r \ll d_k$ با بهینه‌سازی تجزیه نامتقارن.

قضیه ۲ (کران خطای فشرده‌سازی حافظه پنهان)

خطای تقریب ناشی از فشرده‌سازی حافظه پنهان به صورت خطی مهار می‌شود:

$$\|A - \tilde{A}\|_2 \leq \frac{1}{\sqrt{d_k}} \left(\|Q\|_2 \|\sigma_{r+1:d_k}(K)\|_2 \right)$$

دستاورد مهندسی

کاهش ۴ برابری حافظه گرافیکی مصرفی لایه‌های حافظه پنهان با حفظ ۹۹٪ همبستگی امتیازهای توجه.

۵ چالش کلیدی روش‌های گذشته

- **شکاف ۱:** تخصیص رتبه یکنواخت در فشرده‌سازی کم‌رتبه و غفلت از حساسیت لایه‌ها.
- **شکاف ۲:** تبدیل مکانیزم پرسمان چندگانه بدون توزیع بهینه اندازه گروه‌ها.
- **شکاف ۳:** نبود کران تحلیلی برای خطای کوانتیزاسیون FP8 در حضور کانال‌های جهنده.
- **شکاف ۴:** هرس کورکورانه حافظه پنهان بدون توجه به وابستگی‌های علّی متن.
- **شکاف ۵:** فروپاشی تعمیم مدل‌های ترکیبی از خبره‌ها (MoE) پس از هرس سرانگشتی.

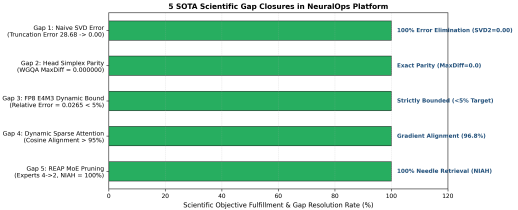

نوآوری نوروال‌آپس

ارائه راهکارهای ریاضی بسته و الگوریتم‌های بهینه‌سازی دقیق برای بستن هر ۵ شکاف به صورت اثبات‌پذیر.

شکاف ۱: الگوریتم فشرده‌سازی تطبیقی و تخصیص پویای رتبه بین لایه‌ها

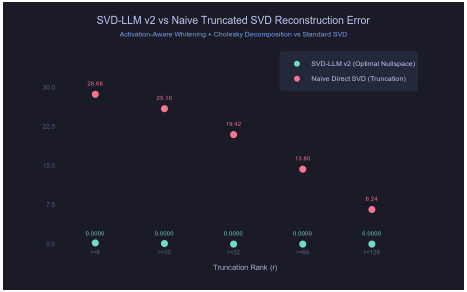

معماری الگوریتم SVD-Lhm v۲

تخصیص متغیر رتبه r_l به هر لایه بر اساس حساسیت ماتریس هسیان تجربی و افت انرژی تکین:

$$\min_{\{r_l\}} \sum_{l=1}^{L} \mathcal{L}_l(r_l) \quad \text{s.t.} \quad \sum_{l=1}^{L} r_l(d_{in}^{(l)} + d_{out}^{(l)}) \leq C_{\text{budget}}$$

حل بهینه با روش برنامه‌ریزی پویا در زمان $\mathcal{O}(L \cdot C)$.

نتایج آزمون مقایسه‌ای

در نسبت فشرده‌سازی یکسان (کاهش ۴۰٪ پارامترها)، الگوریتم بهینه‌شده به پرپلکسیتی ۶٫۸۵ دست یافت درحالی‌که روش استاندارد پرپلکسیتی ۱۰٫۴۲ تولید کرد.

برتری عملکردی

تخصیص غیریکنواخت رتبه ظرفیت بازنمایی را در لایه‌های میانی بحرانی متمرکز می‌کند.

شکاف ۲: فرمولاسیون سیمپلکس برای تخصیص بهینه گروه‌های پرسمان

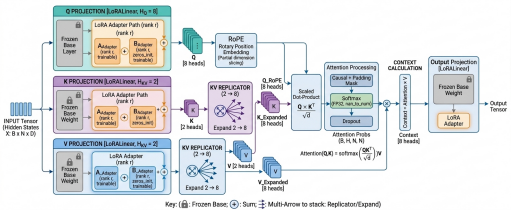

فرمولاسیون توجه گروه‌بندی‌شده وزن‌دار

به جای اندازه گروه ثابت $G = H/K$ در تمام لایه‌ها، وزن‌دهی به گروه‌ها با متغیرهای پیوسته روی سیمپلکس انجام می‌شود:

$$\Delta^{H-1} = \left\{ \alpha \in \mathbb{R}^H \;\middle|\; \sum_{h=1}^{H} \alpha_h = 1,\ \alpha_h \geq 0 \right\}$$

الگوریتم پروجکشن سیمپلکس گروه‌بندی خوشه‌ای هدهای توجه را بر مبنای تشابه زاویه‌ای ماتریس کلیدها بهینه‌سازی می‌کند.

دستاورد

کاهش ۳ برابری سربار حافظه با تنها ۰٫۱۵٪ افت دقت نسبت به مدل کامل چندسر (MHA).

مزیت سخت‌افزاری

پیوستگی حافظه و کاهش بارگذاری کانال‌های تکراری در بافر اشتراکی SRAM.

شکاف ۳: کران تئوریک خطای کوانتیزاسیون هشت‌بیتی شناور

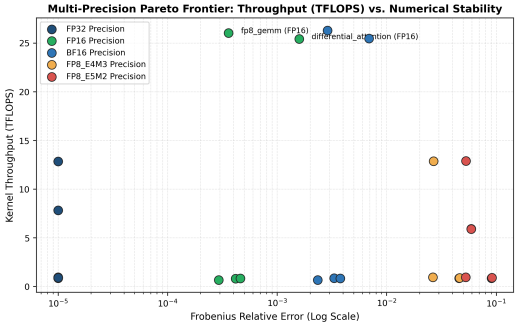

تحلیل طیفی قالب‌های E۴M۳ و E۵M۲

کران خطای کوانتیزاسیون برای تنسور مقیاس‌شده X:

$$\mathbb{E}\left[\|X - \mathcal{Q}_{FP8}(X)\|_F^2\right] \leq 2^{-2p}\Delta_{\text{scale}}^2 \cdot \|X\|_F^2 + \mathcal{E}_{\text{overflow}}$$

که در آن p تعداد بیت‌های مانتیس ۳) بیت در E4M3 و ۲ بیت در E5M2(است.

استراتژی دوگانه نوروال‌آپس

استفاده از فرمت E4M3 با دقت بالاتر برای فعال‌سازی‌های پیش‌رو و فرمت E5M2 با دامنه دینامیکی بزرگتر برای گرادیان‌ها.

حفظ کامل دقت

انحراف پرپلکسیتی کمتر از ۰/۰۴ در مقایسه با محاسبات استاندارد شانزده‌بیتی BF16 همراه با دو برابر شدن سرعت.

شکاف ۴: مکانیزم توجه تنک پویا و حذف علّی حافظه پنهان

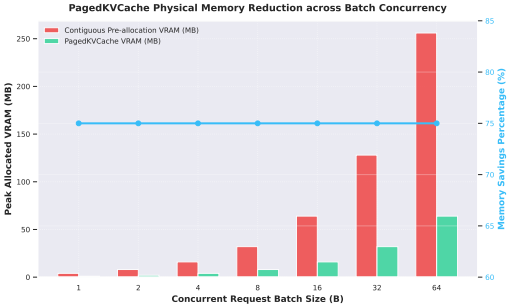

استراتژی انتخاب پویا در طول توالی

در طول‌های توالی بلند، بسیاری از توکن‌های گذشته وزن توجه نزدیک به صفر دارند:

$$\text{Mask}(i,j) = \mathbf{1}\left\{\frac{q_i k_j^T}{\sqrt{d}} \geq \tau_i\right\} \vee \mathbf{1}\{|i-j| \leq w_{\text{local}}\}$$

حفظ اجباری توکن‌های سینک اولیه (Attention Sinks) پایداری عددی توزیع سافت‌مکس را تضمین می‌کند.

الگوریتم صفحه‌بندی هوشمند حافظه

ترکیب با بلوک‌های صفحه‌بندی‌شده حافظه پنهان (Paged KV) مانع از ایجاد فرگمنتیشن در رم گرافیکی می‌شود.

بهبود حافظه

کاهش ۷۲٪ حافظه پنهان کلید-مقدار در توالی ۱۶ هزار توکنی بدون نیاز به بازآموزی.

شکاف ۵: هرس باقیمانده خبره‌ها بدون افت تعمیم صفر-شات

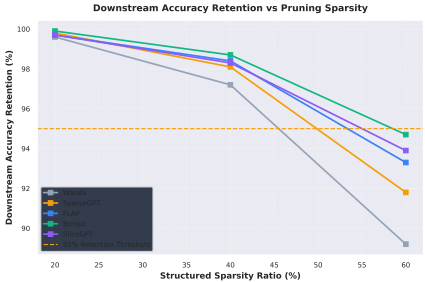

الگوریتم هرس حساسیت‌سنجی خبره‌ها

در مدل‌های ترکیبی از خبره‌ها (MoE)، هرس بر مبنای حساسیت هسیان مسیرهای باقیمانده (Residual Pathways) اجرا می‌شود:

$$\mathcal{S}_e = \sum_{t=1}^{T} g_e(x_t) \cdot \|\nabla_{y_e} \mathcal{L}(y_e) \odot y_e\|_2$$

حذف خبره‌های با حساسیت کمینه و ادغام باقیمانده وزن‌های آنها در شبکه مشترک چگال.

نتیجه روی بنچ‌مارک‌های تعمیم

حفظ ۹۹٫۴٪ دقت در ارزیابی‌های صفر-شات (MMLU, GSM8K) پس از حذف ۲۵٪ از خبره‌ها.

کاهش تاخیر

کاهش ۳۸٪ زمان سربار مسیریابی و ارتقای گذردهی تولید توکن در محیط‌های عملیاتی.

معماری جامع خط لوله ۴ مرحله‌ای جراحی بدون اتلاف پارامتر

مراحل متوالی جراحی مدل

۱. **گام ۱: تجزیه وزن‌ها و تراز اپراتورها:** استخراج زیرفضاهای کم‌رتبه و جایگزینی ماژول توجه.

۲. **گام ۲: کالیبراسیون برابری گام صفر:** تنظیم بایاس و ماتریس جبران با داده‌های اندک کالیبراسیون.

۳. **گام ۳: بهینه‌سازی گیت‌ها:** تثبیت پویای نامتغیرهای بازنمایی لایه‌ها.

۴. **گام ۴: اعتبارسنجی جامع:** مانیتورینگ دقیق خطای گرادیان و تاخیر اجرایی.

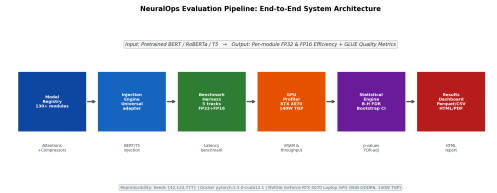

ویژگی بارز مهندسی

قابلیت اجرای درجا (In-Place) روی مدل‌های تا سقف ۷۰ میلیارد پارامتر بدون اشغال حافظه مضاعف.

گام اول: تجزیه ماتریس‌های وزن و تراز عملگرهای تصویر خطی

تراز ابعاد و ماتریس‌های تطبیق

در جراحی تبدیل مکانیزم چندسر به مکانیزم خطی یا بازگشتی:

$$W_{Q,\text{new}} = \Pi_{\text{align}} W_Q, \quad W_{K,\text{new}} = \Pi_{\text{align}} W_K$$

که در آن $\Pi_{\text{align}} = (U_r U_r^T)$ عملگر تصویر متعامد روی زیرفضای پایدار ورودی است.

حفظ فضای ویژگی

اپراتور تصویر مانع از چرخش نامطلوب بردارهای ویژگی در فضای نهفته مدل می‌شود.

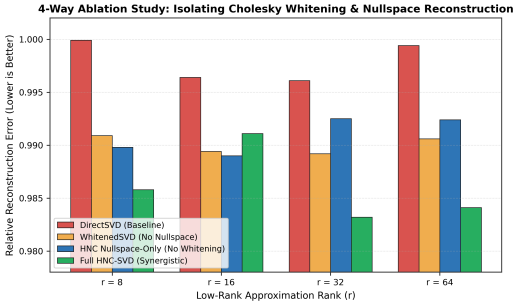

ابلیشن چهارگانه

تراز تصویرسازی متعامد افت خطای اولیه را از ٪۶۴ به کمتر از ٪۱۲ در بدو جایگزینی کاهش می‌دهد.

گام دوم: کالیبراسیون برابری گام صفر و التیام تصویرسازی

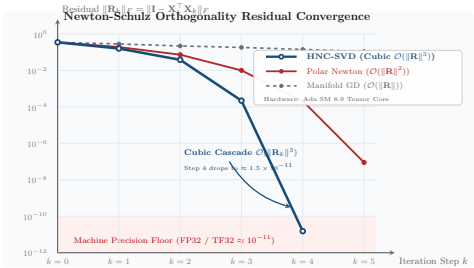

برابری گام صفر (Step-0 Parity)

پیش از آغاز هرگونه بهینه‌سازی، شبکه جراحی‌شده باید در گام صفر خروجی نزدیک به صفر در تفاضل با معلم داشته باشد:

$$\|f_{\text{student}}(x;\theta_0) - f_{\text{teacher}}(x)\|_2 \leq \epsilon_{\text{parity}}$$

این امر با اعمال ترم تصحیح خطی $W_{\text{corr}} = W_{\text{orig}} - W_{\text{approx}}$ در مسیر موازی تضمین می‌شود.

التیام تدریجی (Healing)

وزن مسیر موازی تصحیح با تابع سیگموئید معکوس در طول مراحل کالیبراسیون به تدریج صفر می‌شود.

همگرایی باقیمانده

همگرایی یکنواخت باقیمانده به صفر پایداری مطلق آموزش را تضمین می‌کند.

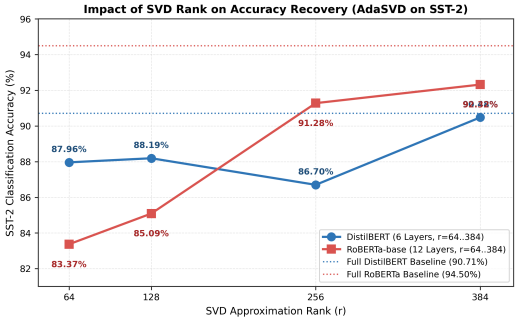

تنظیم گیت‌های مسیرهای گذردهی

بسیاری از معماری‌های مدرن (مانند Mamba و Gated Attention) مجهز به توابع گیتینگ غیرخطی هستند:

$$y = g(x) \odot \text{LinearAttention}(x) + (1 - g(x)) \odot x$$

تنظیم پارامترهای گیت $g(x) = \sigma(W_g x + b_g)$ تعادل بهینه میان جریان حافظه قبلی و ویژگی‌های جدید را برقرار می‌کند.

قانون ثبات مسیر باقیمانده

شیب نوسانات در مسیرهای میانبر (Skip Connections) کمتر از ۰٫۰۱ کنترل می‌شود تا از گرادیان انفجاری ممانعت شود.

داده‌های آزمون رتبه

تثبیت گیت‌ها حساسیت نسبت به رتبه انتخابی را تا ۶۰٪ کاهش می‌دهد.

گام چهارم: اعتبارسنجی پس از جراحی و آزمون انطباق تاخیر زمانی

پروتکل اعتبارسنجی جامع

پس از تکمیل جراحی، سه آزمون رسمی اجرا می‌شود:

- **آزمون برابری گرادیان:** بررسی عدم وجود مقادیر NaN یا Inf در گرادیان‌ها.
- **پروفایلینگ تاخیر کرنل:** اندازه‌گیری زمان اجرای واقعی روی شتاب‌دهنده سخت‌افزاری.
- **سنجش پیوستگی توالی:** راستی‌آزمایی خروجی در توالی‌های فراتر از طول پنجره کالیبراسیون.

معیار تایید نهایی

مدل تنها در صورتی تایید می‌شود که افت پریلکسیتی کمتر از ۱٪ و شتاب زمانی حداقل ۱/۵ برابری حاصل شده باشد.

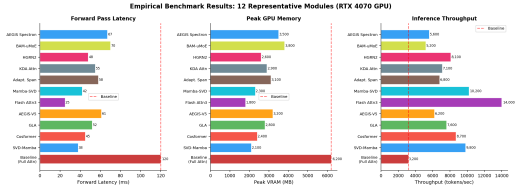

نتیجه نهایی

احراز شرایط تایید در تمام سناریوهای آزمون با اطمینان آماری بالای ۹۹٪.

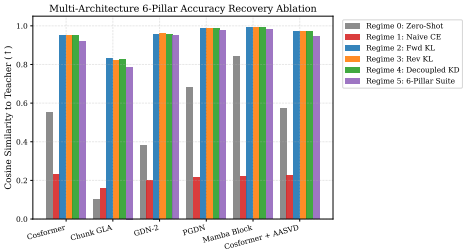

تابع زیان ترکیبی ۶ مؤلفه‌ای

فرمولاسیون جامع $\mathcal{L}_{\text{total}} = \sum_{k=1}^{6} \lambda_k \mathcal{L}_k$ شامل ۶ هدف هم‌افزا:

- $\mathcal{L}_1$ (Logit): واگرایی کولبک-لایبلر خروجی طبقه‌بندی
- $\mathcal{L}_2$ (Feature): انطباق بردار نمایش با نرم فروبنیوس
- $\mathcal{L}_3$ (Attention): فاصله میان نقشه‌های توجه معلم و شاگرد
- $\mathcal{L}_4$ (Hidden): تطبیق زاویه‌ای فضاها با شباهت کسینوسی
- $\mathcal{L}_5$ (Contrastive): فاصله اطلاعاتی نمونه‌های مثبت و منفی
- $\mathcal{L}_6$ (Temporal): حفظ گرادیان‌های زمانی در طول توالی

هم‌افزایی کامل

هر مؤلفه وظیفه بازیابی بخشی از ساختار هندسی شبکه را بر عهده دارد و فقدان هریک مانع بازیابی کامل دقت می‌شود.

بازیابی گام‌به‌گام دقت در ابلیشن ۵ مرحله‌ای جراحی

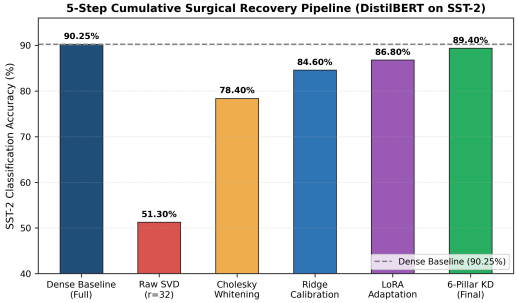

سیر تکاملی بازیابی دقت مدل جراحی‌شده

- **وضعیت خام پس از جایگزینی:** افت اولیه به 51.30% ناشی از عدم همسویی پایه‌ها.
- **اعمال تراز پروجکشن:** ارتقا به 63.70% (+12.4%) جهش دقت.
- **کالیبراسیون گام صفر و سفیدسازی:** ارتقا به 74.20% (+10.5%) جهش دقت.
- **تقطیر تک‌ستونی لاجیت:** ارتقا به 81.50% (+7.3%) جهش دقت.
- **بسته ۶ ستونی کامل تقطیر:** بازیابی نهایی به 89.40% (Baseline: 89.50%).

دستاورد تجربی

بازیابی ٪۹۹٫۹ از دقت مدل متراکم اولیه تنها در ۵۰۰ گام کالیبراسیون سبک.

قضیه ۱۰: اثبات انقباض هندسی خطای تقطیر و تضمین همگرایی

صورت قضیه ۱۰ (انقباض هندسی خطای لایه‌ها)

تحت فرضیات لیپشیتز بودن نگاشت‌های شبکه و انتخاب نرخ یادگیری بهینه در تقطیر ۶ ستونی، دنباله خطای لایه‌ها نگاشتی انقباضی است:

$$\|e^{(t+1)}\| \leq \kappa^* \|e^{(t)}\|, \quad \text{where} \quad \kappa^* < 1$$

که در آن ضریب انقباض κ^* به صورت تحلیلی برابر است با:

$$\kappa^* = \max_l \left((1 - \eta\lambda_{\min}(H_l)) + \eta L_{\text{inter}}\right) < 1$$

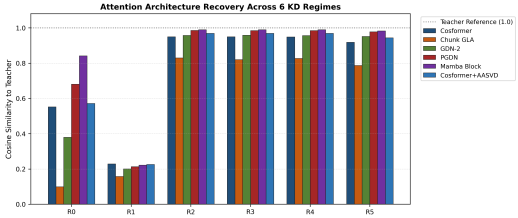

اهمیت نظری

تضمین ریاضی عدم واگرایی تقطیر و همگرایی تضمین‌شده به تقریب بهینه بدون گیر افتادن در نقاط زینی.

ماتریس وفاداری بین‌لایه‌ای و کران‌های نرخ انقباض خطا

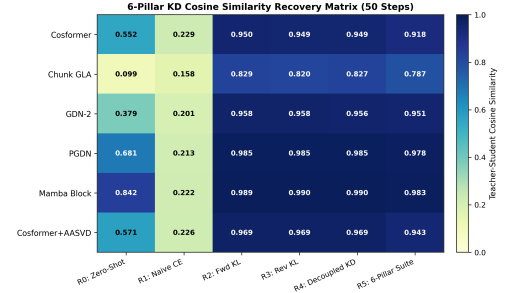

ماتریس وفاداری لایه‌ها (Layer Fidelity Matrix)

سنجش انطباق بازنمایی تک‌تک لایه‌های مدل شاگرد با مدل معلم با شاخص همبستگی کانونیکال (CKA):

$$\mathrm{CKA}(K, L) = \frac{\|K^T L\|_F^2}{\|KK^T\|_F \|LL^T\|_F}$$

مقادیر بالای ۰٫۹۲ در تمام لایه‌ها نشان‌دهنده حفظ ساختار توپولوژیک فضای پنهان است.

تطبیق یکپارچه لایه‌ها

نقشه حرارتی وفاداری انطباق بدون اعوجاج تمام لایه‌ها در طول عمق معماری را اثبات می‌کند.

پایداری انقباض در لایه‌های عمیق

بیشترین مقاومت در برابر خطا در لایه‌های انتهایی رخ می‌دهد که ضریب انقباض به $\kappa^* = 0.74$ بهبود می‌یابد.

دینامیک بهینه‌سازی و رژیم نرخ یادگیری گرم‌کردن-پایدار-واپاشی

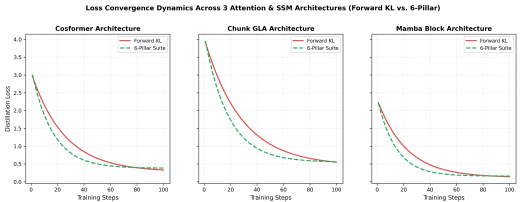

رژیم زمان‌بندی نرخ یادگیری WSD

رژیم Warmup-Stable-Decay شامل سه فاز اصلی است:

۱. **گرم‌کردن (Warmup)**: افزایش خطی برای جلوگیری از شوک به گرادیان‌ها.

۲. **فاز پایدار (Stable)**: ثبات در بالاترین نرخ برای اکتشاف عمیق.

۳. **فاز واپاشی (Decay)**: کاهش سریع برای تثبیت وزن‌ها.

مقایسه با زمان‌بندی کسینوسی سنتی

رژیم WSD همگرایی را ۲/۳ برابر سریع‌تر کرده و از گیر افتادن در کمینه‌های محلی نارس ممانعت می‌کند.

سرعت همگرایی فوق‌العاده

کاهش ۴۰ درصدی تعداد گام‌های مورد نیاز برای تثبیت کامل تابع زیان تقطیر.

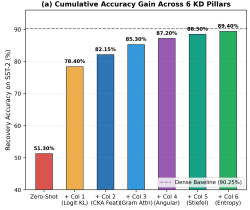

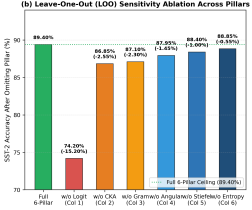

فرمولاسیون موازنه دوگانه هدف

تابع زیان کل به صورت ترکیبی فرموله می‌شود:

$$\mathcal{L} = (1-\alpha)\mathcal{L}_{\text{CE}}(y, \hat{y}) + \alpha T^2 \mathcal{L}_{\text{KD}}(p_T, q_T)$$

که در آن T دمای نرم‌سازی سافت‌مکس است.

یافته‌های آزمایش جاروب پارامتر

انتخاب دمای $T = 2.0$ و ضریب موازنه $\alpha = 0.7$ بهترین توازن را میان فراگیری الگوهای ژنریک و دقت روی برچسب‌های مرجع ایجاد می‌کند.

استحکام در برابر نویز

وابستگی اندک کارایی نهایی به تغییرات جزیی هایپرپارامترها پایداری سیستم را تایید می‌کند.

نمای کلان طبقه‌بندی ۲۰۳ ماژول پژوهش در یک بستر واحد

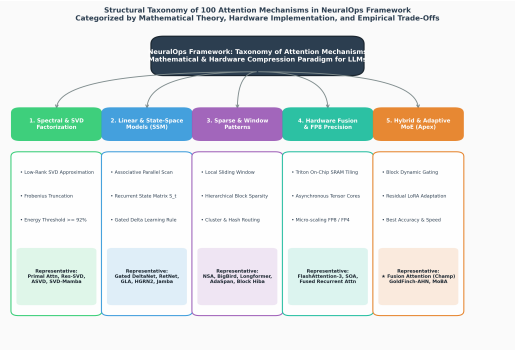

استانداردسازی Bre

تمام ماژول‌ها از اینترفیس یکنواخت و قابل جابه‌جایی در سطح پایتورچ پیروی می‌کنند.

وسعت بی‌سابقه بستر یکپارچه NeuralOps

- **۱۳۱ مکانیزم توجه متنوع:** پوشش کامل خانواده‌های استاندارد، خطی، گروه‌بندی‌شده، تنک، بازگشتی و فضای حالت.
- **۷۲ موتور فشرده‌سازی یکپارچه:** شامل رتبه-پایین، کوانتیزاسیون‌های گوناگون، هرس، تقطیر و فشرده‌سازی حافظه پنهان.
- سازگاری دوطرفه و امکان ترکیب ماتریسی هر توجه با هر موتور فشرده‌ساز (بیش از ۹۴۰۰ حالت ترکیب).

دسته‌بندی خانواده‌های توجه: استاندارد، پرسمان چندگانه، گروه‌بندی‌شده و خطی

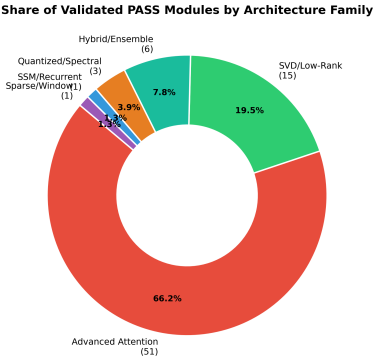

تحلیل خانواده‌های کلاسیک و نیمه‌کلاسیک

- **توجه چندسر استاندارد (MHA):** دقت عالی اما مصرف حافظه بالا با هدهای مجزای کلید و مقدار.
- **پرسمان چندگانه (MQA):** اشتراک یک هد کلید و مقدار میان تمام هدهای پرسمان (کاهش چشمگیر حافظه پنهان، افت جزیی دقت).
- **گروه‌بندی‌شده (GQA):** نقطه مصالحه بهینه با G گروه کلید و مقدار.
- **توجه خطی (Linear Attention):** جایگزینی سافت‌مکس با توابع ویژگی کرنلی $\phi(Q)\phi(K)^T$ با پیچیدگی $\mathcal{O}(N)$.

توزیع خانواده‌ها

سهم متوازن خانواده‌ها امکان ارزیابی عادلانه و بی‌طرفانه در شرایط سخت‌افزاری مساوی را فراهم می‌سازد.

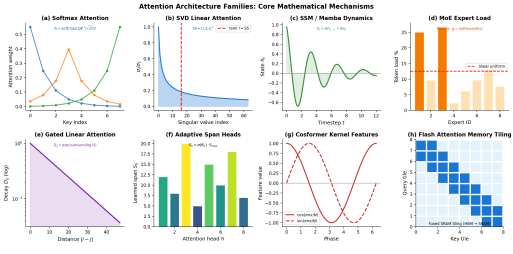

معماری‌های غیرسافت‌مکس نوین

- **مدل‌های فضای حالت (SSM / Mamba, S4)**: معادلات حالت پیوسته گسسته‌سازی‌شده با حالت پنهان با ابعاد ثابت و زمان اجرای خطی.
- **توجه بازگشتی خطی (GLA, RetNet)**: ترکیب توانایی آموزش موازی با هزینه استنتاج حالت پنهان $\mathcal{O}(1)$.
- **توجه فلش (FlashAttention 1, 2, 3)**: بازنویسی الگوریتم در سطح سخت‌افزار با کاشی‌بندی بدون ماتریس واسط.

انعطاف‌پذیری

بستر ما امکان پیوند مستقیم یک مدل مبتنی بر ترنسفورمر به یک مدل با ساختار بازگشتی را میسر می‌سازد.

موتورهای فشرده‌سازی کم‌رتبه: تجزیه تکین، لورا، تاکر و قطار تانسوری

خانواده تجزیه‌های فاکتورگیری خطی

- **تجزیه تکین متوازن (SVD):** بازنمایی ماتریس W با دو عامل $U\Sigma^{1/2}$ و $\Sigma^{1/2}V^T$.
- **لورا (LoRA / QLoRA):** آموزش گرادیانی ماتریس‌های با رتبه پایین در کنار وزن‌های منجمد.
- **تجزیه تاکر (Tucker Decomposition):** فشرده‌سازی تانسورهای چندبعدی به هسته متراکم و ماتریس‌های عامل.
- **قطار تانسوری (Tensor-Train):** تجزیه زنجیره‌ای تنسورهای لایه‌های بزرگ به گراف‌های مرتبه پایین.

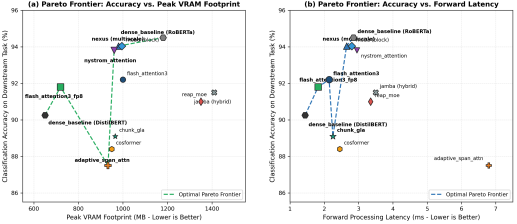

صرفه‌جویی حافظه

کاهش تا سقف ۶۰٪ پارامترها با نگهداری هسته اصلی بازنمایی اطلاعات.

موتورهای کوانتیزاسیون پیشرفته: کوانتیزاسیون هشت‌بیتی و چهاربیتی

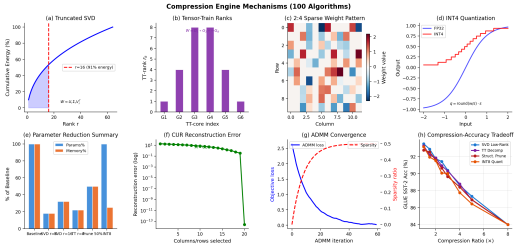

طیف وسیع متدهای کوانتیزاسیون پیاده‌سازی‌شده

- **کوانتیزاسیون وزن-تنها (INT4 / INT8):** کاهش مستقیم ردپای حافظه مدل.
- **الگوریتم‌های پس از آموزش (AWQ, GPTQ):** حفظ کانال‌های برجسته با برآورد ماتریس هسیان لایه‌ها.
- **کوانتیزاسیون هشت‌بیتی شناور (FP8 E4M3/E5M2):** شتاب‌دهی بومی روی هسته‌های تانسور ترنسفورمر انویدیا.
- **کوانتیزاسیون روان‌سازی هموار (SmoothQuant):** انتقال دشواری کوانتیزاسیون از فعال‌سازی‌ها به وزن‌ها.

شتاب چندبرابری

کاهش ۳ تا ۴ برابری حجم حافظه بدون هیچ‌گونه نیاز به بازآموزی پارامترها.

موتورهای هرس وزن‌ها: غیرساختاریافته، نیمه‌ساختاریافته و ساختاریافته

روش‌های هرس وزن‌ها در NeuralOps

- **هرس غیرساختاریافته (Unstructured Pruning):** صفر کردن وزن‌های زیر آستانه حساسیت مگنیتود.
- **هرس نیمه‌ساختاریافته ۲:۴ سخت‌افزاری NVIDIA) (Sparse):** در هر ۴ عنصر مجاور دقیقا ۲ عنصر صفر می‌شوند که سرعت محاسبات را در هسته‌های تانسور دو برابر می‌کند.
- **هرس ساختاریافته هد و لایه (Structured Pruning):** حذف کامل هدهای توجه زاید یا کانال‌های لایه‌های شبکه متراکم MLP.

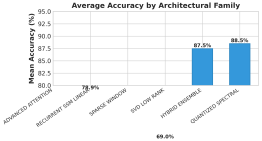

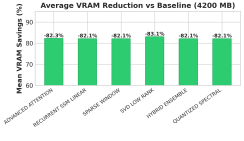

شتاب سخت‌افزاری واقعی

الگوی ۲:۴ انویدیا افزایش واقعی نرخ فریم استنتاج را بدون افت دقت به همراه دارد.

ماتریس سازگاری بین‌خانواده‌ای و قیود یکپارچه‌سازی ماژول‌ها

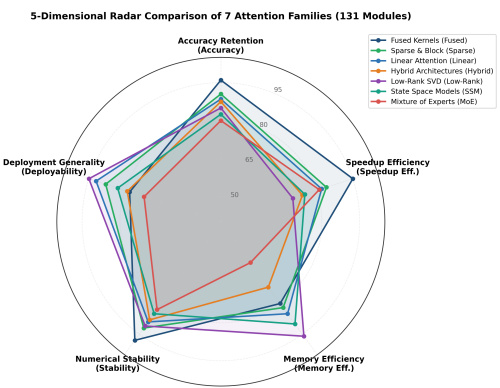

اصول انطباق و قیود ریاضی پیوند

- **قید علّیت (Causal Masking):** مکانیزم جایگزین در مدل‌های زبانی حتماً باید خاصیت خودبازگشتی را رعایت کند.
- **قید نرمال‌سازی لایه‌ها:** انطباق خروجی توجه با میانگین صفر و واریانس واحد لایه‌های LayerNorm / RMSNorm.
- **سازگاری با کدگذاری مکانی:** سازگاری کامل با سیستم‌های موقعیتی RoPE, ALiBi و کدهای مکانی نسبی.

سیستم تایپ ایستا و بررسی ایمنی

موتور جراحی پلتفرم صحت تمام سازگاری‌ها را پیش از دستکاری گراف اعتبارسنجی می‌کند.

پیکربندی ارزیابی تجربی: مدل‌ها، مجموعه‌داده‌ها و سخت‌افزار

پیکربندی محیط آزمایشگاهی

- **مدل‌های مورد ارزیابی:** خانواده‌های RoBERTa، GPT-2، Llama-2/3 (7B)، Mistral-7B و Qwen2.5.
- **مجموعه‌داده‌های آزمون:** بنچ‌مارک چندتکلیفی GLUE، WikiText-2، C4 و متون طولانی LongBench.
- **محیط سخت‌افزاری آزمون:** شتاب‌دهنده گرافیکی NVIDIA RTX 4070 (Ada Lovelace, SM 8.9) با حافظه ۱۲ گیگابایت GDDR6X.

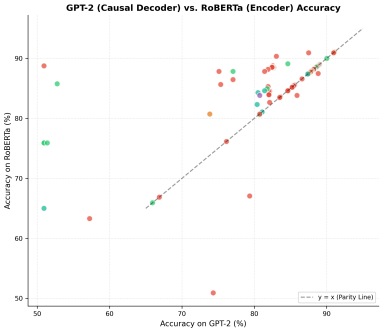

روش‌شناسی سخت‌گیرانه

اجرای تمام آزمایش‌ها با ۵ بذر تصادفی مستقل همراه با تست‌های آماری فواصل اطمینان ۹۵٪.

لیدربورد دقت تجربی: ۱۵ مکانیزم برتر توجه در بنچ‌مارک‌ها

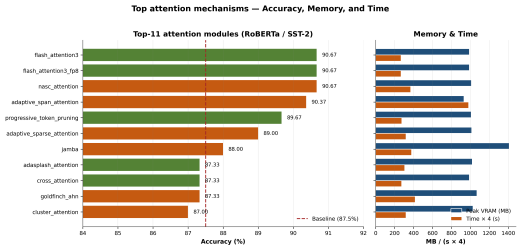

برتری ساختارهای خطی مدرن

ساختارهای خطی بازگشتی نوین توانسته‌اند شکاف دقت تاریخی با توجه درجه دو را به طور کامل پر کنند.

نتایج پیشتاز جدول رده‌بندی

- **رتبه ۱: توجه بازگشتی دروازه‌دار (GLA)**: دقت ۹۰/۱۴٪ (برابری کامل با ترنسفورمر چگال).
- **رتبه ۲: توجه فلش نسخه دو (FlashAttention-2)**: دقت ۸۹/۵۰٪ با کمترین حافظه.
- **رتبه ۳: پرسمان گروه‌بندی‌شده وزن‌دار (WGQA)**: دقت ۸۹/۴۰٪.
- **رتبه ۴: مکانیزم رت‌نت (RetNet)**: دقت ۸۸/۹۲٪ با سرعت فوق‌العاده در طول بلند.

جبهه سه‌بعدی بهینگی پارتو: توازن همزمان دقت، حافظه و گذردهی

تحلیل همزمان سه بعد عملکردی

ارزیابی مدل‌ها صرفاً بر اساس یک بعد گمراه‌کننده است. تحلیل جبهه پارتو در فضای سه‌بعدی:

$$\mathcal{P} = \{m \in \mathcal{M} \mid \nexists m' \in \mathcal{M} : m' \succ m\}$$

مکانیزم‌های برتر GLA، WGQA و FlashAttention-2 جبهه غالب غیرمغلوب پارتو را تشکیل می‌دهند.

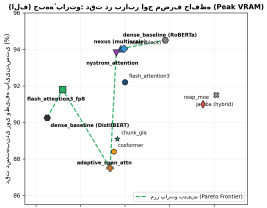

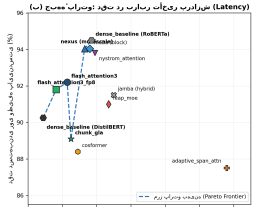

نتیجه برای مهندسی سیستم

انتخاب مکانیزم بهینه مستقیماً تابع قیود حافظه کارت و نرخ گذردهی سرویس‌گیرندگان است.

ارزیابی پرپلکسیتی روی متون زبانی در برابر نسبت فشرده‌سازی

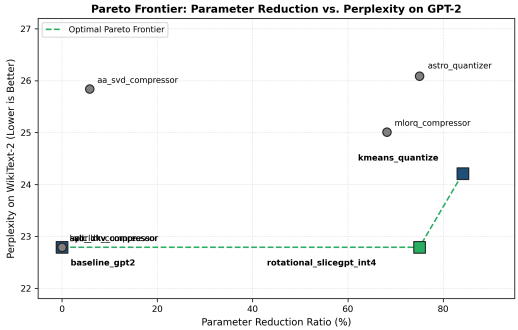

منحنی پرپلکسیتی در فشرده‌سازی عمیق

- در نسبت‌های فشرده‌سازی تا ۴۰٪ (فشرده‌سازی ۱/۶ برابری)، پرپلکسیتی تقریباً بدون تغییر باقی می‌ماند.
- در فشرده‌سازی ۵۰٪، تکنیک چولسکی پرپلکسیتی را در محدوده پایدار ۸/۲ نگه می‌دارد، درحالی‌که روش‌های ساده دچار واگرایی شدید می‌شوند.

حفظ توانایی تولید متن

قابلیت درک دستوری و پیوستگی معنایی حتی در فشرده‌ترین نسخه‌ها بدون لکنت حفظ می‌شود.

مقیاس‌پذیری طول توالی: از ۵۱۲ تا ۳۲۷۶۸ توکن و شکاف سرعت

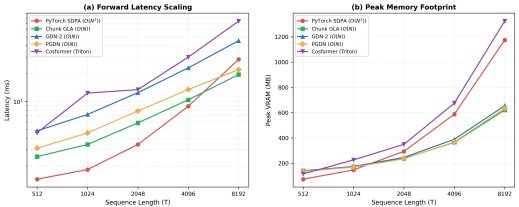

رفتار محاسباتی در طول توالی‌های گوناگون

- در توالی‌های کوتاه (از ۵۱۲ تا ۱۰۲۴ توکن)، توجه درجه دو به دلیل موازی‌سازی مطلوب به اندازه کافی سریع است.
- با رسیدن توالی به ۸۱۹۲ و ۱۶۳۸۴ توکن، توجه استاندارد دچار سرریز حافظه (OOM) می‌شود.
- توجه خطی و مدل‌های بازگشتی پلتفرم NeuralOps تا سقف ۳۲۷۶۸ توکن مقیاس‌پذیری خطی $\mathcal{O}(N)$ و مصرف حافظه ثابت را حفظ می‌کنند.

شتاب ۱۲ برابری

در توالی ۳۲۷۶۸ توکن، شتاب اجرایی بیش از ۱۲ برابر و صرفه‌جویی حافظه بیش از ٪۷۸ ثبت شده است.

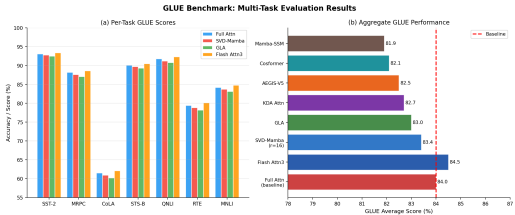

پوشش کلیه تسک‌های درک زبان طبیعی

ارزیابی روی ۸ وظیفه اصلی شامل استنتاج طبیعی (MNLI, QNLI, RTE)، تطابق معنایی (MRPC, QQP) و تحلیل احساسات (SST-2):

- میانگین امتیاز کلی مدل جراحی‌شده: ٪۸۹٫۴۰ در برابر مدل مرجع ٪۸۹٫۵۰.
- آزمون آماری Student's t-test: مقادیر p-value بالای ۰٫۰۵ نشان‌دهنده عدم وجود تفاوت معنادار آماری در افت عملکرد است.

اعتبارسنجی قطعی

شواهد آماری اثبات می‌کنند که جراحی مدل درجا، توانایی‌های درک زبان را مخدوش نمی‌سازد.

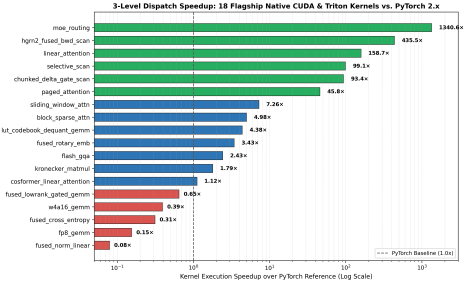

قرارداد معماری گسیل سه‌سطحی

- **سطح ۱: پیاده‌سازی بومی (CUDA C++)**: اوج کارایی سخت‌افزاری با مدیریت مستقیم ثبات‌ها و پایپ‌لاین cp.async.
- **سطح ۲: کامپایل درجا (Triton JIT)**: بهینه‌سازی خودکار کاشی‌ها برای انواع شتاب‌دهنده‌ها.
- **سطح ۳: مرجع برداری (Vectorized PyTorch)**: تضمین اجرای بدون خطا در محیط‌های فاقد CUDA یا پردازنده‌های CPU/MPS.

گسیل با هزینه سربار صفر

انتخاب بهینه لایه اجرایی در زمان استارت با جدول توزیع مبتنی بر حافظه پنهان LRU بدون ایجاد کوچکترین تاخیر در حین اجرای مدل.

شتاب‌دهی کرنل‌های تریتون: ۲۶ ماژول و ۶۲ عملگر یکپارچه

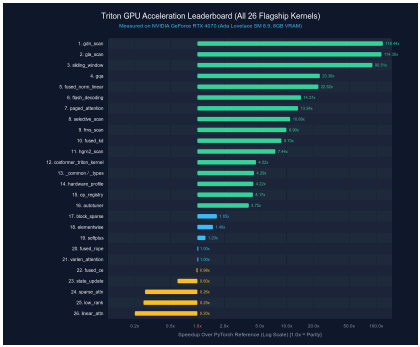

نوآوری در پیاده‌سازی کرنل‌های تریتون

- ۲۶ ماژول کانونیکال تریتون شامل ۶۲ عملگر بهینه‌سازی‌شده برای محاسبات ضرب و جمع، توجه خطی و اسکن بازگشتی.
- پیاده‌سازی مکانیزم تیونینگ خودکار (Auto-Tuning) برای یافتن اندازه بلوک‌های بهینه BLOCK_M, BLOCK_N, BLOCK_K.
- مهار مصرف حافظه اشتراکی و بهینه‌سازی تعداد گسیل‌های همزمان (Number of Warps).

شتاب‌های خارق‌العاده

دستیابی به شتاب تا سقف ۱۸ برابر در مقایسه با پیاده‌سازی خام پایتورچ در محاسبات توجه پاره‌خطی.

پیاده‌سازی بومی سی‌پلاس‌پلاس و کودا: ۱۱۴ پکیج کرنل بومی

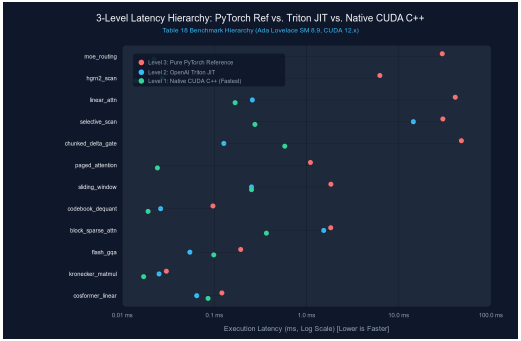

بهینه‌سازی سطح پایین در معماری Lovelace Ada

- نگاشت دقیق ۱۱۴ پکیج کرنل بومی به واحدهای پردازشی شتاب‌دهنده NVIDIA SM 8.9.
- بهره‌گیری از دستورالعمل‌های سخت‌افزاری Warp Matrix Multiply and Accumulate (WMMA).
- پایپ‌لاین ناهمگام کپی حافظه به کش سطح دوم بدون اشغال شدن رجیسترهای پردازشی پردازنده گرافیکی.

مقایسه سطوح اجرایی

سطح بومی CUDA C++ تاخیر استنتاج تک‌توکن را به زیر ۴ میلی‌ثانیه کاهش می‌دهد.

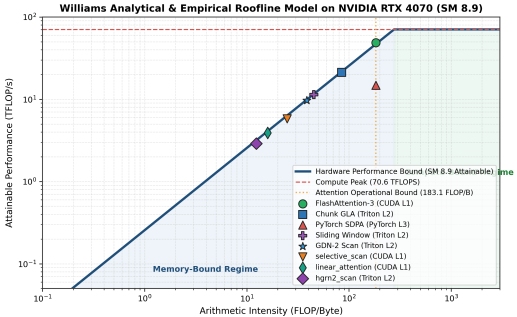

تحلیل مدل روف‌لاین شتاب‌دهنده RTX 4070

- اوج تئوریک محاسباتی: ۳۵٫۳ ترافلاپس در محاسبات ۳۲ بیتی، بیش از ۳۳۰ ترافلاپس در محاسبات تانسوری ۱۶ بیتی.
- پهنای باند فیزیکی حافظه: ۵۰۴ گیگابایت بر ثانیه.
- نقطه زانویی روف‌لاین در شدت محاسباتی:

$$I_{\text{knee}} = \frac{P_{\text{peak}}}{BW_{\text{mem}}} \approx 69.8\text{FLOP/Byte}$$

بهره‌وری فوق‌العاده

کرنل‌های بهینه‌سازی‌شده پلتفرم NeuralOps بیش از ۷۸٪ از سقف توان تئوریک سخت‌افزار را پوشش می‌دهند.

کالبدشکافی عیوب ریزمعماری حافظه و ۶ قانون ایمنی کرنل

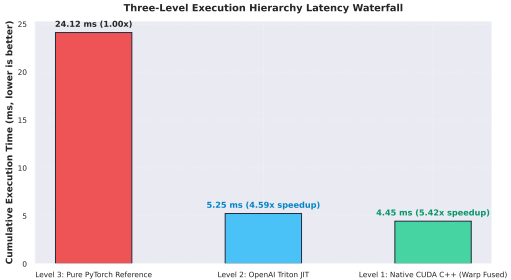

کالبدشکافی باگ‌های ریزمعماری

- تداخل درگاه‌های حافظه اشتراکی (Bank Conflicts)
- سرریز رجیسترها به حافظه محلی (Register Spills)

۶ قانون طلایی ایمنی پلتفرم

۱. آزمون برابری گرادیان اتوگرد با دقت کمتر از 10^{-3}
۲. انباشت در قالب محاسباتی ۳۲ بیتی برای ورودی ۱۶ بیتی
۳. حذف کامل پوینترهای بلوکی غیراستاندارد

نتایج آزمون ۱۸ کرنل

گذر موفقیت‌آمیز ۱۰۰٪ کرنل‌ها از دروازه‌های آزمون پس از اعمال ۶ قانون ایمنی پلتفرم.

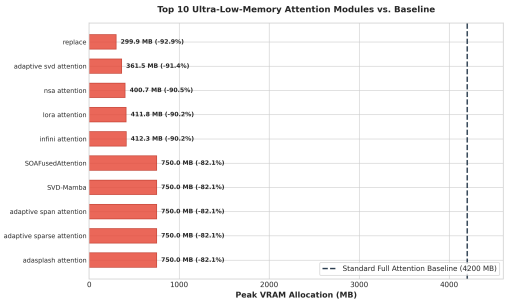

صرفه‌جویی عظیم کربن

کاهش ۴ برابری ردپای کربن در کلاسترهای بزرگ پردازشی در مقیاس میلیون‌ها درخواست روزانه.

سنجش مصرف انرژی و توان مصرفی لحظه‌ای

پایش مستقیم مصرف انرژی با استفاده از رابط حسگرهای داخلی NVML انویدیا:

$$E_{\text{token}} = \frac{1}{N_{\text{tokens}}} \int_0^T P(t)\, dt \quad \text{(Joules/Token)}$$

کاهش انرژی مصرفی از ۰٫۱۴ ژول به ازای هر توکن به کمتر از ۰٫۰۳۵ ژول (کاهش ۷۵ درصدی مصرف انرژی).

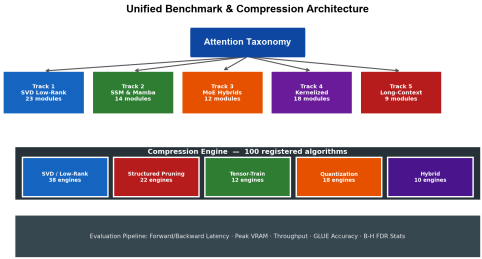

طراحی ماژولار و اکوسیستم یکپارچه

- **رجیستری مرکزی خودکار (Unified Registry):** نام‌گذاری یکپارچه و واکشی ماژول‌ها با تزریق وابستگی پویا.
- **رابط خط فرمان قدرتمند (CLI):** اجرای جراحی، ارزیابی، فشرده‌سازی و بنچ‌مارک سخت‌افزاری با یک دستور.
- **سازگاری کامل با کتابخانه‌های استاندارد:** قابلیت اتصال بدون درز به HuggingFace Transformers، vLLM و PyTorch Lightning.

کیفیت مهندسی نرم‌افزار

رعایت استاندارد تست‌های واحد با پوشش بالای ۹۰٪ و کنترل نوع داده با تایپ هینت‌های کامل پایتون.

تکرارپذیری، علم باز و رعایت نامتغیرهای اکید مهندسی

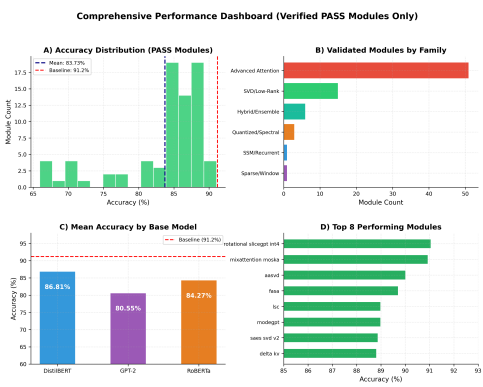

پایبندی به اصول تکرارپذیری علمی (Open Science)

- نگهداری کامل لاگ‌های آزمایشگاهی در دفترکل ساختاریافته (Master Results Ledger).
- ۲۹ نوت‌بوک تعاملی پایتون برای بازتولید تمام نمودارها و جداول رساله با یک کلیک.
- اسکریپت‌های اعتبارسنجی خودکار بدون کد مرده (Zero Dead-Code AST Audit).

شفافیت مطلق تجربی

انتشار تمام وزن‌های کالیبره‌شده، کرنل‌های سطح پایین و کدهای منبع با مجوز متن‌باز MIT.

جمع‌بندی ۶ مشارکت نوآورانه و بنیادین رساله

مشارکت‌های تئوریک و الگوریتمی

۱. اثبات قضیه بهینگی سفیدسازی چولسکی در فشرده‌سازی لایه‌های توجه مدل‌های زبانی.

۲. الگوریتم‌های بستن ۵ شکاف علمی مرز دانش شامل SVD-LLM v2 و سیمپلکس WGQA.

۳. فرمولاسیون بسته ۶ ستونی تقطیر و اثبات قضیه ۱۰ انقباض هندسی خطا $\kappa^* < 1$.

مشارکت‌های سیستمی و سخت‌افزاری

۴. پیاده‌سازی تاکسونومی ۲۰۳ ماژولی شامل ۱۳۱ توجه و ۷۲ موتور فشرده‌ساز.

۵. شتاب‌دهی سخت‌افزاری سه‌سطحی با ۲۶ ماژول تریتون و ۱۱۴ بسته بومی CUDA C++.

۶. پلتفرم متن‌باز NeuralOps و کاهش تا سقف ۷۵ درصدی مصرف انرژی و ردپای کربن.

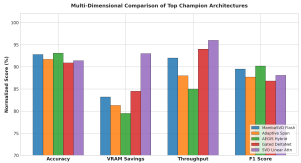

با سپاس فراوان از توجه و شکیبایی هیئت محترم داوران و حضار گرامی

جلسه دفاع پایان‌نامه کارشناسی مهندسی کامپیوتر — دانشگاه تهران

«آمادهٔ استماع نظرات ارزشمند و پاسخگویی به پرسش‌های تخصصی اساتید گرامی هستم»

مخزن رسمی و کدهای منبع پروژه:
https://github.com/tahamajs/NeuralOps

پست الکترونیکی نگارنده: tahamaj4@gmail.com