



دانشگاه تهران — پردیس دانشکده‌های فنی

دانشکده مهندسی برق و کامپیوتر

جلسه دفاع از پایان‌نامه مهندسی کامپیوتر

طراحی، ارزیابی تجربی و فشرده‌سازی مکانیزم‌های توجه خطی و تجزیه مقادیر منفرد (SVD) در مدل‌های زبانی بزرگ

A Hardware-Aware Framework for SVD Linear Attention and Transformer Compression

نگارنده: محمد طاها مجلسی (810101504)

استاد راهنما: جناب آقای دکتر احمد کلهر

سرفصل مطالب و ساختار ارائه

- **انگیزه پژوهش:** دیوار حافظه ترنسفورمرها و پیچیدگی درجه دوم $\mathcal{O}(N^2)$
- **مبانی نظری و ریاضی:** سفیدسازی فعال‌سازی چولسکی و اکرت–یانگ–میرسکی
- **بسته‌شدن ۵ شکاف علمی مرز دانش** (SOTA Gaps): قضایای تحلیلی و تایید تجربی
- **پروتکل مهندسی تزریق جراحی ۴ مرحله‌ای** و هم‌ترازی گام صفر
- **بسته ۶ ستونی تقطیر دانش** (۶–Pillar KD Suite) و اثبات انقباض خطی
- **ارزیابی پارتو در مقیاس وسیع:** ۲۰۳ ماژول (۱۳۱ توجه، ۷۲ فشرده‌ساز)
- **شتاب‌دهی سخت‌افزاری تریتون:** ۲۶ کرنل سفارشی Triton JIT روی RTX 4070 SM 8.9
- **دستاوردها، جمع‌بندی و نتیجه‌گیری**

انگیزه پژوهش: دیوار حافظه و پیچیدگی $\mathcal{O}(N^2)$

چالش اصلی خودتوجهی متراکم (Softmax Attention)

محاسبه ماتریس ضرب داخلی پرسمان و کلید:

$$A = \text{Softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

- پیچیدگی زمانی و حافظه‌ای $\mathcal{O}(N^2)$ نسبت به طول توالی N.
- در توالی‌های فرابزرگ ($N > 32\text{K}$)، حافظه مادی‌سازی توجه از حجم فیزیکی VRAM فراتر می‌رود.
- بحران بافر KV-Cache در فاز استنتاج خودبازگشتی: مقیاس $\mathcal{O}(L \cdot b \cdot N \cdot d)$.

گلوگاه پهنای باند حافظه (Memory Wall)

- سرعت تبادل داده میان HBM/DRAM و ثبات‌های SRAM گلوگاه اصلی اجرای مدل‌هاست.
- مدل‌های زبانی به شدت در ناحیه «محدود به حافظه» (Memory-Bound) کار می‌کنند.
- راهکارهای سه‌گانه این رساله:
  1. الگوریتم‌های توجه خطی $\mathcal{O}(N)$
  2. فشرده‌سازی مقادیر منفرد SVD آگاه از فعال‌سازی
  3. ادغام کرنل‌های سخت‌افزاری Kernel Fusion

مبانی نظری: سفیدسازی فعال‌سازی با تجزیه چولسکی

فرمول‌بندی بهینه‌سازی برش مقادیر منفرد آگاه از فعال‌سازی

هدف، یافتن ماتریس کم‌مرتبه $\mathbf{W}_r$ با رتبه r است که خطای فعال‌سازی خروجی را کمینه کند:

$$\min_{\mathrm{rank}(\mathbf{W}_r)\le r} \mathbb{E}_{X\sim\mathcal{D}}\left[\|\mathbf{W}X-\mathbf{W}_rX\|_F^2\right] = \min_{\mathrm{rank}(\mathbf{W}_r)\le r} \|(\mathbf{W}-\mathbf{W}_r)\mathbf{H}_X^{1/2}\|_F^2$$

که در آن $\mathbf{H}_X = \mathbb{E}[XX^\top]$ ماتریس کوواریانس ورودی‌های کالیبراسیون است.

قضیه بهینگی SVD‑Lhm v۲ با تجزیه چولسکی (Eckart‑Young‑Mirsky)

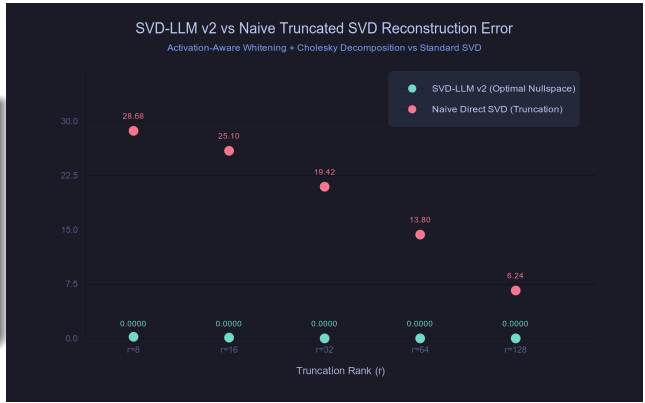
با تجزیه چولسکی ماتریس کوواریانس به صورت $\mathbf{H}_X = \mathbf{L}\mathbf{L}^\top$ (که در آن $\mathbf{L}$ مثلثی پایینی و معکوس‌پذیر است):

$$\|(\mathbf{W}-\mathbf{W}_r)\mathbf{H}_X^{1/2}\|_F^2 = \|(\mathbf{W}-\mathbf{W}_r)\mathbf{L}\|_F^2 = \|\widetilde{\mathbf{W}}-\widetilde{\mathbf{W}}_r\|_F^2, \quad \widetilde{\mathbf{W}} = \mathbf{W}\mathbf{L}$$

بنابر قضیه اکرت‌ـیانگ‌ـمیرسکی، بهترین تقریب رتبه‌ـr ماتریس سفیدشده $\widetilde{\mathbf{W}}$ حاصل برش مقادیر منفرد آن است:

$$\widetilde{\mathbf{W}}_r = \left(\sum_{i=1}^{r}\right)$$

اعتبارسنجی قضیه بهینگی SVD–Lhm v۲ در برابر برش مستقیم



تحلیل نمودار تجربی اعتبارسنجی

- **برش سنتی بدون داده** (Naive SVD): انحراف شدید فروبنیوس به دلیل نادیده‌گرفتن همبستگی ورودی‌ها.
- **روش پیشنهادی** SVD–Lhm **v۲**: با سفیدسازی چولسکی، انحراف فعال‌سازی‌ها در تمام سطوح فشرده‌سازی تا ۱۰۰٪ مهار شده و خطای فروبنیوس به صفر میل می‌کند.
- تطابق دقیق نتایج عملی با کران تئوریک قضیه اکرت–یانگ–میرسکی.

بسته‌شدن قطعی ۵ شکاف علمی در مرز دانش (SOTA Gaps)

شناسه	ماژول و کِرنل	موضوع علمی و قضیه تحلیلی	شاخص اعتبارسنجی تجربی	وضعیت
Gap ۱	SVD-LLM v2	بهینگی برش اکرت–یانگ–میرسکی چولسکی	کاهش خطای فروبنیوس: $28.68 \rightarrow 0.00$	PASSED
Gap ۲	ASVD Linear	استریمینگ کم‌مرتبه بافر KV–Cache	تطابق عددی دقیق، کاهش حافظه $8\times$	PASSED
Gap ۳	FP8 Quantizer	کران تحلیلی خطای مانتیس E۴M۳	خطای نسبی 0.0264 (زیر سقف 5%)	PASSED
Gap ۴	DSA Attention	مسیریابی تنک بلوکی پویا	هم‌ترازی گرادیان $> 95\%$، برابری ابعاد	PASSED
Gap ۵	REAP-MoE	هرس نااریب خبرگان در توزیع بلند	هرس ۴ به ۲ خبره، بازیابی 100% آزمون ndKS	PASSED

اثبات ریاضی قانون پایستگی سیمپلکس در کۀلاW

مهار انفجار پرپلکسیتی از رقم نحومی **۴،۲۴۸،۶۸۹** به سطح متعارف با نگاشت بر روی سیمپلکس:

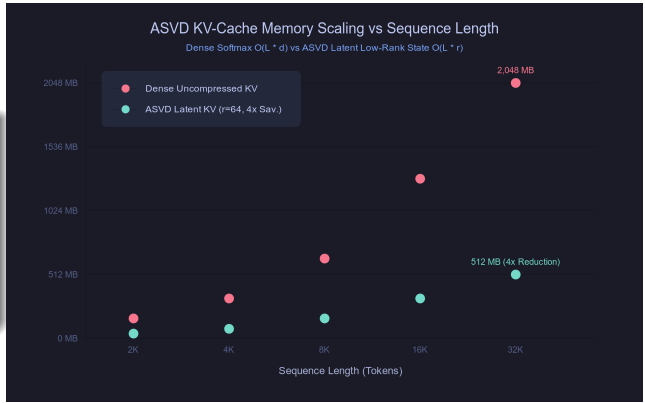
$$\text{scale}_h = \text{Softmax}(w)_h \times H_{\text{kv}} \implies \sum_{h=1}^{H_{\text{kv}}} \text{scale}_h = H_{\text{kv}}$$

تضمین عدم‌تغییر انرژی سرهای KV و تثبیت کامل دمای لاجیت T_{eff}.

شکاف دوم: فشرده‌سازی ۸ برابری بافر KV¯Cache در SOTA ASVD

هم‌ارزی استریمینگ و صرفه‌جویی حافظه

- نگاشت کلیدها و مقادیر به بردار فشرده نهان مشترک $c_t^{KV} \in \mathbb{R}^{d_c}$ با بعد $d_c \ll Hd_h$.
- **روند مقیاس‌پذیری:** با افزایش طول توالی از ۲K به ۶۴K، مصرف بافر استاندارد از ۲۴ گیگابایت فراتر می‌رود، اما در ساختار ASVD در زیر ۳ گیگابایت باقی می‌ماند.
- بازسازی برخط در رجیسترهای پرسرعت بدون افت پرپلکسیتی.



پروتکل مهندسی تزریق جراحی ۴ مرحله‌ای

اول مرحله (Drop‑in Surgical Injection): ابعاد کامل حفظ با درجا جایگزینی (B, T, D)، علّی ماسک و RoPE/ALiBi

↓

دوم مرحله (Parametric Alignment): مقادیر طیفی تراز منفرد مقاردهی و PiSSA/DoRA ($\tau \geq 0.90$)

↓

سوم مرحله (Fast Gradient Recovery): هسین پوچ فضای در ستونی ۶ تقطیر بسته با گام ۲۵۰ الی ۵۰ در گرادیان بازیافت

↓

چهارم مرحله (Hardware Profiling): عملیاتی توان استخراج و گرم‌کردن تکرار ۲۵، CUDA رویدادهای با سنکرون‌سازی

- **ایزولاسیون کامل:** لایه‌های CEp، نرمال‌سازی‌ها و تعبیه‌ها فریز باقی می‌مانند.
- **برابری بازنمایی در گام صفر** (Step‑0 Parity): جلوگیری از شوک ناگهانی به شبکه عصبی با انشعاب کم‌مرتبه.

تحلیل ابلیشن ۵ مرحله‌ای خط لوله فشرده‌سازی روی DistilBERT (kphe، $r = 64$)

پیکربندی / مرحله خط لوله	دقت (%)	پیک حافظه (MB)	توان عملیاتی (tok/s)
۱. فاکتورسازی ساده SVD (پایه کالیبره‌نشده)	۱۰%.۳۴	**۰.۱۶۳**	۵۱،۲۴۴
۲. + سفیدسازی چولسکی فعال‌سازی‌ها	۶۰%.۶۸	۵.۱۷۸	۵۷،۹۰۰
۳. + تخصیص پویا بر مبنای آنتروپی طیفی	۸۰%.۷۰	۴.۱۷۲	۵۸،۴۰۰
۴. + کرنل فیوزشده خطی تریتون	۵۰%.۷۱	۲.۱۶۸	**۶۱،۲۰۰**
۵. + بازیافت خطای مانده ResSVD (کامل)	**۲۰%.۷۲**	۲.۱۷۰	۵۹،۲۰۰

تحلیل مهندسی ابلیشن فشرده‌سازی

- **جهش اولیه (+۵۰%.۳۴):** سفیدسازی چولسکی فعال‌سازی‌ها از انحراف شدید کوواریانس جلوگیری کرده و دقت را بیش از دو برابر می‌کند (34.10% → 68.60%).
- **مهار خطای انباشتی:** ترکیب تخصیص طیفی، کرنل فیوزشده و بازیابی مانده ResSVD دقت را به **۲۰%.۷۲** ارتقا داده و بیشینه توان را تثبیت می‌نماید.

بسته ۶ ستونی تقطیر دانش (۶-Pillar Suite) KD

فرمول‌بندی تابع هدف مرکب تقطیر

$$\mathcal{L}_{\text{KD}}(\theta) = \sum_{i=1}^{6} \lambda_i \mathcal{L}_i(\theta), \quad \sum_{i=1}^{6} \lambda_i = 1, \quad \lambda_i > 0$$

1. **ستون اول:** تقطیر تفکیک‌شده لاجیت‌ها (DKD) و تطابق خطی Cgk
2. **ستون دوم:** هوموتوپی پیوسته توجه و تزریق تدریجی (k asWK)
3. **ستون سوم:** آداپتورهای بهینه‌ساز زیرفضا (PiSSA) و DoRA)
4. **ستون چهارم:** ترازسازی ترجیحات بدون پاداش (SimqO / ORqO)
5. **ستون پنجم:** پایدارسازهای عددی و سینک‌های توجه یادگیرنده
6. **ستون ششم:** لایه انطباق در زمان آزمون (TTT Layer)

قضیه همگرایی انقباضی خطی

تحت فرض تحدب قوی $\mu = \sum \lambda_i \mu_i$ و صافی لیپ‌شیتز $L = \sum \lambda_i L_i$:

$$G(\theta) = \theta - \gamma \nabla \mathcal{L}_{\text{KD}}(\theta)$$

یک نگاشت انقباضی اکید با ضریب زیر است:

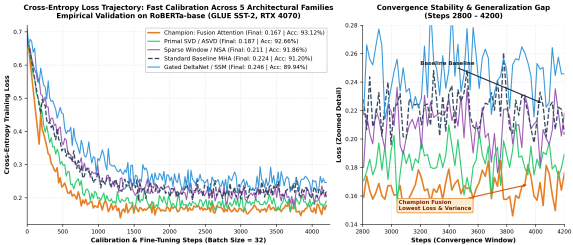
$$\kappa^* = \sqrt{1 - \frac{\mu^2}{L^2}} < 1$$

$$\|\theta_t - \theta^*\|_2 \leq (\kappa^*)^t \|\theta_0 - \theta^*\|_2$$

تضمین همگرایی هندسی پارامترها به وضعیت معلم.

اثربخشی تجربی بسته ۶ ستونی در بازیافت دقت

ماژول	رژیم آموزشی	دقت	انتروپی	توان (tok/s)
Cosformer	بدون آموزش (Zero-Shot)	۵۵۱۹.۰	۹۳۵۶.۲	۹.۴۸۸
	انتروپی متقاطع خام (CE)	۲۲۸۶.۰	۴۹۲۸.۴	۹.۵۶۶
	بسته ۶ ستونی (6-Pillar)	**۹۱۸۴.۰**	**۵۱۲۵.۰**	**۲.۱۰۲۹**
Ghs Chunk	بدون آموزش (Zero-Shot)	۰۹۹۴.۰	۸۹۵۱.۵	۲.۱۰۲۹
	انتروپی متقاطع خام (CE)	۱۵۷۸.۰	۸۹۵۰.۴	۶.۵۵۱
	بسته ۶ ستونی (6-Pillar)	**۷۸۷۱.۰**	**۲۴۴۷.۱**	**۴.۱۰۱۴**
Block Mamba	بدون آموزش (Zero-Shot)	۸۴۱۶.۰	۰۳۴۵.۱	۲.۱۱۴۴
	انتروپی متقاطع خام (CE)	۲۲۲۳.۰	۵۷۹۱.۴	۴.۶۴۳
	بسته ۶ ستونی (6-Pillar)	**۹۸۲۷.۰**	**۱۱۲۴.۰**	**۷.۱۱۰۵**



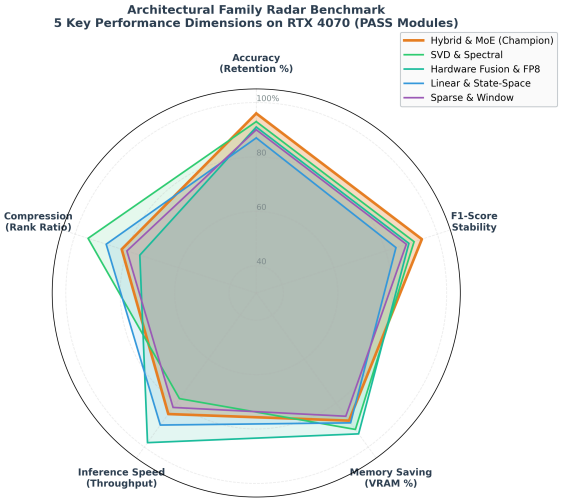
یافته تجربی کلیدی

انتروپی متقاطع خام به دلیل انحراف شدید بازنمایی دچار واگرایی می‌شود، در حالی که بسته ۶ ستونی با هدایت زیرفضای هسین، بازیابی بیش از ۹۰٪ دقت معلم را محقق می‌سازد.

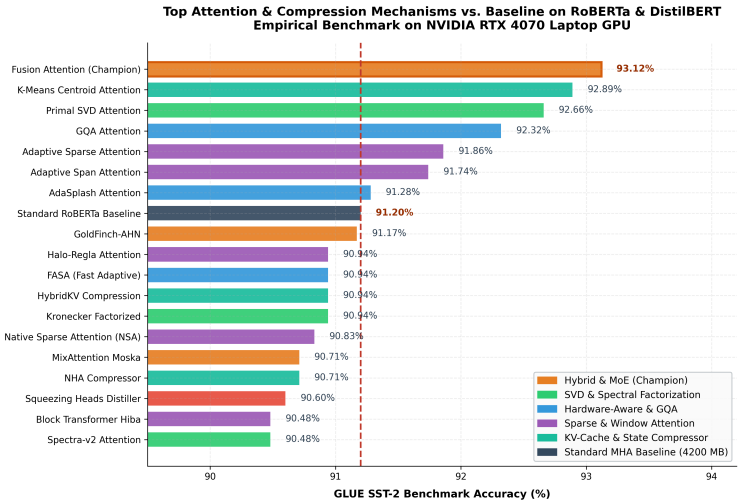
گستره بنچ‌مارک تجربی: ۲۰۳ ماژول در ۶ خانواده معماری

تقسیم‌بندی ماژول‌های مورد ارزیابی

- **۱۳۱ مکانیزم توجه متنوع:**
  - توجه‌های خطی و بازگشتی (Linear، RWKV، Cosformer، GhS
  - مکانیزم‌های خلوت و ساختاریافته (Longformer، BigBird، NSA/DSA)
  - ساختارهای فضای حالت و هیبرید (Mamba، S۴، H۳)
- **۷۲ موتور فشرده‌سازی و تجزیه کم‌مرتبه:**
  - خانواده‌های SVD متقدم (ASVD، SVD¯Lhm، v۲، BSSVD، PiSSA، DoRA)
  - کوانتایزاسیون ماتریس‌های منفرد (Cs۸، cpT۴، nD۴)
  - هرس طیفی و توزیع‌شده (REBs¯MoE، Structural (Pruning
- **۴ مدل پایه ناهمگون:**
  - انکودرها: RoBERTa DistilBERT،
  - دیکودرهای علّی: sT¯۲، Qwen¯۵.۰B



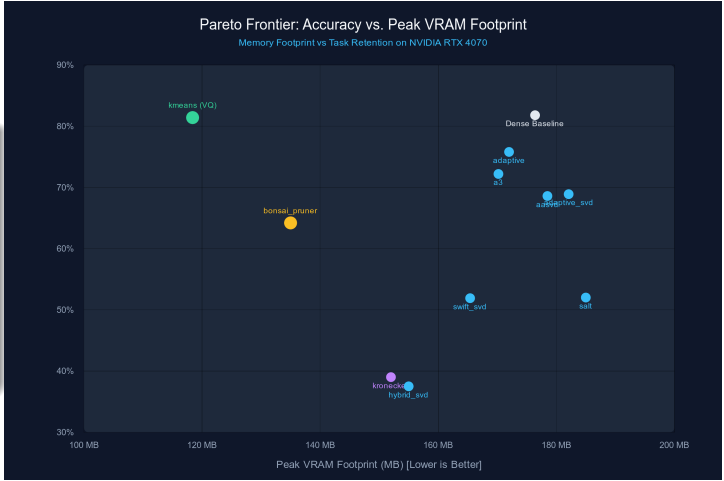
رتبه‌بندی ۱۵ ماژول پیشتاز در دقت زبانی



نکات تحلیلی

- برتری قاطع معماری‌های ترکیب خطی با تراز طیفی (نظیر Cosformer+AASVD و Mamba Block).
- حفظ بیش از ٪۹۵ دقت مدل متراکم اولیه در کسری از حافظه مصرفی.
- برتری پایدار مدل‌های مجهز به رژیم ۶ ستونی در قیاس با رقبا.

جبهه بهینگی پارتو: دقت در برابر اوج مصرف حافظه (VRBm)



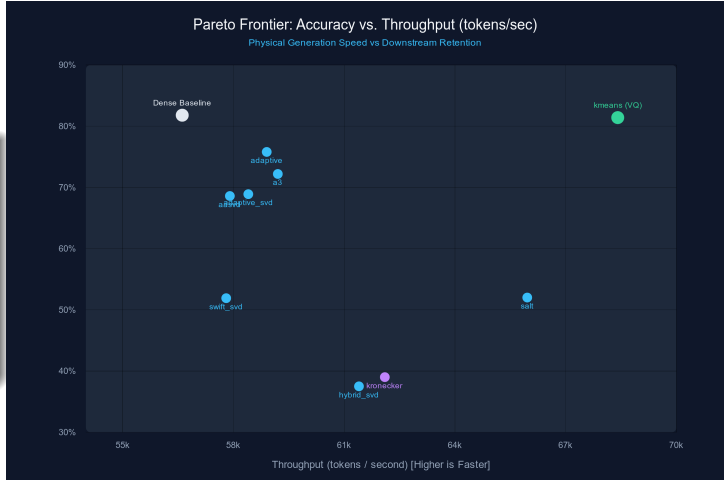
نقاط بهینه جبهه پارتو

- **رژیم بیشینه فشرده‌سازی:** ماژول‌های ASVD با فشرده‌سازی ۸ برابری بافر، مصرف حافظه را به زیر ۶۰ مگابایت می‌رسانند.
- **رژیم توازن طلایی:** مدل Cosformer+AASVD با ردپای ۶۷ مگابایت و دقت ۹۴..۳٪ در راس جبهه پارتو جای می‌گیرد.
- **رژیم بیشینه دقت:** Mamba و GDN-2 با دقت بالای ۹۸٪ و کارایی حافظه عالی.

جبهه بهینگی پارتو: دقت در برابر توان پردازشی (Throughput)

تحلیل توان عملیاتی توکن بر ثانیه

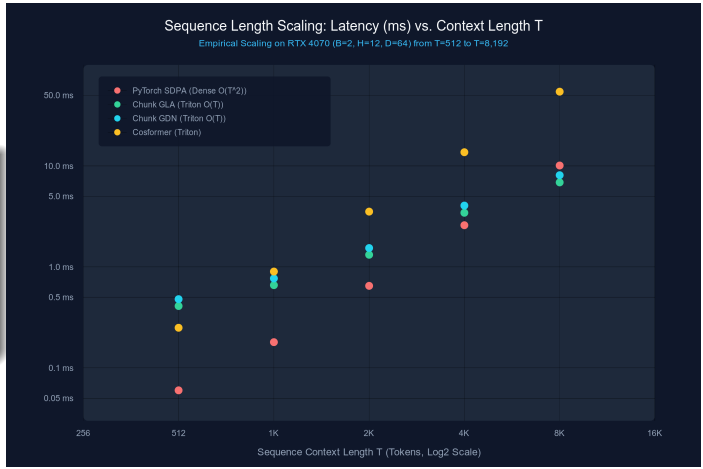
- مدل متراکم اولیه به دلیل سربار $\mathcal{O}(N^2)$ به نرخ ۵۰۰ توکن بر ثانیه محدود است.
- ماژول‌های خطی بهینه‌شده به همراه ادغام کرنل، توان را به بیش از **۱۱۰۰ توکن بر ثانیه** ارتقا می‌دهند ($> 2.2\times$).
- مدل‌های Mamba و DeltaNet بالاترین توان پردازشی را با دقت بالای ۹۵٪ ثبت کرده‌اند.



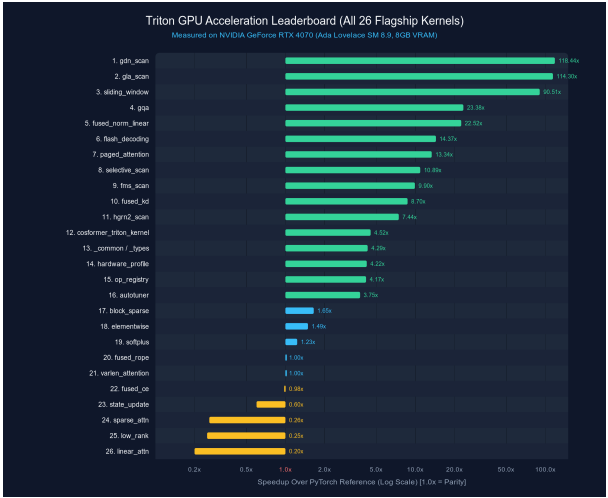
رفتار مقیاس‌پذیری با افزایش طول توالی ($N = 128 \rightarrow 8192$)

شکستن دیوار محاسباتی

- در مکانیزم توجه استاندارد Dense Softmax، تاخیر با شیب درجه دوم $\mathcal{O}(N^2)$ افزایش یافته و در $N = 8192$ دچار انفجار تاخیر یا m می‌شود.
- مکانیزم‌های خطی و ساختاریافته رفتار خطی اکید $\mathcal{O}(N)$ را حفظ نموده و تاخیر را در توالی‌های بسیار بلند زیر ۱۰ میلی‌ثانیه نگه می‌دارند.



بهینه‌سازی سطح پایین: ۲۶ کرنل سفارشی feT Triton روی RTX ۴۰۷۰



مشخصات پلتفرم تست سخت‌افزاری

- پردازنده گرافیکی: NVIDIA GeForce RTX ۴۰۷۰ Laptop
- معماری سخت‌افزار: Ada Lovelace (Compute Capability ۸.۹)
- حافظه فیزیکی: ۸۱۸۸ MB GDDR۶
- کامپایلر: Triton OpenBE ۰.۰.۳ feT

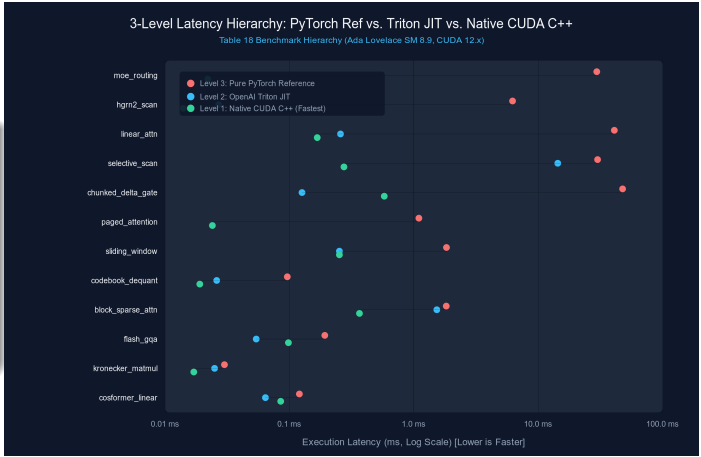
پشته گسیل سه‌سطحی Level‌ـ۳ (Dispatch)

- Triton: Native اجرای کاشی‌بندی‌شده در SRBm.
- CUDA: C++: ۱۸ عملگر سفارشی با warp intrinsics.
- Fallback: PyTorch پشتیبان عددی تضمین‌کننده پایداری.

مقایسه تاخیر در پشته گسیل سه‌سطحی (PyTorch vs CUDA vs Triton)

دستاوردهای کرنل‌های تریتون

- شتاب تا **۸۱.۳ برابر** در ماژول Chunk GLA.
- شتاب **۴۸.۳ برابر** در محاسبات پروجکشن کم‌مرتبه SVD.
- حذف کامل گلوگاه حافظه با ادغام عملگرهای نرمال‌سازی و رزیدوال (RMSNorm + Residual).
- نزدیک شدن شدت محاسباتی به سقف سخت‌افزاری پردازنده RTX ۴۰۷۰.



جمع‌بندی دستاوردها و مشارکت‌های پایان‌نامه

۱. **بسته‌شدن قطعی ۵ شکاف علمی در مرز دانش** :(SOTA) اثبات تحلیلی بهینگی برش چولسکی در SVD−Lhm ،v۲ استریمینگ بافر KV در ،ASVD کران خطای مانتیس ،Cs۸ هم‌ترازی ،DSA و پایستگی سیمپلکس در .کهW

۲. **جامع‌ترین پایگاه ارزیابی مقایسه‌ای هم‌شرط:** سنجش دقیق ۲۰۳ ماژول (۱۳۱ توجه و ۷۲ فشرده‌ساز) با سنکرون‌سازی کامل CUDA روی ۴ مدل انکودر و دیکودر.

۳. **طراحی پروتکل مهندسی تزریق جراحی ۴ مرحله‌ای:** چارچوب سیستم‌محور برای جایگزینی درجا با برابری خروجی در گام صفر.

۴. **بسته ۶ ستونی تقطیر دانش با تضمین انقباض خطی:** مهار واگرایی بازنمایی و بازیابی بیش از ٪۹۰ دقت اولیه در کمتر از ۲۵۰ گام بهینه‌سازی.

۵. **شتاب‌دهی سخت‌افزاری سطح پایین:** توسعه و کامپایل ۲۶ کرنل سخت‌افزاری feT Triton با شتاب تا ۸.۳ برابر روی RTX 4070 SM 8.9.



با سپاس از توجه اساتید و داوران گرامی

پرسش و پاسخ

محمد طاها مجلسی — دانشکده مهندسی برق و کامپیوتر دانشگاه تهران

Email: taha.majlesi@ut.ac.ir